Matemática para Aprendizaje Automático

Clase 2.1 — Geometría Analítica

Pablo A. Iturralde · Universidad Católica del Uruguay · 2026

Plan de la clase

Geometría del espacio vectorial:

Normas, productos internos, longitudes, distancias, ángulos, ortogonalidad

Bases y bases ortonormales:

Bases, matrices ortogonales, sistemas lineales como problemas de coordenadas

Proyecciones ortogonales:

Proyección sobre rectas y subespacios, ecuación normal

Referencia: MML Capítulo 3 (secciones 3.1–3.6, 3.8)

Disclaimer: las diapositivas de clase son un breve resumen de los temas tratados. Las mismas no sustituyen la lectura de los textos recomendados.

¿Por qué necesitamos geometría?

En ML representamos datos como vectores. Para hacer algo útil con ellos necesitamos poder responder:

- ¿Qué tan **similares** son dos documentos / imágenes / embeddings?
- ¿Cuál es el dato **más cercano** a una consulta?
- ¿Cómo **comprimir** datos perdiendo lo menos posible?
- ¿Cómo **proyectar** datos a un subespacio?

Todas estas preguntas requieren nociones de **distancia**, **ángulo** y **cercanía** — es decir, geometría. El álgebra lineal sola (suma, escalar) no alcanza.

Norma — definición

Una **norma** es una función $\|\cdot\| : V \to \mathbb{R}$ que asigna una "longitud" a cada vector.

Debe satisfacer (para todo $x, y \in V$, $\lambda \in \mathbb{R}$):

1. **Homogeneidad absoluta:** $\|\lambda x\| = |\lambda|\,\|x\|$
2. **Desigualdad triangular:** $\|x + y\| \leq \|x\| + \|y\|$
3. **Definida positiva:** $\|x\| \geq 0$, y $\|x\| = 0 \iff x = \mathbf{0}$

Norma ℓ_2 — norma euclidiana

La norma más común es la **norma euclidiana**:

$$\|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}$$

Es la longitud geométrica del vector x en el espacio. Coincide con la distancia en el sentido físico.

Pero otras nociones de distancia pueden definirse y ser más apropiadas para ciertos problemas.

La familia de normas ℓ_p

Una familia de normas comúnmente usada es la de las normas ℓ_p:

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}, \quad p \geq 1$$

Para cualquier valor de $p \geq 1$, $\| \cdot \|_p$ es una norma válida. Cada valor de p da lugar a una geometría diferente.

Tres casos relevantes en aprendizaje automático: $p = 2$ (ya vista), $p = 1$ y $p = \infty$.

Norma ℓ_1

Cuando $p = 1$, la norma se llama **norma Manhattan** o **norma de la ciudad**:

$$\|x\|_1 = \sum_i |x_i|$$

¿Por qué "Manhattan"? Porque es la distancia que recorrerías caminando por las calles de una ciudad con una grilla cuadrada perfecta, como Manhattan. No es la distancia "en línea recta", sino la distancia "a lo largo de las calles".

Ejemplo: norma ℓ_1 (1/1)

Busco una farmacia y no estoy dispuesto a caminar más de 10 cuadras. La posición inicial es $(0, 0)$ (justo sobre una esquina) y supongamos que existen farmacias en las siguientes esquinas:

$$x_A = (6, 5), \quad x_B = (9, 0), \quad x_C = (-8, 8)$$

donde las coordenadas son cuadras hacia el este y hacia el norte, respectivamente.

Las farmacias "en un radio de 10 cuadras" en el sentido Euclideano, son:

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2} \leq 10$$

Calculando la norma ℓ_2 para cada farmacia:

$$\|x_A\|_2 = \sqrt{6^2 + 5^2} = \sqrt{36 + 25} = \sqrt{61} \approx 7.81$$

¿Pero es A la *más cercana*?

Ejemplo: norma ℓ_1 (2/2)

¡No! La farmacia A está a 7.81 cuadras en línea recta, pero para llegar caminando hay que recorrer 6 cuadras hacia el este y 5 hacia el norte, lo que da una distancia total de:

$$\|x_A\|_1 = |6| + |5| = 11$$

La farmacia B está a:

$$\|x_B\|_1 = |9| + |0| = 9$$

Y la farmacia C está a:

$$\|x_C\|_1 = |-8| + |8| = 16$$

¡La farmacia B es la más cercana caminando! (en el sentido de la norma ℓ_1)

De ahí el nombre "norma de la ciudad" — es la distancia que realmente recorrerías caminando por las calles.

Norma ℓ_∞ — norma del máximo

Cuando $p \to \infty$, la norma ℓ_p converge a la **norma del máximo**:

$$\|x\|_\infty = \lim_{p\to\infty} \left(\sum_i |x_i|^p \right)^{1/p} \approx \left(\max_i |x_i|^p \right)^{1/p} = \max_i |x_i|$$

¿Por qué? Cuando $p \to \infty$, la suma $\sum |x_i|^p$ queda dominada por la componente más grande: si $|x_j| > |x_k|$ para todo $k \neq j$, entonces $|x_j|^p \gg |x_k|^p$. En el límite, solo sobrevive el término más grande.

Cálculo de normas — ejemplo

Ejemplo: $x = [2, -1, 2]^\top$

Norma	Fórmula	Valor
ℓ_1 (Manhattan)	$	2
ℓ_2 (Euclideana)	$\sqrt{4+1+4}$	3
ℓ_∞	$\max(2, 1, 2)$	2

La norma ℓ_2 es la más usada por ser diferenciable en todo punto (excepto el origen), y por coincidir con la noción de distancia en espacios físicos. La norma ℓ_1 no es diferenciable cuando alguna componente es cero.

Ejercicio: normas

Sea $x = [1, -3, 2, 0]^\top$. Calcular $\|x\|_1$, $\|x\|_2$ y $\|x\|_\infty$.

⌛ ...

Ejercicio: normas — solución

$x = [1, -3, 2, 0]^\top$

$\|x\|_1 = 1 + 3 + 2 + 0 = 6$

$\|x\|_2 = \sqrt{1 + 9 + 4 + 0} = \sqrt{14} \approx 3.74$

$\|x\|_\infty = \max(1, 3, 2, 0) = 3$

Verificar: $3 \leq 3.74 \leq 6$ ✓

Entornos unitarios — interpretación geométrica

El conjunto de los puntos a una distancia igual o menor a cierto umbral se conoce como el entorno o bola (*ball* en inglés) de un radio dado.

En términos formales: $\{x : \|x\|_p \leq \rho\}$ es el **entorno unitario** en norma ℓ_p de radio ρ.

Ejercicio: Dibujar los entornos unitarios de radio $\rho = 1$ para las normas ℓ_1, ℓ_2 y ℓ_∞ en $\mathbb{R}^2$.

Entornos unitarios — solución del ejercicio

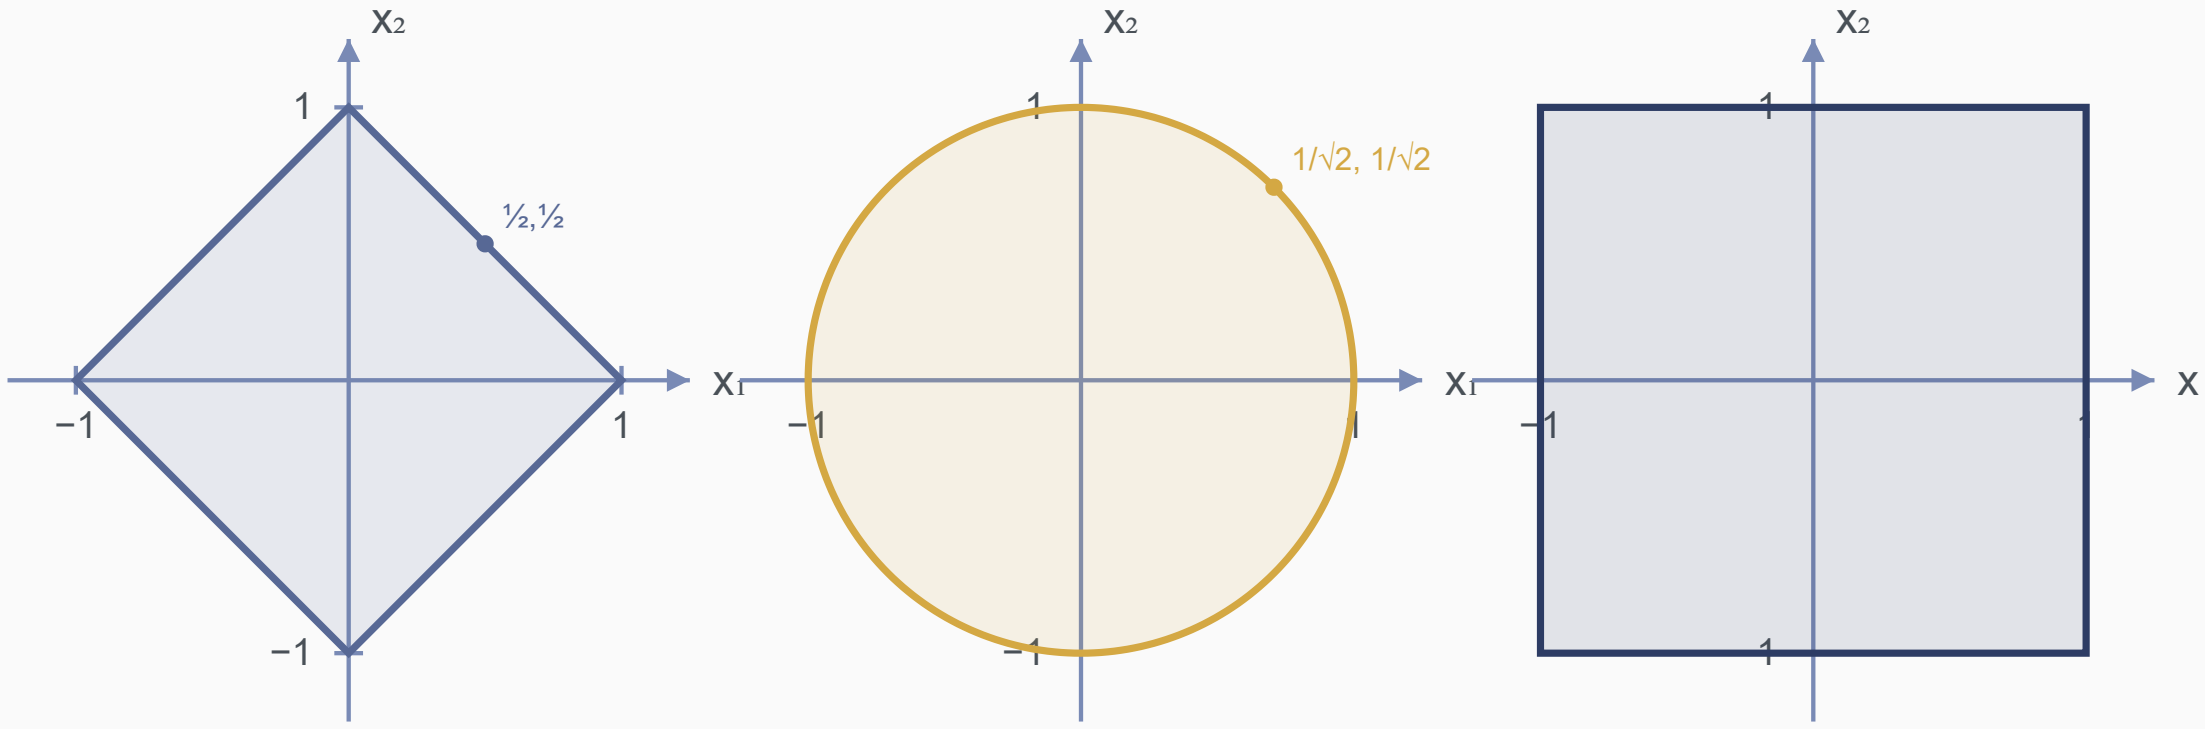

ℓ_1

$|x_1| + |x_2| \leq 1$

ℓ_2

$x_1^2 + x_2^2 \leq 1$

ℓ_∞

$\max(|x_1|,|x_2|) \leq 1$

La familia ℓ_p — evolución de la forma

A medida que p crece, la bola unitaria "se infla" del diamante ($p = 1$) hacia el cuadrado ($p = \infty$):

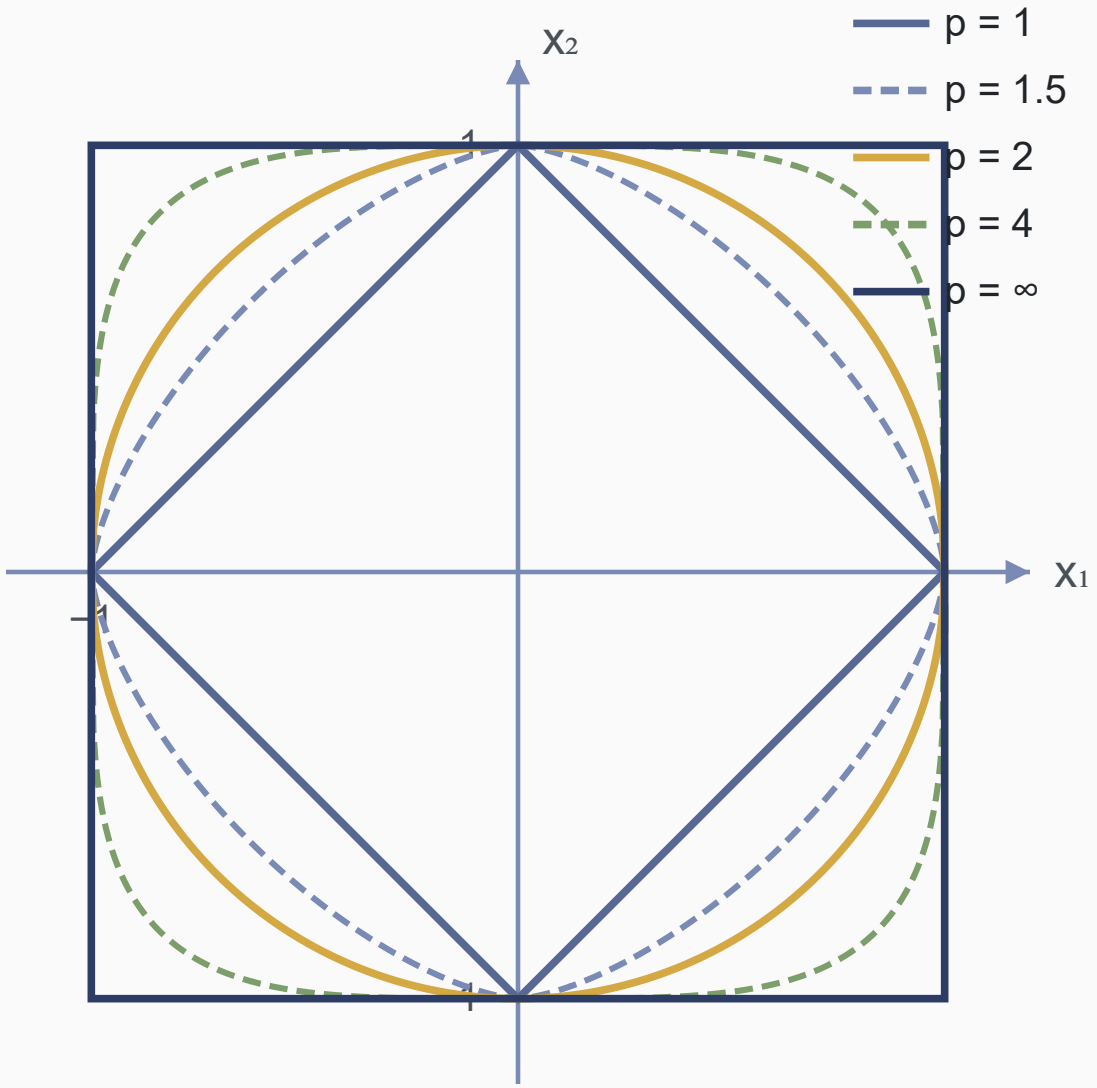

¿Qué norma elegir? Depende del problema

La elección de norma es una **decisión de diseño**, no una cuestión matemática (no hay una norma correcta o más precisa: hay una que se ajusta mejor a la realidad del problema).

"Todas las farmacias a 10 cuadras": ¿cuál es la distancia correcta? Si camino por la grilla, ℓ_1. Si vuelo un dron, ℓ_2.

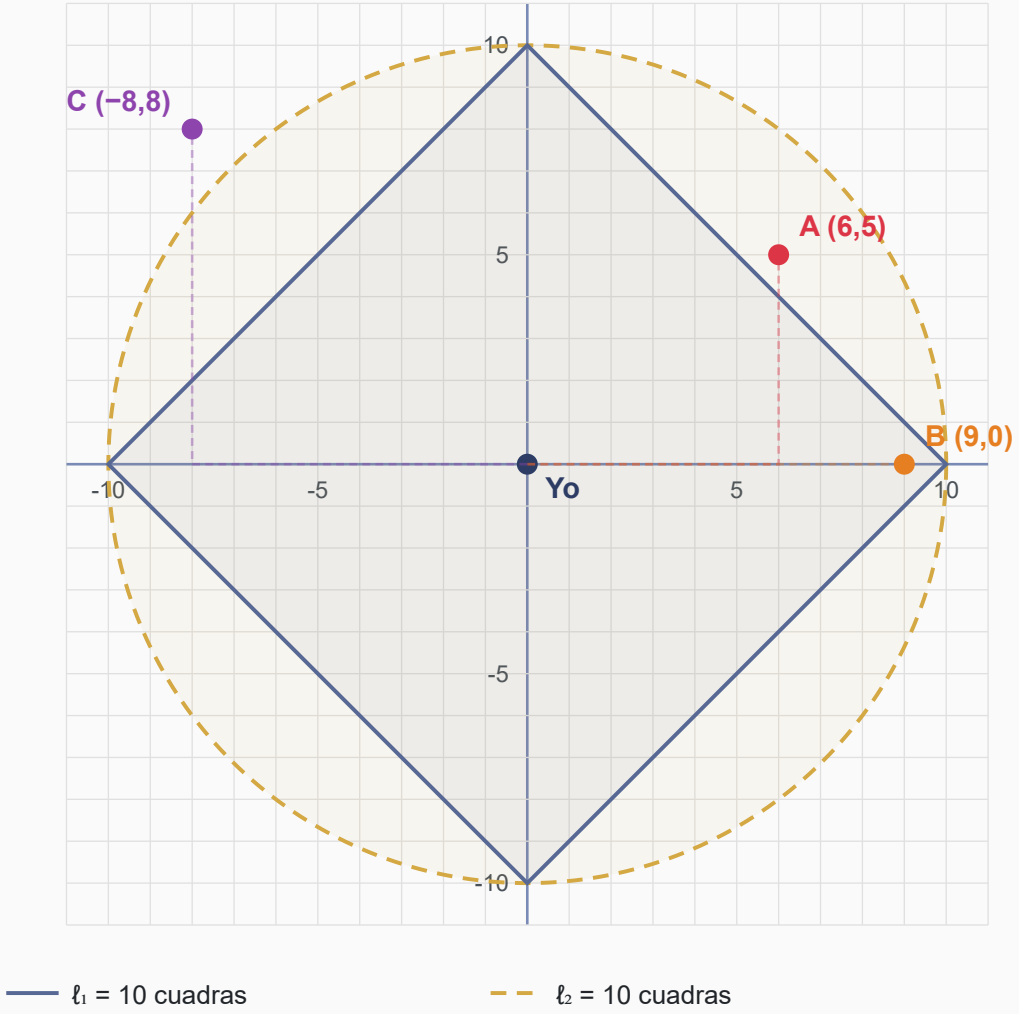

Producto interno — definición general

Un **producto interno** es una función $\langle \cdot, \cdot \rangle : V \times V \to \mathbb{R}$ que satisface:

1. **Bilineal:** lineal en cada argumento
2. **Simétrico:** $\langle x, y \rangle = \langle y, x \rangle$
3. **Definido positivo:** $\langle x, x \rangle > 0$ para todo $x \neq \mathbf{0}$, y $\langle \mathbf{0}, \mathbf{0} \rangle = 0$

Producto punto:

$$\langle x, y \rangle = \sum_{i=1}^{n} x_i y_i = x^\top y$$

El producto punto $x^\top y$ es el caso más familiar, pero no es el único.

Producto interno general en $\mathbb{R}^n$

La forma general en $\mathbb{R}^n$: $\langle x, y \rangle = x^\top A y$ donde A es simétrica definida positiva.

Nota: una matriz es simétrica si $A = A^\top$ y definida positiva si satisface que $x^\top A x > 0$ para todo $x \neq \mathbf{0}$.

El producto interno da geometría al espacio

Todo producto interno induce automáticamente nociones de:

- Longitud:

$$\|x\| = \sqrt{\langle x, x \rangle}$$

- Distancia:

$$d(x, y) = \|x - y\|$$

- Ángulo:

$$\cos\theta = \frac{\langle x, y \rangle}{\|x\| \, \|y\|}$$

Distancia

La **distancia** entre x e y es la longitud del vector diferencia:

$$d(x, y) = \|x - y\| = \sqrt{\langle x - y,\ x - y \rangle}$$

Con el producto punto, esto es la **distancia euclidiana**:

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

La distancia d satisface las propiedades de una **métrica:**

1. $d(x, y) \geq 0$, con igualdad $\iff$ $x = y$
2. $d(x, y) = d(y, x)$
3. $d(x, z) \leq d(x, y) + d(y, z)$

Desigualdad de Cauchy-Schwarz

Para todo $x, y \in V$:

$$|\langle x, y \rangle| \leq \|x\| \, \|y\|$$

La igualdad se da $\iff$ x e y son linealmente dependientes (uno es múltiplo del otro).

Consecuencia: $\dfrac{\langle x, y \rangle}{\|x\| \, \|y\|} \in [-1, 1]$

Esto nos permite definir ángulos, porque el resultado está en el rango del coseno.

Ángulo entre vectores

Para $x, y \neq \mathbf{0}$, el **ángulo** ω entre ellos:

$$\cos \omega = \frac{\langle x, y \rangle}{\|x\| \, \|y\|}$$

Valen las nociones usuales: un coseno cercano a 1 → ángulo pequeño, cercano a 0 → ángulo de 90°, cercano a -1 → ángulo de 180°.

El coseno en sí mismo puede utilizarse como una (pseudo-)métrica (no cumple con la definición formal dada anteriormente), llamada **similitud coseno**.

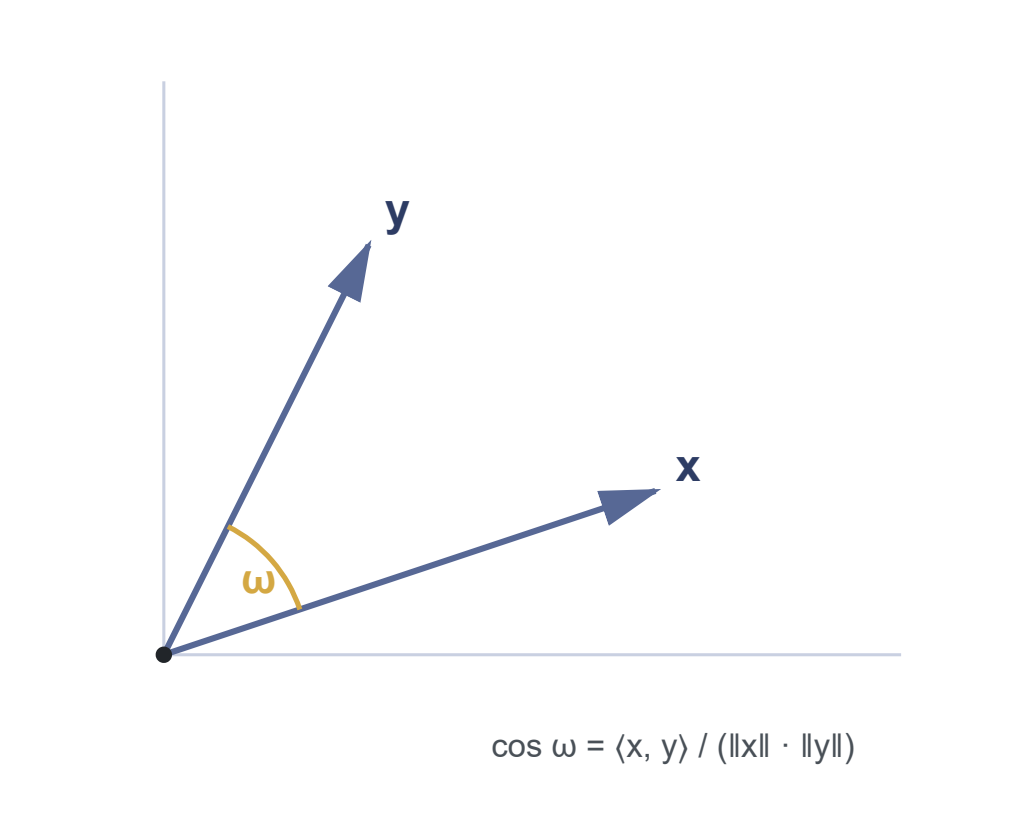

Ejercicio: ángulo entre vectores

Calcular el ángulo entre $x = [3, 1]^\top$ e $y = [-1, 2]^\top$ (producto punto).

⌛ ...

Ejercicio: ángulo — solución

$x = [3, 1]^\top$, $y = [-1, 2]^\top$

$$\cos\omega = \frac{x^\top y}{\|x\|\,\|y\|} = \frac{-3+2}{\sqrt{10}\cdot\sqrt{5}} = \frac{-1}{\sqrt{50}} \approx -0.141$$

$$\omega = \arccos(-0.141) \approx 98.1^\circ$$

El ángulo es **obtuso** — el coseno es negativo.

Ortogonalidad y bases ortonormales

Ortogonalidad

Dos vectores son **ortogonales** si su producto interno es cero:

$$x \perp y \iff \langle x, y \rangle = 0$$

El ángulo entre vectores ortogonales es 90° ($\cos 90^\circ = 0$).

Ejemplo: $u = [2, -1, 0]^\top$ y $v = [1, 2, 5]^\top$ son ortogonales:

$u^\top v = 2 - 2 + 0 = 0$ ✓

Nota: El producto interno define la noción de ángulo. Con otro producto interno (p. ej. $A = \mathrm{diag}(2, 1, 1)$) los vectores pueden no ser ortogonales, ya que $\langle u, v \rangle_A = 4 - 2 + 0 = 2 \neq 0$.

Ejercicio: ortogonalidad

¿Son ortogonales los siguientes pares de vectores?

(a) $u = [1, 2, -1]^\top$, $v = [3, 0, 3]^\top$

(b) $u = [1, 1, 1]^\top$, $v = [1, -2, 1]^\top$

⌛ ...

Ejercicio: ortogonalidad — solución

(a) $u^\top v = 3 + 0 - 3 = 0$ → **sí** ✓

(b) $u^\top v = 1 - 2 + 1 = 0$ → **sí** ✓

Notar que (b) no es "visualmente obvio" en $\mathbb{R}^3$ — la ortogonalidad a veces sorprende.

Bases — repaso

Una **base** de V es un conjunto de vectores linealmente independientes que generan V.

La dimensión de V es la cantidad de vectores en cualquier base (p. ej. en $\mathbb{R}^n$: una base tiene exactamente n vectores.)

Todo vector x se escribe de forma **única** como combinación lineal de la base. Los coeficientes son las **coordenadas** de x en esa base.

Hay infinitas bases posibles. En un espacio de dimensión n alcanza con cualquier conjunto de n vectores linealmente independientes. La base canónica de $\mathbb{R}^n$ es un ejemplo, pero hay muchas otras.

Base ortonormal (ONB)

Una base $\{b_1, \ldots, b_n\}$ de V es una **base ortonormal** (ONB) si:

$$\langle b_i, b_j \rangle = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}$$

Ejemplo: $q_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$, $q_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ es una ONB de $\mathbb{R}^2$.

Verificar: $q_1^\top q_2 = \frac{1}{2}(1 - 1) = 0$ ✓, $\|q_1\| = \|q_2\| = 1$ ✓

Ejercicio: ¿es base? ¿es ortonormal?

Para cada conjunto, indicar si es base de $\mathbb{R}^3$, y si lo es, si es ortonormal.

$$(a)\ \left\{ \begin{bmatrix}1\\0\\0\end{bmatrix}, \begin{bmatrix}0\\1\\0\end{bmatrix}, \begin{bmatrix}0\\0\\1\end{bmatrix} \right\} \qquad (b)\ \left\{ \begin{bmatrix}1\\1\\0\end{bmatrix}, \begin{bmatrix}0\\1\\1\end{bmatrix}, \begin{bmatrix}1\\0\\1\end{bmatrix} \right\}$$

$$(c)\ \left\{ \begin{bmatrix}2\\0\\0\end{bmatrix}, \begin{bmatrix}0\\3\\0\end{bmatrix}, \begin{bmatrix}0\\0\\5\end{bmatrix} \right\} \qquad (d)\ \left\{ \begin{bmatrix}1\\2\\3\end{bmatrix}, \begin{bmatrix}2\\4\\6\end{bmatrix}, \begin{bmatrix}0\\1\\0\end{bmatrix} \right\}$$

$$(e)\ \left\{ \frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\\0\end{bmatrix}, \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}, \begin{bmatrix}0\\0\\1\end{bmatrix} \right\} \qquad (f)\ \left\{ \begin{bmatrix}1\\0\\0\end{bmatrix}, \begin{bmatrix}0\\1\\0\end{bmatrix} \right\}$$

⌛ ...

Ejercicio: bases — solución

(a) Base canónica. Ortonormal. ✓

(b) Base (vectores l.i., verificar que $\det \neq 0$). Ortogonal: no ($b_1 \cdot b_2 = 1 \neq 0$). Normal: no ($\|b_1\| = \sqrt{2} \neq 1$).

(c) Base (vectores l.i.). Ortogonal: sí (productos cruzados = 0). Normal: no ($\|b_1\| = 2$). Es ortogonal pero no ortonormal.

(d) No es base: $b_2 = 2b_1$ → linealmente dependientes.

(e) Base. Ortogonal: sí. Normal: sí ($\|b_i\| = 1$ para cada i). **Ortonormal** ✓

(f) No es base de $\mathbb{R}^3$: solo 2 vectores, no generan el espacio. (Es base de un subespacio de dimensión 2.)

Matrices ortogonales - definición

Una matriz cuadrada $A \in \mathbb{R}^{n \times n}$ es **ortogonal** si sus columnas son ortonormales:

$$A^\top A = I = AA^\top \qquad \Longrightarrow \qquad A^{-1} = A^\top$$

Invertir es simplemente transponer.

Consecuencia: Las columnas de A (a_i) son ortogonales entre sí ($a_i^\top a_j = 0$ para $i \neq j$) y de norma 1 ($a_i^\top a_i = 1$). **Son una ONB** de $\mathbb{R}^n$.

Matrices ortogonales como transformaciones lineales: $y = Ax$.

- **Preservan longitudes:** $\|Ax\| = \|x\|$
- **Preservan ángulos** entre vectores: $\langle Ax, Ay \rangle = \langle x, y \rangle$

Las transformaciones ortogonales son **rotaciones o reflexiones**: mueven los vectores sin deformarlos (la geometría se preserva).

Sistemas lineales $Ax = b$ como un problema geométrico

Resolver un sistema $Ax = b$ es lo mismo que **expresar b como combinación lineal de las columnas de A**:

$$Ax = \begin{bmatrix} | & & | \\ a_1 & \cdots & a_n \\ | & & | \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = x_1 a_1 + \cdots + x_n a_n = b$$

El vector x contiene las **coordenadas** de b en la base dada por las columnas de A.

Tipo de sistema y geometría

¿Tiene $Ax = b$ solución? Depende de si las columnas de A forman una base:

Situación	Columnas de A	Tipo de sistema
$A \in \mathbb{R}^{n \times n}$, rango n	Base de $\mathbb{R}^n$	Bien determinado: solución **única**
Más filas que columnas ($m > n$)	No generan $\mathbb{R}^m$	Sobredeterminado: en general **sin solución** exacta
Más columnas que filas ($n > m$)	L.d.: sobran vectores	Subdeterminado: en general **infinitas soluciones**

¿Por qué las ONB son especiales?

Con una base arbitraria B: para encontrar las coordenadas λ de x, hay que resolver:

$$B\lambda = x \implies \lambda = B^{-1}x$$

Con una ONB: como $B^\top B = I$, simplemente:

$$\lambda = B^\top x$$

Cada coordenada es un **producto punto**: $\lambda_i = b_i^\top x$. Sin inversiones, sin sistemas.

Coordenadas en una ONB — visualmente

Dada una ONB, las coordenadas de cualquier vector se obtienen por productos punto.

En una base arbitraria, necesitaríamos resolver un sistema lineal.

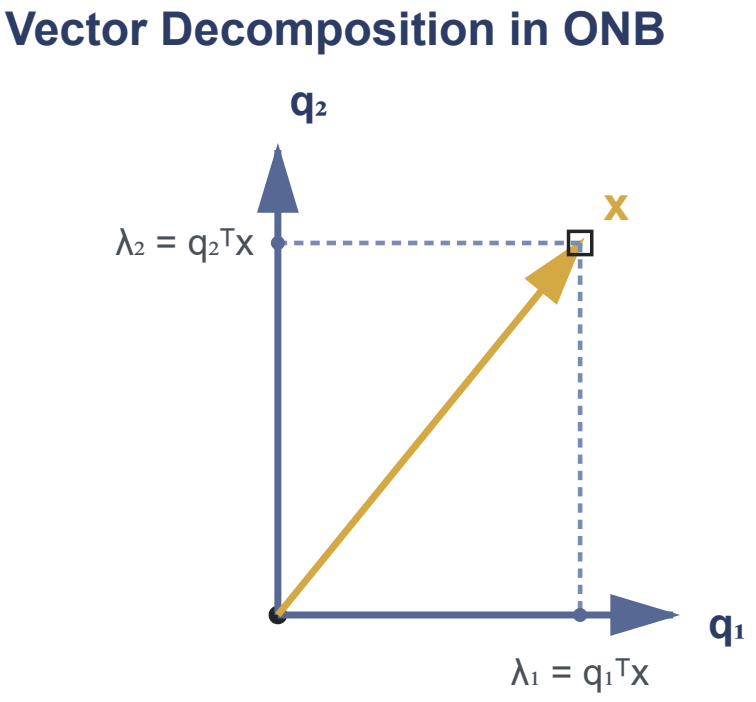

$$\mathbf{x} = \lambda_1 \mathbf{q}_1 + \lambda_2 \mathbf{q}_2$$

Ejercicio: coordenadas en una ONB

La siguiente es una ONB de $\mathbb{R}^3$:

$$q_1 = \frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix}, \quad q_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}, \quad q_3 = \frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\-2\end{bmatrix}$$

Encontrar las coordenadas de $x = [4, 2, 0]^\top$ en esta base.

Planteo: buscamos $\lambda_1, \lambda_2, \lambda_3$ tales que $\lambda_1 q_1 + \lambda_2 q_2 + \lambda_3 q_3 = x$. En forma matricial: $Q\lambda = x$ donde $Q = [q_1\ q_2\ q_3]$. Como Q es ortogonal: $\lambda = Q^\top x$.

⌛ ...

Ejercicio: coordenadas en ONB — solución

$$\lambda_1 = q_1^\top x = \frac{4+2+0}{\sqrt{3}} = 2\sqrt{3} \qquad \lambda_2 = q_2^\top x = \frac{4-2}{\sqrt{2}} = \sqrt{2} \qquad \lambda_3 = q_3^\top x = \frac{4+2+0}{\sqrt{6}} = \sqrt{6}$$

Verificación:

$$\lambda_1 q_1 + \lambda_2 q_2 + \lambda_3 q_3 = \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \\ 0 \end{bmatrix} = x \checkmark$$

Con una base arbitraria habría que resolver un sistema 3×3.

Proyecciones ortogonales

¿Por qué proyectar?

En muchos problemas de datos, interesa encontrar el punto de un subespacio generado por un modelo que está más cerca de un dato dado.

Este modelo puede representar restricciones físicas, hipótesis de trabajo, o simplemente ser una forma de resumir la información.

Esto es una **proyección**: dado un punto fuera de un subespacio, encontrar el punto del subespacio más cercano.

Proyección sobre una recta

Dado $x \in \mathbb{R}^n$ y una recta que pasa por el origen (U), queremos halllar el punto $\pi_U(x) \in U$ **más cercano** a x.

¿Cómo hallarlo?

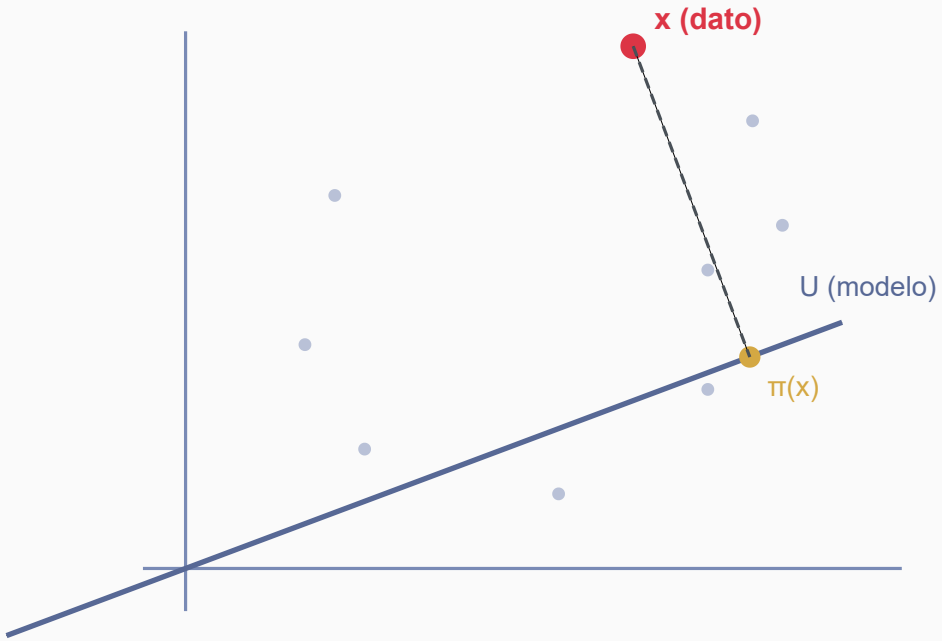

Proyección en el sentido euclideano

Cualquier recta por el origen es un subespacio unidimensional $U = \mathrm{span}\{b\}$, donde b es un vector no nulo que define la dirección de la recta.

Como $\pi_U(x)$ está en la recta: $\pi_U(x) = \lambda b$.

"Más cercano", en el sentido euclideano, $\implies$ el residuo $x - \pi_U(x)$ es **ortogonal** a b:

$$\langle x - \lambda b,\ b \rangle = 0$$

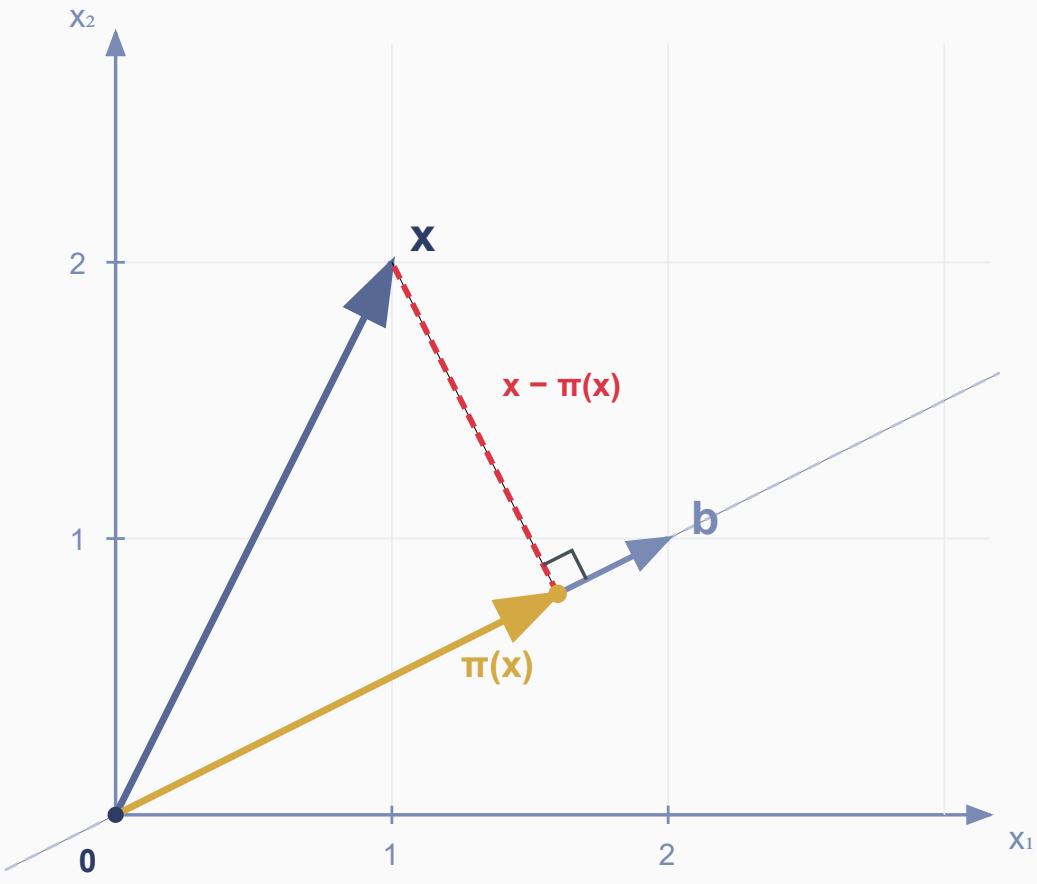

Proyección sobre una recta — derivación

Encontrar λ:

$$\langle x - \lambda b, b \rangle = 0 \implies \lambda = \frac{b^\top x}{\|b\|^2}$$

Si $\|b\| = 1$: $\lambda = b^\top x$ (un simple producto punto).

Proyección: $\pi_U(x) = \lambda b = \frac{b^\top x}{\|b\|^2}\, b$

Matriz de proyección: $\boxed{P_\pi = \frac{bb^\top}{\|b\|^2}}$

Notar: $bb^\top$ es un producto **externo** (matriz rango 1), no el producto punto $b^\top b$.

Ejercicio: proyección sobre una recta

$$b = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}, \quad x = \begin{bmatrix} 3 \\ 1 \\ 0 \end{bmatrix}$$

Encontrar: λ, $\pi_U(x)$, y verificar que el residuo es ortogonal a b.

⏳ ...

Ejercicio: proyección sobre una recta — solución

$\|b\|^2 = 1 + 1 + 4 = 6, \quad b^\top x = 3 - 1 + 0 = 2, \quad \lambda = \frac{2}{6} = \frac{1}{3}$

$$\pi_U(x) = \frac{1}{3}\begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1/3 \\ -1/3 \\ 2/3 \end{bmatrix}$$

Residuo: $x - \pi_U(x) = [\frac{8}{3}, \frac{4}{3}, -\frac{2}{3}]^\top$

Verificar ortogonalidad: $b^\top(x - \pi_U(x)) = \frac{8}{3} - \frac{4}{3} - \frac{4}{3} = 0$ ✓

Proyección sobre subespacios generales

Ahora $U \subseteq \mathbb{R}^n$ es un subespacio de dimensión m con base $B = [b_1 \cdots b_m]$.

$$\pi_U(x) = B\lambda, \quad \lambda \in \mathbb{R}^m$$

Condición de ortogonalidad: el residuo $x - B\lambda$ debe ser $\perp$ a **todos** los vectores de la base:

$$B^\top(x - B\lambda) = 0$$

La misma lógica que en la recta, extendida a m direcciones.

Ecuación normal

$$B^\top(x - B\lambda) = 0 \implies \boxed{B^\top B\,\lambda = B^\top x}$$

Esta es la **ecuación normal**.

Solución (si las columnas de B son l.i., $B^\top B$ es invertible):

$$\lambda = (B^\top B)^{-1} B^\top x$$

Proyección: $\pi_U(x) = B(B^\top B)^{-1} B^\top x$

Matriz de proyección: $P_\pi = B(B^\top B)^{-1} B^\top$

Propiedades de la matriz de proyección

$$P_\pi = B(B^\top B)^{-1}B^\top$$

- $P_\pi^2 = P_\pi$ — **idempotente**: proyectar dos veces = proyectar una vez
- $P_\pi^\top = P_\pi$ — **simétrica**
- $\mathrm{rk}(P_\pi) = \mathrm{rk}(B)$

Longitud de la proyección: $\|\pi_U(x)\| = |\cos\omega| \cdot \|x\|$

donde ω es el ángulo entre x y b.

Igual que en trigonometría: la proyección es la "sombra" de x sobre la recta.

Simplificación con ONB

Si la base B es **ortonormal** ($B^\top B = I$):

$$\lambda = B^\top x \qquad \text{y} \qquad P_\pi = BB^\top$$

No hay inversión de matrices. Solo productos punto.

Esta simplificación es una de las razones para querer bases ortonormales. En la próxima clase veremos cómo construir una ONB a partir de una base cualquiera (Gram-Schmidt) y cómo eso lleva a la descomposición QR.

Ejercicio: proyección sobre un subespacio 2D

$$U = \operatorname{span}\left\{ \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \right\} \subset \mathbb{R}^3, \quad x = \begin{bmatrix} 4 \\ 4 \\ 0 \end{bmatrix}$$

Encontrar λ, $\pi_U(x)$, y verificar que el residuo es ortogonal a la base.

⌛ ...

Ejercicio: subespacio 2D — solución (1/2)

$$B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad B^\top B = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad B^\top x = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$$

Ecuación normal ($\det(B^\top B) = 3$):

$$\lambda = \frac{1}{3} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 4 \\ 4 \end{bmatrix} = \begin{bmatrix} 4/3 \\ 4/3 \end{bmatrix}$$

$$\pi_U(x) = B\lambda = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 4/3 \\ 4/3 \end{bmatrix} = \begin{bmatrix} 4/3 \\ 4/3 \\ 8/3 \end{bmatrix}$$

Ejercicio: subespacio 2D — solución (2/2)

Residuo: $x - \pi_U(x) = [\frac{8}{3}, \frac{8}{3}, -\frac{8}{3}]^\top$

Verificar ortogonalidad:

$b_1^\top(x - \pi_U(x)) = \frac{8}{3} + 0 - \frac{8}{3} = 0 \checkmark$

$b_2^\top(x - \pi_U(x)) = 0 + \frac{8}{3} - \frac{8}{3} = 0 \checkmark$

Norma del residuo: $\|x - \pi_U(x)\| = \frac{8}{3}\sqrt{3} \approx 4.62$

Complemento ortogonal

Dado un vector $x \in V$ y un subespacio $U \subseteq V$, se cumple que:

$$x = \underbrace{\pi_U(x)}_{\in U} + \underbrace{(x - \pi_U(x))}_{\in U^\perp}$$

Todo vector se descompone de forma **única** en una parte dentro del subespacio y una parte ortogonal a él.

$U^\perp$ es el **complemento ortogonal** de U, y $\dim(U) + \dim(U^\perp) = \dim(V)$.

Proyección sobre el complemento ortogonal

Si $P_\pi = B(B^\top B)^{-1}B^\top$ proyecta sobre U, entonces:

$$P_{\pi^\perp} = I - P_\pi$$

proyecta sobre $U^\perp$. Dado un vector x:

$$P_{\pi^\perp}\, x = x - \pi_U(x)$$

Restar la proyección de x sobre U produce la componente de x que es ortogonal a U.

Resumen

Producto interno $\Longrightarrow$ norma, distancia, ángulo $\Longrightarrow$ ortogonalidad $\Longrightarrow$ ONB, proyecciones

Cada concepto se construye sobre el anterior.

Las normas ℓ_p son una familia paramétrica; la elección depende del problema. El producto interno induce toda la geometría del espacio.

Las ONB simplifican los cálculos (coordenadas por producto punto, inversiones por transposiciones).

Las proyecciones resuelven el problema de la mejor aproximación sujeto a pertenecer a un subespacio. La matriz de proyección tiene propiedades especiales (idempotente, simétrica).

Próxima clase: ¿Cómo construir una ONB a partir de una base cualquiera? → Gram-Schmidt y descomposición QR.

Bibliografía

Principal: MML 3.1–3.6, 3.8

Complementaria:

- Strang, *Introduction to Linear Algebra*, Cap. 4
- Trefethen & Bau, *Numerical Linear Algebra*, Lectures 7–8

¿Preguntas?

pablo.iturralde@ucu.edu.uy