Matemática para Aprendizaje Automático

Notas de Clase — Análisis de Componentes Principales (PCA)

Universidad Católica del Uruguay • 2026

> ***Referencia principal:*** *Deisenroth, Faisal & Ong, Mathematics for Machine Learning, Cap. 10 (secciones 10.1–10.6).* ***Referencias complementarias:*** *Strang, Introduction to Linear Algebra, Cap. 6; Nica, Linear Algebra and Optimization for Machine Learning, sección 7.3.4.*

1. Reducción de dimensionalidad

1.1 El problema

Dado un conjunto de n datos $\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^d$, buscamos una representación en un espacio de menor dimensión $\mathbb{R}^m$ con $m < d$ (a veces $m \ll d$). Es decir, buscamos un mapa

$$f : \mathbb{R}^d \to \mathbb{R}^m$$

que asigne a cada dato $\mathbf{x}_i$ un vector reducido $\mathbf{z}_i = f(\mathbf{x}_i)$ con m coordenadas en lugar de d.

Esta representación reducida permite comprimir datos, reducir ruido, construir modelos de menor complejidad y mitigar la *maldición de la dimensionalidad* (Bellman, 1961; ver también MML sección 8.6). En general, la reducción implica pérdida de información: no podemos recuperar $\mathbf{x}_i$ exactamente a partir de $\mathbf{z}_i$, pero sí es posible preservar una representación adecuada de los datos a ciertos efectos.

1.2 Reducción lineal

Si nos restringimos al caso en que f es lineal, podemos representar dicha transformación mediante una matriz $P \in \mathbb{R}^{d \times m}$:

$$\mathbf{z} = P^\top \mathbf{x} \in \mathbb{R}^m$$

Los vectores reducidos $\mathbf{z}$ representan los productos internos de $\mathbf{x}$ sobre las columnas de P.

Una interpretación posible de esta operación es que elegimos representar los datos solo en función de su proyección sobre el subespacio $\operatorname{span}(\mathbf{p}_1, \ldots, \mathbf{p}_m) \subset \mathbb{R}^d$, ignorando la componente de los datos ortogonal a dichos vectores.

El problema de reducción de dimensionalidad lineal se reduce entonces a un problema de **proyección**: proyectar los datos sobre un subespacio de dimensión m y registrar sus m coordenadas en dicho subespacio en alguna base.

Como tenemos libertad de elegir la base en la que elegimos representar este subespacio (sin cambiar el subespacio mismo), es conveniente elegir una matriz cuyas columnas $\mathbf{p}_1, \ldots, \mathbf{p}_m$ forman una base ortonormal ($P^\top P = I_m$), por motivos ya vistos en el curso.

La pregunta a responder entonces es: *¿cuál es el mejor subespacio de dimensión m para representar los datos?*

---

2. PCA: Análisis de Componentes Principales

PCA (*Principal Component Analysis*) responde la pregunta anterior proponiendo dos criterios de optimalidad equivalentes.

2.1 Formulación 1: minimizar el error de reconstrucción

La primera formulación de PCA sustituye la pregunta anterior por la siguiente: dado el vector reducido $\mathbf{z} = P^\top \mathbf{x}$, ¿cuánto distorsiono el vector original $\mathbf{x}$ al sustituirlo por el vector reducido?

Dada la proyección que implica la reducción lineal, lo mejor que podemos recuperar del dato original es su proyección sobre el subespacio en cuestión:

$$\hat{\mathbf{x}} = P\mathbf{z} = PP^\top \mathbf{x}$$

Donde se definió el vector $\hat{\mathbf{x}}$ como la proyección ortogonal de $\mathbf{x}$ sobre $\operatorname{span}(P)$. La diferencia $\mathbf{x} - \hat{\mathbf{x}}$ es el **error de reconstrucción**: la componente de $\mathbf{x}$ que se pierde al proyectar.

PCA busca el subespacio (es decir, la matriz P) que minimiza el error de reconstrucción total en el sentido de la norma ℓ_2 o euclideana:

$$\min_{P \in \mathbb{R}^{d \times m},\ P^\top P = I_m} \sum_{i=1}^{n} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2$$

Donde la búsqueda está sujeta a la restricción $P^\top P = I_m$ ya que elegimos utilizar una base ortonormal del espacio.

Resultado. Sea $S = XX^\top \in \mathbb{R}^{d \times d}$, donde $X = [\mathbf{x}_1 \cdots \mathbf{x}_n]$ es la matriz de datos (cada dato como columna). Entonces la solución es

$$P = [\mathbf{u}_1 \cdots \mathbf{u}_m],$$

donde $\mathbf{u}_1, \ldots, \mathbf{u}_m$ son los vectores propios de S asociados a los m valores propios más grandes $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_m$.

Las direcciones $\mathbf{u}_1, \ldots, \mathbf{u}_m$ se denominan **componentes principales** de los datos, y de ahí el nombre del algoritmo. Se numeran según el valor propio asociado: la **primera componente principal** (PC1) es $\mathbf{u}_1$, la **segunda componente principal** (PC2) es $\mathbf{u}_2$, y así sucesivamente.

El error de reconstrucción en este subespacio es:

$$\sum_{i=1}^{n} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 = \sum_{j=m+1}^{d} \lambda_j,$$

es decir, la suma de los $d - m$ valores propios más pequeños de S. La demostración de este resultado puede encontrarse en la sección 5.

2.2 Formulación 2: maximizar la varianza preservada

Una visión alternativa del mismo problema es: en lugar de buscar reducir los errores, buscar el subespacio de dimensión m que preserva lo más posible el "tamaño" de los datos proyectados, e implícitamente las distancias relativas entre los mismos:

$$\max_{P \in \mathbb{R}^{d \times m},\ P^\top P = I_m} \sum_{i=1}^{n} \|\hat{\mathbf{x}}_i\|^2$$

La cantidad $\sum_i \|\hat{\mathbf{x}}_i\|^2$ mide cuánta de la energía (o varianza) original de los datos se preserva en la proyección.

Resultado. La solución es la misma: $P = [\mathbf{u}_1 \cdots \mathbf{u}_m]$, los m vectores propios de S con mayores valores propios. La varianza preservada es:

$$\sum_{i=1}^{n} \|\hat{\mathbf{x}}_i\|^2 = \sum_{j=1}^{m} \lambda_j$$

2.3 Equivalencia: el teorema de Pitágoras

La equivalencia entre ambas formulaciones surge directamente de la geometría de la proyección. Para cualquier dato $\mathbf{x}$ y su proyección $\hat{\mathbf{x}} = PP^\top \mathbf{x}$, el residuo $\mathbf{x} - \hat{\mathbf{x}}$ es ortogonal a $\hat{\mathbf{x}}$ (por definición de proyección ortogonal). Por el teorema de Pitágoras:

$$\|\mathbf{x}\|^2 = \|\hat{\mathbf{x}}\|^2 + \|\mathbf{x} - \hat{\mathbf{x}}\|^2$$

Sumando sobre todos los datos:

$$\underbrace{\sum_{i=1}^{n} \|\mathbf{x}_i\|^2}_{\text{constante (no depende de } P)} = \sum_{i=1}^{n} \|\hat{\mathbf{x}}_i\|^2 + \sum_{i=1}^{n} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2$$

Como el lado izquierdo es fijo (los datos no cambian para distintas matrices P), maximizar el primer término del lado derecho equivale a minimizar el segundo. Las dos formulaciones son dos caras del mismo problema.

Para el caso en que seleccionamos la matriz P óptima, la igualdad anterior puede expresarse en términos de los valores propios de S como: $\sum_{j=1}^{d} \lambda_j = \sum_{j=1}^{m} \lambda_j + \sum_{j=m+1}^{d} \lambda_j$

2.4 Centrado de datos y la matriz de covarianza

Los resultados anteriores son ciertos para cualquier matriz de datos X, pero típicamente se desea trabajar con datos centrados: $\sum_i \mathbf{x}_i = \mathbf{0}$. Si esto no se cumple en los datos originales, se puede centrar previo a

realizar el resto de los cálculos:

$$\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i, \qquad \tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}$$

La intuición detrás de este centrado es que, en lugar de buscar el subespacio óptimo sobre un espacio con un origen de referencia arbitrario, es preferible considerar un cambio de origen de coordenadas donde el centro de los datos es el origen del problema: buscamos las direcciones de mayor dispersión *alrededor* del centro, no respecto a un origen arbitrario.

Con datos centrados, la matriz $\Sigma = \frac{1}{n}\tilde{X}\tilde{X}^\top$ es la **matriz de covarianza** de los datos (este concepto se formaliza en Probabilidad y Estadística). Al reconstruir datos en coordenadas originales, se debe sumar $\bar{\mathbf{x}}$ nuevamente: $\hat{\mathbf{x}}_i^{\text{orig}} = \hat{\tilde{\mathbf{x}}}_i + \bar{\mathbf{x}}$.

2.5 El algoritmo de PCA

Con los resultados anteriores podemos describir el procedimiento para obtener la representación óptima (en el sentido dado por PCA) para un conjunto de datos $\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^d$ y una dimensión objetivo m:

1. **Centrar:** calcular $\bar{\mathbf{x}} = \frac{1}{n}\sum_i \mathbf{x}_i$ y definir $\tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}$.
2. **Construir** la matriz de datos centrados $\tilde{X} = [\tilde{\mathbf{x}}_1 \cdots \tilde{\mathbf{x}}_n] \in \mathbb{R}^{d\times n}$.
3. **Calcular** $S = \tilde{X}\tilde{X}^\top \in \mathbb{R}^{d\times d}$.
4. **Descomponer:** obtener valores propios $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$ y vectores propios ortonormales $\mathbf{u}_1, \ldots, \mathbf{u}_d$ de S (por el teorema espectral, S es simétrica semidefinida positiva, por lo que sus valores propios son no negativos y sus vectores propios son ortogonales).
5. **Seleccionar** los primeros m vectores propios: $P = [\mathbf{u}_1 \cdots \mathbf{u}_m] \in \mathbb{R}^{d\times m}$.
6. **Proyectar:**
   - Datos reducidos (en $\mathbb{R}^m$): $\mathbf{z}_i = P^\top \tilde{\mathbf{x}}_i$
   - Datos reconstruidos (en $\mathbb{R}^d$): $\hat{\mathbf{x}}_i = P\mathbf{z}_i + \bar{\mathbf{x}} = PP^\top\tilde{\mathbf{x}}_i + \bar{\mathbf{x}}$

Nota. Los vectores $\mathbf{z}_i$ y $\hat{\mathbf{x}}_i$ representan la misma información geométrica — los datos proyectados sobre el subespacio — expresada en bases distintas. $\mathbf{z}_i \in \mathbb{R}^m$ usa la base $\{\mathbf{u}_1, \ldots, \mathbf{u}_m\}$ y tiene m coordenadas. $\hat{\mathbf{x}}_i \in \mathbb{R}^d$ usa la base canónica de $\mathbb{R}^d$ y tiene d coordenadas, pero vive en un subespacio de dimensión m.

2.6 Elección de m: varianza explicada

En algunos problemas, m es definido de antemano. Pero comúnmente m es un parámetro de diseño: no sabemos **cuánto** queremos reducir la dimensión del espacio de antemano.

Una forma usual de elegir m es considerar la proporción de varianza o energía explicada para distintos valores de m:

$$\rho(m) = \frac{\sum_{j=1}^{m}\lambda_j}{\sum_{j=1}^{d}\lambda_j} \in [0,1]$$

$\rho(m)$ mide qué fracción de la energía, o tamaño, total de los datos capturan los primeros m componentes. Un criterio usado en la práctica es elegir el menor valor m tal que $\rho(m) \geq \tau$ para un umbral deseado. En

el ejemplo dado por la figura que se presenta debajo, se toma $\tau = 0.95$, que es un valor umbral comun, y se obtiene $m = 5$ como la dimensión necesaria para preservar el 95% de la energía.

Por lo visto anteriormente, la varianza o energía explicada es la contracara del error relativo de reconstrucción:

$$e(m) = 1 - \rho(m) = \frac{\sum_{j=m+1}^{d} \lambda_j}{\sum_{j=1}^{d} \lambda_j} \in [0, 1]$$

Por tanto, si elegimos la dimensión m que preserva, por ejemplo, el 95% de la varianza o energía de los datos, tendremos un error de reconstrucción menor al 5%.

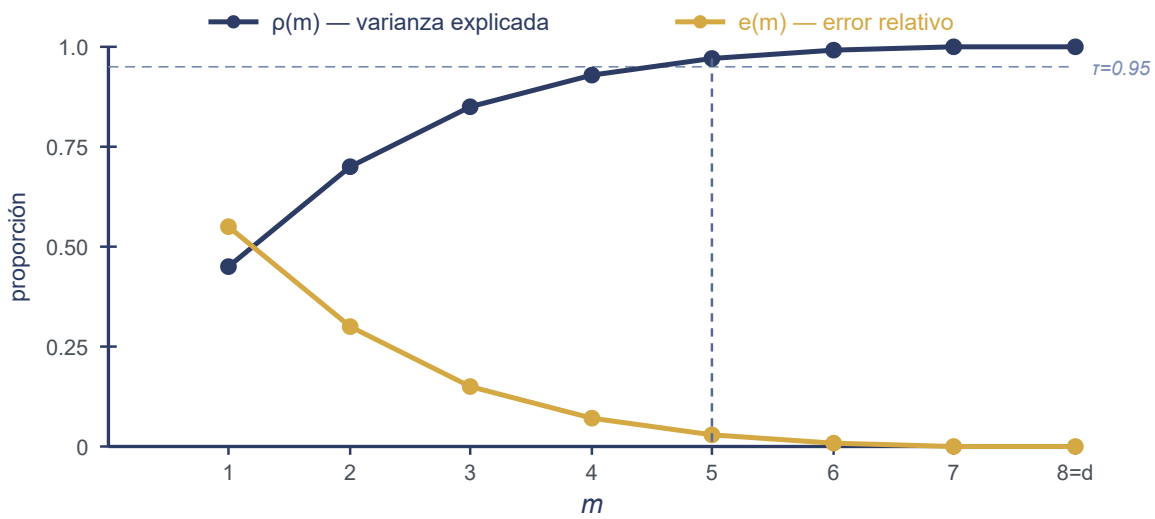

3. Ejemplos de cálculo

3.1 Ejemplo en $\mathbb{R}^2$: reducción a una recta

Consideremos cuatro datos en $\mathbb{R}^2$:

$$\mathbf{x}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 4 \\ 3 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 6 \\ 5 \end{pmatrix}, \quad \mathbf{x}_4 = \begin{pmatrix} 8 \\ 7 \end{pmatrix}$$

Paso 1: centrar. La media es $\bar{\mathbf{x}} = \frac{1}{4}(2+4+6+8,\ 1+3+5+7)^\top = (5,\ 4)^\top$. Los datos centrados son:

$$\tilde{\mathbf{x}}_1 = \begin{pmatrix} -3 \\ -3 \end{pmatrix}, \quad \tilde{\mathbf{x}}_2 = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \quad \tilde{\mathbf{x}}_3 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \tilde{\mathbf{x}}_4 = \begin{pmatrix} 3 \\ 3 \end{pmatrix}$$

Paso 2: calcular S.

$$\tilde{X} = \begin{pmatrix} -3 & -1 & 1 & 3 \\ -3 & -1 & 1 & 3 \end{pmatrix}, \qquad S = \tilde{X}\tilde{X}^\top = \begin{pmatrix} 20 & 20 \\ 20 & 20 \end{pmatrix}$$

Paso 3: valores y vectores propios de S.

$\det(S - \lambda I) = \lambda^2 - 40\lambda = \lambda(\lambda - 40) = 0$, de donde $\lambda_1 = 40$, $\lambda_2 = 0$.

- $\lambda_1 = 40$: $(S - 40I)\mathbf{u} = \mathbf{0}$ da $\mathbf{u}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix}$.
- $\lambda_2 = 0$: $\mathbf{u}_2 = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\end{pmatrix}$.

Paso 4: proyectar ($m = 1$). $P = \mathbf{u}_1 = \frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\end{pmatrix}$.

Datos reducidos: $z_i = \mathbf{u}_1^\top \tilde{\mathbf{x}}_i$:

$$z_1 = -3\sqrt{2}, \quad z_2 = -\sqrt{2}, \quad z_3 = \sqrt{2}, \quad z_4 = 3\sqrt{2}$$

En este caso $\lambda_2 = 0$, por lo que el error de reconstrucción es cero: los datos centrados ya vivían en un subespacio de dimensión 1 (la recta $x_1 = x_2$), y PCA lo descubrió. La varianza explicada es $\rho(1) = 40/40 = 1$.

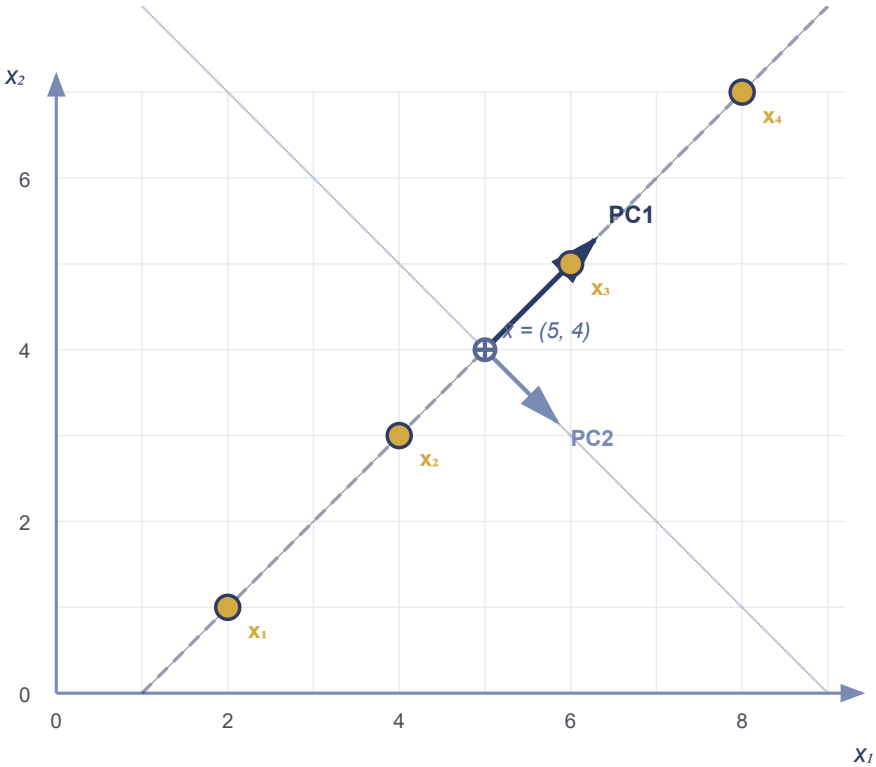

Los datos están alineados sobre PC1: error de reconstrucción = 0, ρ(1) = 1

3.2 Ejemplo en $\mathbb{R}^3$: reducción a un plano

Consideremos tres datos (ya centrados) en $\mathbb{R}^3$:

$$\mathbf{x}_1 = \begin{pmatrix}1\\2\\0\end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix}-1\\0\\0\end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix}0\\-2\\0\end{pmatrix}$$

Matriz S:

$$S = XX^\top = \begin{pmatrix}2 & 2 & 0\\2 & 8 & 0\\0 & 0 & 0\end{pmatrix}$$

Valores propios: $\det(S - \lambda I) = -\lambda[(2-\lambda)(8-\lambda) - 4] = -\lambda(\lambda^2 - 10\lambda + 12) = 0$.

$$\lambda_1 = 5 + \sqrt{13} \approx 8.61, \quad \lambda_2 = 5 - \sqrt{13} \approx 1.39, \quad \lambda_3 = 0$$

Vectores propios. Para $\lambda_1 = 5 + \sqrt{13}$, resolvemos $(S - \lambda_1 I)\mathbf{u} = \mathbf{0}$:

$$\begin{pmatrix} -3-\sqrt{13} & 2 & 0 \\ 2 & 3-\sqrt{13} & 0 \\ 0 & 0 & -(5+\sqrt{13}) \end{pmatrix} \mathbf{u} = \mathbf{0} \implies \mathbf{u}_1 = \frac{1}{\|\cdot\|} \begin{pmatrix} 2 \\ 3+\sqrt{13} \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.30 \\ 0.95 \\ 0 \end{pmatrix}$$

La tercera fila fuerza $u_3 = 0$, por lo que el vector propio vive en el plano $x_3 = 0$.

Análogamente, para $\lambda_2 = 5 - \sqrt{13}$, la entrada $(3,3)$ de $S - \lambda_2 I$ es $-(5-\sqrt{13}) \neq 0$, lo que nuevamente fuerza $u_3 = 0$:

$$\mathbf{u}_2 = \frac{1}{\|\cdot\|} \begin{pmatrix} 2 \\ 3-\sqrt{13} \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.95 \\ -0.30 \\ 0 \end{pmatrix}$$

Para $\lambda_3 = 0$: $\mathbf{u}_3 = (0,0,1)^\top$. El tercer valor propio es cero porque los tres datos viven en el plano $x_3 = 0$.

Con $m = 1$: $P = \mathbf{u}_1$, varianza explicada $\rho(1) = \lambda_1/(\lambda_1 + \lambda_2) \approx 86\%$.

Con $m = 2$: $P = [\mathbf{u}_1\ \mathbf{u}_2]$, varianza explicada $\rho(2) = (\lambda_1 + \lambda_2)/(\lambda_1 + \lambda_2) = 100\%$, y el error de reconstrucción es $\lambda_3 = 0$.

---

4. Demostración: PCA como maximización de varianza

Mostramos que el subespacio que maximiza $\sum_i \|\hat{\mathbf{x}}_i\|^2$ está dado por los vectores propios de S con mayores valores propios. Procedemos primero con el caso $m = 1$ (buscar la mejor dirección) y luego extendemos.

4.1 Caso $m = 1$: la mejor dirección

Buscamos un vector unitario $\mathbf{p} \in \mathbb{R}^d$, $\|\mathbf{p}\| = 1$, que maximice la varianza de la proyección:

$$\sum_{i=1}^{n} \|\hat{\mathbf{x}}_i\|^2 = \sum_{i=1}^{n} (\mathbf{p}^\top \mathbf{x}_i)^2 = \mathbf{p}^\top \left(\sum_{i=1}^{n} \mathbf{x}_i \mathbf{x}_i^\top \right) \mathbf{p} = \mathbf{p}^\top S\, \mathbf{p}$$

El problema se convierte en:

$$\max_{\mathbf{p} \in \mathbb{R}^d,\ \|\mathbf{p}\|=1} \mathbf{p}^\top S\, \mathbf{p}$$

Esta es la maximización del **cociente de Rayleigh** de S (visto en clase 3.1). Por el teorema espectral, $S = \sum_{j=1}^{d} \lambda_j \mathbf{u}_j \mathbf{u}_j^\top$. Escribiendo $\mathbf{p} = \sum_j c_j \mathbf{u}_j$ con $\sum_j c_j^2 = 1$:

$$\mathbf{p}^\top S\, \mathbf{p} = \sum_{j=1}^{d} \lambda_j c_j^2$$

Es un promedio ponderado de los valores propios con pesos c_j^2 que suman 1. Se maximiza asignando todo el peso al mayor valor propio: $c_1 = 1$, $c_j = 0$ para $j \geq 2$. Es decir, $\mathbf{p}^* = \mathbf{u}_1$ y el máximo es λ_1.

4.2 Extensión a m componentes

Para el segundo componente, buscamos $\mathbf{p}_2$ unitario y ortogonal a $\mathbf{u}_1$ que maximice $\mathbf{p}_2^\top S\, \mathbf{p}_2$. La restricción $\mathbf{p}_2 \perp \mathbf{u}_1$ implica que, al escribir $\mathbf{p}_2 = \sum_j c_j \mathbf{u}_j$, se tiene $c_1 = 0$. El problema se reduce a:

$$\max_{\substack{c_2,\ldots,c_d \\ \sum_{j=2}^d c_j^2 = 1}} \sum_{j=2}^d \lambda_j c_j^2,$$

que es exactamente el mismo problema de Rayleigh pero sobre los valores propios restantes $\lambda_2, \ldots, \lambda_d$. La solución es $c_2 = 1$, $c_j = 0$ para $j \geq 3$, es decir $\mathbf{p}_2^* = \mathbf{u}_2$ con valor λ_2.

Por inducción, el k-ésimo componente se obtiene maximizando en el complemento ortogonal de $\{\mathbf{u}_1, \ldots, \mathbf{u}_{k-1}\}$, lo que fuerza $c_1 = \cdots = c_{k-1} = 0$ y reduce el problema al cociente de Rayleigh sobre $\lambda_k, \ldots, \lambda_d$. La solución es $\mathbf{p}_k^* = \mathbf{u}_k$, y la varianza total capturada por los m componentes es $\sum_{j=1}^m \lambda_j$. $\square$

5. Demostración como minimización del error

En la sección 4 mostramos que el subespacio que maximiza $\sum_i \|\hat{\mathbf{x}}_i\|^2$ es el dado por los m vectores propios de S con mayores valores propios, y que la varianza preservada es $\sum_{j=1}^m \lambda_j$.

Por el teorema de Pitágoras (sección 2.3), para cada dato:

$$\|\mathbf{x}_i\|^2 = \|\hat{\mathbf{x}}_i\|^2 + \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2$$

Sumando sobre todos los datos y reordenando:

$$\sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 = \sum_{i=1}^n \|\mathbf{x}_i\|^2 - \sum_{i=1}^n \|\hat{\mathbf{x}}_i\|^2$$

El primer término del lado derecho es constante (no depende de P). Por lo tanto, minimizar el error de reconstrucción equivale a maximizar $\sum_i \|\hat{\mathbf{x}}_i\|^2$, cuya solución ya conocemos. El subespacio óptimo es el mismo: $P = [\mathbf{u}_1 \cdots \mathbf{u}_m]$.

El error de reconstrucción resulta:

$$\sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 = \underbrace{\sum_{j=1}^d \lambda_j}_{\text{varianza total}} - \underbrace{\sum_{j=1}^m \lambda_j}_{\text{varianza explicada/preservada}} = \underbrace{\sum_{j=m+1}^d \lambda_j}_{\text{error de reconstrucción}} \qquad \square$$

Donde se usó que

$$\sum_{i=1}^n \|\mathbf{x}_i\|^2 = \|X\|_F^2 = \operatorname{tr}(XX^\top) = \operatorname{tr}(S) = \sum_{j=1}^d \lambda_j$$