Matemática para Aprendizaje Automático

Syllabus 2026

Ingeniería en Inteligencia Artificial y Ciencia de Datos • Universidad Católica del Uruguay

Resumen

Objetivos

Resultados de aprendizaje

Conocimientos previos requeridos

Equipo docente

Horarios

Clases sincrónicas

Clases de consulta

Temario

Unidad 1: Álgebra Lineal para Aprendizaje Automático — Geometría y Cómputo 5 semanas

Unidad 2: Sistemas Lineales 4 semanas

Unidad 3: Análisis Multivariado 4 semanas

Unidad 4: Introducción a la Optimización 3 semanas

Cronograma tentativo

Plan de evaluación

Detalle de las instancias de evaluación

Aprobación del curso

Modalidad de la retroalimentación

Política académica

Entregas fuera de fecha

Uso de inteligencia artificial

Integridad académica y plagio

Comunicación

Recursos

Bibliografía principal

Bibliografía complementaria

Otras referencias

Resumen

Este curso profundiza la formación matemática de los estudiantes para entender e implementar algoritmos de aprendizaje automático. El curso introduce temas de álgebra lineal numérica, análisis multivariado, optimización y factorización de matrices. Los estudiantes adquirirán las herramientas matemáticas esenciales para diseccionar algoritmos, entender comportamientos de modelos y navegar por espacios de datos de alta dimensión. Al completar el curso, los estudiantes estarán equipados con las herramientas matemáticas necesarias para desempeñarse en el campo del aprendizaje automático.

El curso busca ser práctico y orientado a aplicaciones en aprendizaje automático, evitando la teoría matemática abstracta. Está diseñado para ser accesible a estudiantes con formación matemática básica en álgebra y cálculo en una variable, y al mismo tiempo ofrecer profundidad y rigor para quienes deseen explorar más a fondo los fundamentos matemáticos. La experiencia práctica es un pilar del curso: se incluye una cantidad significativa de ejercicios de programación y laboratorios. Al mismo tiempo, se enfatiza la comprensión de los conceptos matemáticos detrás de los algoritmos, no solo su implementación.

Objetivos

Que el estudiante sea capaz de comprender, formular y resolver los problemas matemáticos fundamentales que aparecen en el aprendizaje automático, tanto de forma analítica como computacional.

Resultados de aprendizaje

- Comprender la geometría de los espacios vectoriales (subespacios, proyecciones, cambio de base) y utilizarla para interpretar y resolver problemas de aprendizaje automático como PCA y regresión.
- Elegir y aplicar factorizaciones matriciales (LU, QR, SVD, descomposición espectral) según las propiedades del problema, evaluando costo computacional y estabilidad numérica.
- Calcular gradientes, jacobianos y hessianos de funciones multivariables, y aplicar la regla de la cadena en grafos computacionales (backpropagation).
- Formular problemas de optimización con y sin restricciones, y resolverlos mediante descenso del gradiente y multiplicadores de Lagrange.
- Implementar en Python los algoritmos y métodos numéricos estudiados, e interpretar críticamente sus resultados.

Conocimientos previos requeridos

Para poder seguir apropiadamente y aprovechar el curso, es necesario tener conocimientos previos en:

- Programación básica (preferiblemente en Python). Ej.: Programación 1.
- Álgebra lineal básica. Ej.: Álgebra Lineal.
- Cálculo diferencial e integral en una variable. Ej.: Cálculo 1.

No se requieren conocimientos de probabilidad, estadística, ni cálculo multivariado.

Equipo docente

- **Profesor Responsable**: Dr. Ing. Pablo Iturralde — pablo.iturralde@ucu.edu.uy
- **Asistente de Enseñanza**: Juan Paroli — j.paroli@ucu.edu.uy
- **Asistente de Enseñanza**: Mercedes Barrutia — m.barrutia@ucu.edu.uy

Horarios

Clases sincrónicas

- **Martes y Jueves**: 8:00 – 11:00, salón 214 (Edificio Central)

Clases de consulta

- **Martes**: 17:00 – 18:00

Temario

Unidad 1: Álgebra Lineal para Aprendizaje Automático — Geometría y Cómputo 5 semanas

Repaso de álgebra lineal: vectores, matrices, operaciones fundamentales, sistemas de ecuaciones, núcleo, imagen, rango y nulidad. Espacios vectoriales, subespacios, bases, cambio de base y proyecciones. Ortogonalidad, proceso de Gram-Schmidt y descomposición QR. Autovalores y autovectores, diagonalización y teorema espectral. Aspectos computacionales: costo de algoritmos matriciales, representación en punto flotante, condicionamiento y estabilidad numérica. Aplicación: análisis de componentes principales (PCA).

Unidad 2: Sistemas Lineales 4 semanas

Resolución de sistemas lineales en sus distintas variantes. Caso compatible determinado: descomposición LU, pivoteo, factorización de Cholesky. Caso sobredeterminado: mínimos cuadrados y ecuaciones normales. Los cuatro subespacios fundamentales. Descomposición en valores singulares (SVD): definición, interpretación geométrica y aproximaciones de bajo rango. Pseudoinversa y solución unificada de Ax=b. Caso subdeterminado: solución de mínima norma y regularización.

Unidad 3: Análisis Multivariado 4 semanas

Funciones escalares de varias variables: derivadas parciales, derivadas direccionales, regla de la cadena. Derivadas de segundo orden y matriz hessiana. Serie de Taylor multivariable. Mínimos, máximos y puntos de silla. Funciones vectoriales: matriz jacobiana y regla de la cadena generalizada. Diferenciación automática y backpropagation. Integración en una y varias variables.

Unidad 4: Introducción a la Optimización 3 semanas

Formulación de problemas de optimización: función objetivo, restricciones, convexidad. Método de Newton. Descenso del gradiente y variantes. Optimización con restricciones: multiplicadores de Lagrange.

Cronograma tentativo

Sem.	Fechas	Unidad	Clase 1	Clase 2	Laboratorio	Hoja	Lectura principal	Lectura compl.
1	09/03 – 13/03	U1	Introducción al curso.	Repaso de álgebra lineal. Álgebra computacional. Núcleo, imagen, rango y nulidad.	Operaciones con matrices y vectores en NumPy.	1.1	MML 2.1–2.7, 3.1–3.3	ILA 1–3; LAOML 1–2
2	16/03 – 20/03	U1	Álgebra y geometría. Proyecciones. Descomposición QR.	Autovalores y autovectores. Diagonalización. Teorema espectral.	Proyecciones y ortogonalización. Implementación de QR.	1.2	MML 3.4–3.8, 4.1–4.4	ILA 4, 6; LAOML 2.7, 3.1–3.3
3	23/03 – 27/03	U1	Costo computacional. Métodos computacionales para autovalores.	Precisión numérica. Condicionamiento y estabilidad.	Costo computacional y precisión numérica. Método de la potencia y algoritmo QR.	1.3	LAOML 3.5	NLA 10, 12–15, 24–29; SCI 1.2–1.3, 4.5
—	30/03 – 03/04	*Semana Santa*	—	—	—			
4	06/04 – 10/04	U1	Aplicación: PCA.	Buffer.	PCA.	1.4	MML 10.1–10.6	LAOML 7.3.4; ILA 7
5	13/04 – 17/04	U1	Revisión.	**Examen 1**	—			
6	20/04 – 24/04	U2	Solución de Ax=b. Descomposición LU. Pivoteo. Cholesky.	Sistemas sobredeterminados. Mínimos cuadrados. Ecuaciones normales. QR para mínimos cuadrados.	LU y Cholesky. Resolución de sistemas compatibles determinados.	2.1	MML 4.3; ILA 2, 4.3	NLA 11, 20–23; LAOML 2.5; MC 3–4
7	27/04 – 01/05	U2	Ax=b general. Los cuatro subespacios. SVD. Aproximaciones de bajo rango.	Pseudoinversa. Solución unificada de Ax=b. Conexión con PCA.	Mínimos cuadrados y QR. Ajuste de rectas como proyección.	2.2	MML 4.5–4.6; ILA 7	NLA 4–5, 31; LAOML 7.2–7.4; MC 5
8	04/05 – 08/05	U2	Sistemas subdeterminados. Solución de mínima norma. Ridge regression.	Aplicaciones: triangulación, calibración de cámaras.	SVD. Aproximación de bajo rango. Aplicación: triangulación.	2.3	MML 9.2; ILA 3.3	LAOML 4.7; BH12
9	11/05 – 15/05	U2	Revisión.	**Examen 2**	—			

Sem.	Fechas	Unidad	Clase 1	Clase 2	Laboratorio	Hoja	Lectura principal	Lectura compl.
10	18/05 – 22/05	U3	Funciones de varias variables. Gradientes.	Derivadas de segundo orden.	Derivadas parciales numéricas.	3.1	MML 5.1–5.2, 5.7–5.8	SC 14.1–14.7
11	25/05 – 29/05	U3	Funciones vectoriales y sus derivadas.	Backpropagation.	Autograd y backpropagation.	3.2	MML 5.3–5.6	GBC 6.5; LAOML 11; BB 8
12	01/06 – 05/06	U3	Integración unidimensional.	Integración multivariable.	Integración numérica.	3.3	SC 5, 7.1, 15.1–15.8	SCI 8
13	08/06 – 12/06	U3	Revisión.	**Examen 3**	—			
14	15/06 – 19/06	U4	Optimización sin restricciones.	Descenso del gradiente y variantes.	Optimización numérica.	4.1	MML 7.1, 7.3; SC 14.7	LAOML 4–5; NW 2–3; BV 9
15	22/06 – 26/06	U4	Optimización con restricciones. Multiplicadores de Lagrange.	Optimización con restricciones de desigualdad.	Optimización con restricciones.	4.2	MML 7.2; SC 14.8	LAOML 6; NW 12, 15; BV 5
16	29/06 – 03/07	U4	Revisión.	**Examen 4**	—			

Plan de evaluación

Instancia de evaluación	Evidencia	Temporalidad	Peso
Pruebas escritas	Evaluación escrita e individual de los conceptos teóricos y prácticos de cada unidad	4 instancias, al final de cada unidad	60%
Quizzes semanales	Evaluación de conocimientos adquiridos en la semana	Todas las semanas	20%
Ejercicios programables	Implementación práctica de algoritmos en Python (notebooks)	Distribuido a lo largo del semestre	10%
Participación	Participación activa en clase, entrega de hojas de ejercicios, y compromiso general	Todas las semanas	10%

Detalle de las instancias de evaluación

Pruebas escritas (60%): Se realizan al final de cada unidad. Son individuales, en papel y lápiz, sin recursos electrónicos. Incluyen tanto problemas analíticos como ejercicios de programación en papel. La última prueba escrita incluirá preguntas de todas las unidades y servirá como instancia de remediación para estudiantes que hayan reprobado una única unidad (ver sección de aprobación).

Quizzes semanales (20%): Evaluaciones cortas administradas de forma asincrónica a través de la plataforma del curso. Se publican los viernes y deben entregarse antes del miércoles siguiente. Los quizzes admiten intentos ilimitados, y se requiere obtener el 100% para recibir el crédito de cada quiz.

Ejercicios programables (10%): Laboratorios de programación en Python (notebooks). Se otorgan puntos por la entrega en tiempo y forma, independientemente de la corrección de los mismos.

Participación (10%): Puntos otorgados por el docente en base a la participación activa en clase, la entrega de hojas de ejercicios, y el compromiso general con el curso durante las sesiones presenciales y los canales virtuales.

Aprobación del curso

Para aprobar el curso es necesario aprobar las cuatro unidades que lo componen. La aprobación de cada unidad se logra con el **60%** del puntaje de dicha unidad. La última prueba escrita incluirá preguntas de todas las unidades. Los estudiantes que hayan reprobado una única unidad deberán aprobar esa unidad en la última prueba escrita. Los estudiantes que reprueben más de una unidad deberán recursar.

La calificación final se computa como el promedio ponderado de las cuatro unidades (25% cada una).

Modalidad de la retroalimentación

- Los ejercicios programables y las hojas de ejercicios serán trabajados en clase y revisados en tiempo real.
- Los quizzes son corregidos automáticamente y se mostrará la retroalimentación inmediatamente después de la entrega.
- Las pruebas escritas serán corregidas y devueltas en un plazo de 10 días hábiles, con retroalimentación detallada sobre los errores y aciertos.

Política académica

Entregas fuera de fecha

Se aceptará hasta un máximo de 5 días totales de demora (sumados entre todas las entregas del curso) sin penalización. A partir de ese límite, se aplicará una penalización del 33% de la calificación por día de demora. Esta política aplica a los ejercicios programables (laboratorios). Los quizzes semanales tienen fecha límite estricta y no admiten entrega tardía.

Uso de inteligencia artificial

Se permite el uso de herramientas de inteligencia artificial (ChatGPT, Copilot, Claude, etc.) como apoyo para el aprendizaje: entender conceptos, explorar ideas, depurar código, o buscar explicaciones alternativas.

No se permite utilizar herramientas de IA para resolver ejercicios evaluados ni para verificar respuestas antes de entregarlas.

Se espera que cada estudiante sea capaz de resolver todos los problemas del curso por sí mismo. Las pruebas escritas (60% de la calificación) se realizan en papel y lápiz, sin ningún recurso electrónico, e

incluyen tanto problemas analíticos como de programación. La capacidad de resolver problemas sin asistencia electrónica es una habilidad fundamental que este curso busca desarrollar.

Integridad académica y plagio

Todas las evaluaciones son estrictamente individuales. Se fomenta la discusión de problemas y enfoques de solución entre compañeros, pero no se permite compartir ningún material escrito (soluciones, código, informes, etc.) ni realizar trabajo en nombre de otro estudiante.

Como criterio orientador: la colaboración es aceptable si podría realizarse por teléfono (discutir ideas y enfoques), pero no si requiere compartir documentos o pantallas.

En caso de detectarse plagio o copia, se iniciará un proceso disciplinario según lo previsto por el reglamento estudiantil de la UCU. El reglamento establece que constituyen faltas gravísimas el fraude o intento de fraude en cualquier instancia de evaluación, incluyendo prestar o recibir ayuda fraudulenta, o presentar como propio un trabajo de terceros, sea en forma parcial o total. Las sanciones previstas van desde la pérdida de la asignatura y la suspensión de la calidad de estudiante hasta la expulsión de la Universidad.

Comunicación

- **Dudas generales del curso**: Foro en la plataforma del curso
- **Consultas específicas**: pablo.iturralde@ucu.edu.uy
- **Soporte técnico** (entorno de programación, instalación, etc.): j.paroli@ucu.edu.uy, m.barrutia@ucu.edu.uy

Recursos

Bibliografía principal

Las abreviaturas entre corchetes se usan en el cronograma para indicar las lecturas de cada semana.

- **[MML]** Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press. Versión gratuita
- **[LAOML]** Aggarwal, C. C. (2020). *Linear Algebra and Optimization for Machine Learning: A Textbook*. Springer. Versión en Timbó
- **[ILA]** Strang, G. (2023). *Introduction to Linear Algebra* (6th ed.). Wellesley-Cambridge Press / SIAM.
- **[SC]** Stewart, J. (2015). *Cálculo de varias variables* (8th ed.). Cengage Learning.

Bibliografía complementaria

- **[NLA]** Trefethen, L. N., & Bau, D. (1997). *Numerical Linear Algebra*. SIAM.
- **[MC]** Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (4th ed.). Johns Hopkins University Press.
- **[SCI]** Heath, M. T. (2018). *Scientific Computing: An Introductory Survey* (2nd ed.). SIAM.

- **[BV]** Boyd, S., & Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press. Versión gratuita
- **[NW]** Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization* (2nd ed.). Springer.
- **[GBC]** Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Versión gratuita
- **[BB]** Bishop, C. M., & Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer.
- **[BH12]** Barata, J. C., & Hussein, M. S. (2012). The Moore–Penrose pseudoinverse: A tutorial review of the theory. *Brazilian Journal of Physics*, 42, 146–165.

Otras referencias

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer. Versión gratuita
- Goldberg, D. (1991). What every computer scientist should know about floating-point arithmetic. *ACM Computing Surveys*, 23(1), 5–48.

Este syllabus puede sufrir modificaciones menores durante el transcurso del semestre. Cualquier cambio será comunicado oportunamente a través de los canales oficiales del curso.