Matemática para Aprendizaje Automático

Clase 2 — Datos, vectores y geometría analítica

Pablo A. Iturralde · Universidad Católica del Uruguay · 2026

Hoy

1. **Datos como vectores** — de píxeles, palabras y sonido a objetos algebraicos
2. **Repaso de álgebra lineal** — espacios, bases, rango, transformaciones, imagen y núcleo
3. **Normas, productos internos, distancias** — cómo medir tamaño, similitud y ángulo
4. **Laboratorio 1** — álgebra lineal en NumPy

Disclaimer: las diapositivas de clase son un breve resumen de los temas tratados. Las mismas no sustituyen la lectura de los textos recomendados.

Parte I

Datos como vectores

Las computadoras son máquinas de calcular

Las computadoras son extraordinariamente buenas en:

- **Almacenar** enormes cantidades de números
- **Realizar** operaciones aritméticas a velocidades absurdas
- **Seguir** instrucciones deterministas sin cansarse

Para aprovechar esa capacidad en cualquier problema, necesitamos **traducir el problema a números y operaciones**.

Recordatorio: ¿cómo funciona el aprendizaje automático?

En la clase anterior vimos:

Programación clásica: Datos + Reglas → Resultados
Aprendizaje automático: Datos + Resultados → Reglas

En la práctica, todo eso es **cómputo numérico masivo:**

- Los datos de entrada son **representaciones numéricas** (números, vectores, matrices)
- Los resultados esperados también son **números** (etiquetas, valores)
- Las reglas aprendidas son **funciones matemáticas** con parámetros ajustados

¿Qué tiene que ver con la clase anterior?

La clase pasada vimos que el aprendizaje automático opera con **datos + resultados → reglas**, y que cada etapa del pipeline tiene una traducción matemática.

Hoy nos enfocamos en la **primera etapa**: representar los datos.

La pregunta central:
¿Cómo convertimos datos del mundo real — imágenes, texto, sonido — en objetos matemáticos con los que la computadora pueda operar?

Pensemos en tipos de datos comunes

En ML trabajamos con datos muy variados: tablas numéricas, texto, audio, imágenes, video, grafos...

Cada uno tiene una estructura distinta. Pero todos necesitan terminar como **números en la computadora**.

Vamos a recorrer varios casos y pensar cómo representar cada uno.

Empecemos por lo más simple: datos tabulares

¿Cómo representarían esta tabla para dársela a una computadora?

Paciente	Edad	Peso (kg)	Presión	Glucosa
1	45	72	130	95
2	32	68	120	88
3	57	85	145	110

Datos tabulares → vectores y matrices

Paciente	Edad	Peso (kg)	Presión	Glucosa
1	45	72	130	95
2	32	68	120	88
3	57	85	145	110

Cada paciente es un **vector** en $\mathbb{R}^4$: $$x_1 = \begin{bmatrix} 45 \\ 72 \\ 130 \\ 95 \end{bmatrix}$$

Toda la tabla es una **matriz** $X \in \mathbb{R}^{3\times 4}$

La matriz es una **colección de vectores**: cada fila es un dato.

¿Y el texto?

¿Cómo convertirían texto en números?

Texto → vectores

Hay varias estrategias, de la más simple a la más sofisticada:

- *One-hot:* si el vocabulario tiene 10.000 palabras, cada palabra es un vector de $\mathbb{R}^{10000}$ con un solo 1 y el resto 0.
- *Bag-of-words:* un documento es un vector que cuenta cuántas veces aparece cada palabra.
- *Embeddings:* cada palabra (o frase) se mapea a un vector denso en $\mathbb{R}^d$ (ej. $d = 768$), aprendido de datos.

En todos los casos: **un texto se convierte en uno o más vectores**.

¿Y el sonido?

¿Cómo convertirían audio en números?

Audio → vectores

El sonido es una **onda de presión** que viaja por el aire. Cuando alguien habla o suena una guitarra, el aire se comprime y descomprime rápidamente.

Un **micrófono** convierte esas variaciones de presión en una señal eléctrica (voltaje proporcional a la presión). Un **conversor analógico-digital** mide ese voltaje a intervalos regulares: por ejemplo, 44.100 veces por segundo.

Cada medición es un número. Un segmento de 2 segundos a 44.100 Hz produce **88.200 números** — un vector en $\mathbb{R}^{88200}$.

¿Y las imágenes?

¿Cómo representarían una imagen para dársela a una computadora?

Imágenes en blanco y negro → vectores

Una imagen en escala de grises es una **grilla de números**: cada píxel tiene un valor entre 0 (negro) y 255 (blanco).

Una imagen de 28×28 píxeles tiene 784 números. Si los apilamos (por ejemplo, fila por fila), obtenemos un **vector en** $\mathbb{R}^{784}$.

Imágenes en color → vectores (más largos)

Una imagen en color tiene **tres canales** (rojo, verde, azul). Cada canal es una grilla de números del mismo tamaño.

Una imagen color de 28×28: $\quad 28 \times 28 \times 3 = 2352$ números → vector en $\mathbb{R}^{2352}$

El procedimiento es el mismo: apilar todos los valores en una lista.

El patrón

Datos tabulares, texto, audio, imágenes... en todos los casos:

$$\boxed{\text{un dato} = \text{un vector en } \mathbb{R}^n}$$

$$\boxed{\text{una colección de datos} = \text{una matriz en } \mathbb{R}^{m \times n}}$$

La matriz es simplemente un **arreglo de vectores apilados** — cada fila es un dato.

Más allá: datos con estructura compleja

No todo dato se convierte fácilmente en una lista de números:

- **Grafos** (redes sociales, moléculas, mapas): nodos y conexiones con estructura irregular
- **Secuencias de longitud variable** (ADN, series temporales)
- **Datos 3D** (nubes de puntos, modelos moleculares)

Hay áreas enteras de investigación dedicadas a encontrar buenas representaciones numéricas para estos datos. Están fuera del alcance de este curso, pero el principio es siempre el mismo: necesitamos **convertir a números** para poder operar computacionalmente.

Resumen: datos → vectores

Las computadoras operan con números. Para usar ML, **todo dato debe tener una representación numérica**.

Independientemente del tipo de dato — tabla, texto, audio, imagen — siempre podemos construir una representación como **vector en** $\mathbb{R}^n$.

Un dataset es una **colección de vectores**, que organizamos como una **matriz** $X \in \mathbb{R}^{m \times n}$.

La **matemática del álgebra lineal** — espacios vectoriales, transformaciones, normas — es la herramienta para trabajar con estos objetos. Ahora vamos a repasarla.

Parte II

Repaso de álgebra lineal

Nota previa

Los temas de esta sección son **repaso**.

Se asume que ya dominan: operaciones con matrices y vectores, sistemas de ecuaciones, eliminación gaussiana (MML 2.1–2.3).

Si no se sienten cómodos, **revisen esos temas por su cuenta** antes de la próxima clase.

Referencia: MML 2.4–2.8 · ILA caps. 1–3 · LAOML caps. 1–2

Espacios vectoriales — la idea

Un **espacio vectorial** es un conjunto V donde podemos hacer dos cosas:

- **Sumar** dos elementos: $x + y \in V$
- **Escalar** un elemento: $\lambda x \in V$

Y el resultado siempre **se queda en** V.

Ejemplos:

- $\mathbb{R}^n$ (vectores de n componentes)
- $\mathbb{R}^{m \times n}$ (matrices)
- Polinomios de grado $\leq k$
- Soluciones de $Ax = 0$

Subespacios

Un **subespacio** U de V es un subconjunto que también es un espacio vectorial con las mismas operaciones.

Condiciones (fáciles de verificar):

1. $U \neq \emptyset$ (contiene al vector $\mathbf{0}$)
2. Cerrado bajo suma: $x, y \in U \Rightarrow x + y \in U$
3. Cerrado bajo escalamiento: $\lambda \in \mathbb{R}, x \in U \Rightarrow \lambda x \in U$

Ejemplo: las soluciones de $Ax = 0$ forman un subespacio de $\mathbb{R}^n$.

No subespacio: las soluciones de $Ax = b$ con $b \neq 0$ (¿por qué?).

Combinaciones lineales e independencia

Combinación lineal: $v = \lambda_1 x_1 + \lambda_2 x_2 + \cdots + \lambda_k x_k$

Independencia lineal: los vectores $x_1, \ldots, x_k$ son **linealmente independientes** si la única forma de obtener $\mathbf{0}$ como combinación lineal es con todos los coeficientes iguales a cero:

$$\lambda_1 x_1 + \cdots + \lambda_k x_k = \mathbf{0} \quad \Rightarrow \quad \lambda_1 = \cdots = \lambda_k = 0$$

Base y dimensión de un espacio vectorial

Base de V: un conjunto de vectores que es:

1. Linealmente independiente
2. Genera todo V (todo vector se escribe como combinación lineal):
   $V = \mathrm{span}\{b_1, \ldots, b_k\}$ o equivalentemente $\forall v \in V, \exists \lambda_i : v = \sum \lambda_i b_i$

Dimensión de V: número de vectores en cualquier base.

- $\dim(\mathbb{R}^n) = n$
- $\dim(\mathbb{R}^{m \times n}) = mn$

Ejercicio Determinar una base y la dimensión de:

- Los vectores reales de 3 elementos
- Las matrices 2×2
- Los polinomios de grado ≤ 3

Coordenadas de un vector (representación en una base)

Dado un vector v y una base $B = \{b_1, \ldots, b_k\}$, podemos escribir:

$$v = \lambda_1 b_1 + \cdots + \lambda_k b_k$$

Los coeficientes λ_i son las **coordenadas** de v en la base B. **Cuando representamos datos en una computadora como un arreglo de números, estamos eligiendo una base** (por ejemplo, la base canónica) y usando las coordenadas resultantes:

$$v_B = \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_k \end{bmatrix}$$

Usualmente omitimos la referencia a la base (que queda implícita) y escribimos simplemente v.

Cambio de base

Un mismo vector v puede tener **distintas coordenadas** según la base que elijamos.

Ejercicio Consideremos el espacio $\mathbb{R}^3$ y dos bases distintas cuyos vectores se expresan en algun sistema de coordenadas como:

$$B = \{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \}$$

$$\tilde{B} = \{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \}$$

¿Cuáles son las coordenadas del vector $v = \begin{bmatrix} 2 \\ 3 \\ 3 \end{bmatrix}$ en cada base?

Escalamiento y suma de vectores

Dado un vector $\mathbf{x}$ y un escalar a, el **escalamiento** es $a\mathbf{x}$. Dado un par de vectores $\mathbf{x}$ e $\mathbf{y}$, la **suma** es $\mathbf{x} + \mathbf{y}$.

Cuando representamos vectores en una base, estas operaciones se traducen a operaciones con sus coordenadas:

$$a\mathbf{x} = a \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix} = \begin{bmatrix} ax_1 \\ ax_2 \\ \vdots \\ ax_k \end{bmatrix} \quad \text{y} \quad \mathbf{x} + \mathbf{y} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix} + \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_k \end{bmatrix} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_k + y_k \end{bmatrix}$$

Producto interno de vectores

El **producto interno** de dos vectores $\mathbf{x}$ e $\mathbf{y}$ es un número (escalar) definido como:

$$< \mathbf{x}, \mathbf{y} >= \mathbf{x} \cdot \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_k y_k$$

Matrices

Una **matriz** es un arreglo rectangular de números:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

Con definiciones análogas a las de los vectores, podemos sumar y escalar matrices.

Transpuesta

Se define la **transpuesta** de una matriz A como la matriz $A^\top$ que se obtiene al intercambiar filas por columnas:

$$A^\top = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}$$

Producto matricial

Se define el producto de dos matrices A ($m \times n$) y B ($n \times p$) como:

$$AB = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1p} \\ c_{21} & c_{22} & \cdots & c_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mp} \end{bmatrix}$$

donde cada elemento c_{ij} se calcula como:

$$c_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}$$

Para que el producto esté definido, el número de columnas de A debe coincidir con el número de filas de B. El resultado es una matriz de tamaño $m \times p$.

Vectores como matrices de una columna

Un vector en un espacio de dimensión n se puede pensar como una matriz de una sola columna.

El producto interno de dos vectores $\mathbf{x}$ e $\mathbf{y}$ se puede escribir como el producto matricial de la transpuesta de $\mathbf{x}$ por $\mathbf{y}$:

$$< \mathbf{x}, \mathbf{y} >= \mathbf{x}^\top \mathbf{y} = \mathbf{y}^\top \mathbf{x}$$

Ejercicio Calcular el producto interno entre

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad \text{y} \quad \mathbf{y} = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}$$

Producto externo

El **producto externo** de dos vectores $\mathbf{x}$ e $\mathbf{y}$ se define como el producto matricial de $\mathbf{x}$ por la transpuesta de $\mathbf{y}$:

$$\mathbf{x} \otimes \mathbf{y} = \mathbf{x}\mathbf{y}^\top$$

Si $\mathbf{x} \in \mathbb{R}^m$ e $\mathbf{y} \in \mathbb{R}^n$, entonces $\mathbf{x}\mathbf{y}^\top$ es una matriz de tamaño $m \times n$.

Nota: El producto interno es conmutativo pero el producto externo no lo es: $\mathbf{x}\mathbf{y}^\top \neq \mathbf{y}\mathbf{x}^\top$ (ni siquiera tienen el mismo tamaño)

Matrices: dos roles fundamentales

En este curso, las matrices van a aparecer con **dos significados distintos**:

1. Colección de datos: cada fila es un dato (vector). La tabla de pacientes, el dataset de imágenes aplanadas. La matriz es un "contenedor" de vectores.

$$X = \begin{bmatrix} — x_1^\top — \\ — x_2^\top — \\ \vdots \\ — x_m^\top — \end{bmatrix} \in \mathbb{R}^{m \times n}$$

2. Transformación lineal: la matriz A define un mapeo $x \mapsto Ax$ que transforma vectores. Veremos esto a continuación.

Es importante no confundir los dos roles, aunque el objeto matemático sea el mismo.

Transformaciones (funciones) entre espacios vectoriales

Una **transformación** (o función) $\Phi : V \to W$ asigna a cada vector $x \in V$ un vector $\Phi(x) \in W$.

(análogo a funciones en cálculo, pero ahora entre espacios vectoriales)

Ejemplos de transformaciones $\mathbb{R}^2 \to \mathbb{R}^2$:

$$\Phi_1\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 2x \\ 3y \end{bmatrix} \quad \text{y} \quad \Phi_2\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} y^3 \\ x \end{bmatrix}$$

Transformaciones lineales

Un mapeo (función) entre dos espacios vectoriales $\Phi : V \to W$ es **lineal** si preserva suma y escalamiento:

$$\Phi(\lambda x + \psi y) = \lambda\, \Phi(x) + \psi\, \Phi(y)$$

Teorema: toda transformación lineal entre espacios de dimensión finita se puede representar como **multiplicación por una matriz**.

$$y = A_\Phi\, x$$

La matriz A_Φ que representa a una transformación/función de vectores depende de las bases elegidas en V y W.

Transformaciones lineales en el plano — ejemplos

Rotación de 45° en el plano:

$$A_1 = \begin{bmatrix} \cos 45^\circ & -\sin 45^\circ \\ \sin 45^\circ & \cos 45^\circ \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}$$

Estiramiento horizontal:

$$A_2 = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

Combinación (reflexión + rotación + estiramiento):

$$A_3 = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ 1 & -1 \end{bmatrix}$$

Cada matriz define una transformación geométrica diferente.

Cambio de base como transformación lineal (1/2)

La operación de cambio de base se puede entender como una transformación lineal que mapea las coordenadas de un vector en una base a las coordenadas en otra base.

Consideremos el ejemplo anterior con $V = \mathbb{R}^3$ y las bases B y $\tilde{B}$. La matriz de cambio de base S que transforma coordenadas de $\tilde{B}$ a B se construye con los vectores de $\tilde{B}$ expresados en la base B:

$$S = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

Verifiquemos con el ejemplo anterior. Las representaciones del vector v en cada base son:

$$v_B = \begin{bmatrix} 2 \\ 3 \\ 3 \end{bmatrix} \quad \text{y} \quad v_{\tilde{B}} = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix} \Rightarrow v_B = S v_{\tilde{B}} \checkmark$$

Cambio de base como transformación lineal (2/2)

Los cambios de base son siempre invertibles (porque todo vector tiene una representación y solo una en cada base) (**¿por qué?**).

Por tanto, la matriz de cambio de base S tiene una inversa S^{-1} que transforma coordenadas de B a $\tilde{B}$:

$$S^{-1} = \frac{1}{2}\begin{bmatrix} 1 & 1 & -1 \\ 1 & -1 & 1 \\ -1 & 1 & 1 \end{bmatrix}$$

Cambio de base: transformaciones lineales (3/3)

La misma transformación lineal tiene **distintas matrices** según la base que elijamos.

Consideremos nuevamente una transformación lineal $\Phi : V \to W$ representada por la matriz A_Φ en las bases B (del espacio V) y C (del espacio W).

¿Cómo es la matriz que representa dicha transformación si cambiamos de base B a $\tilde{B}$ en V y de C a $\tilde{C}$ en W?

$$\tilde{A}_\Phi = T^{-1} A_\Phi \, S$$

- S: cambio de base en V (de $\tilde{B}$ a B)
- T: cambio de base en W (de $\tilde{C}$ a C)

Idea geométrica: la transformación es la misma; solo cambiamos el sistema de coordenadas en que representamos el espacio/los vectores.

Rango de una matriz

El **rango** de una matriz A (notado como $rk(A)$), es el número de columnas linealmente independientes que tiene. Es decir, si consideramos cada columna como un vector, el rango es la cantidad máxima de columnas que no se pueden escribir como combinación lineal de las otras.

Teorema: el rango de una matriz A es igual al de su transpuesta $A^\top$, es decir el número de columnas linealmente independientes de una matriz es igual al número de filas linealmente independientes.

Imagen y núcleo de una transformación lineal

Dada una transformación lineal $\Phi : V \to W$ representada por A:

Imagen (espacio columna):

$$\mathrm{Im}(\Phi) = \{Ax : x \in \mathbb{R}^n\} = \mathrm{span}[\text{columnas de } A]$$

Es el (sub)espacio de todos los vectores que puden formarse como combinaciones lineales de las columnas de A. Por definición de rango, $\dim(\mathrm{Im}(\Phi)) = \mathrm{rk}(A)$.

Núcleo (espacio nulo):

$$\ker(\Phi) = \{x : Ax = \mathbf{0}\}$$

Es el (sub)espacio de todos los vectores que se mapean a $\mathbf{0}$ por la transformación A.

Teorema de rango-nulidad:

$$\dim(\ker(\Phi)) + \dim(\mathrm{Im}(\Phi)) = \dim(V)$$

Imagen y núcleo — interpretación

	Imagen	Núcleo
¿Qué es?	A dónde puedo llegar	Qué se pierde
Subespacio de	W (el codominio)	V (el dominio)
Dimensión	$\mathrm{rk}(A)$	$n - \mathrm{rk}(A)$
Si rk(A) = n	Todo W	Solo el elemento $\mathbf{0}$
Si rk(A) < n	Subespacio estricto de W	Hay múltiples vectores que se mapean a $\mathbf{0}$

Parte III

Normas, productos internos y distancias

¿Por qué necesitamos medir?

Hasta ahora sabemos sumar vectores y escalarlos. Pero no sabemos:

- ¿Cuánto "mide" un vector? → **norma**
- ¿Qué tan parecidos son dos vectores? → **producto interno**
- ¿Qué tan lejos están? → **distancia**
- ¿Qué ángulo forman? → **ángulo**

Las normas y los productos internos **añaden geometría** al espacio vectorial.

Norma de un vector

Una **norma** es una función $\|\cdot\| : V \to \mathbb{R}$ que asigna una "longitud" a cada vector.

Propiedades (para todo $x, y \in V$ y $\lambda \in \mathbb{R}$):

1. $\|\lambda x\| = |\lambda| \, \|x\|$ (escalar estira proporcionalmente)
2. $\|x + y\| \leq \|x\| + \|y\|$ (desigualdad triangular)
3. $\|x\| \geq 0$, y $\|x\| = 0 \iff x = \mathbf{0}$

Normas habituales en $\mathbb{R}^n$

$$\|x\|_1 = \sum_{i=1}^{n} |x_i| \qquad \|x\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2} \qquad \|x\|_\infty = \max_i |x_i|$$

Ejercicio Dibujar la forma que toma el conjunto de vectores con norma 1 (bola unitaria) para cada una de estas normas en $\mathbb{R}^2$.

Normas matriciales — ¿por qué?

Si los datos son vectores y las transformaciones son matrices, necesitamos medir también el **"tamaño" de una transformación**.

¿Cuánto puede una matriz A estirar o encoger un vector?

Norma de Frobenius

Tratamos la matriz como un vector largo de mn componentes:

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\operatorname{tr}(A^\top A)}$$

Es la extensión natural de ℓ_2 al espacio de matrices.

Ejemplo:

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \quad \Rightarrow \quad \|A\|_F = \sqrt{1+4+9+16} = \sqrt{30}$$

Norma espectral

¿Cuánto puede A estirar un vector como máximo?

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$$

Interpretación: buscamos el vector unitario x que maximiza la longitud de Ax.

El resultado es el **máximo factor de estiramiento** de la transformación.

Relación entre normas matriciales

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{r}\,\|A\|_2$$

donde $r = \mathrm{rk}(A)$.

- La norma espectral mide el **máximo** estiramiento.
- La norma de Frobenius mide el estiramiento **promedio** (en cierto sentido).
- Si A tiene rango 1, ambas coinciden.

Producto interno - formalización

Un **producto interno** es una función $\langle \cdot, \cdot \rangle : V \times V \to \mathbb{R}$ que satisface:

- Simétrico: $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$
- Lineal en cada argumento: $\langle a\mathbf{x} + b\mathbf{z}, \mathbf{y} \rangle = a\langle \mathbf{x}, \mathbf{y} \rangle + b\langle \mathbf{z}, \mathbf{y} \rangle$
- $\langle \mathbf{x}, \mathbf{x} \rangle = 0$ sii $\mathbf{x} = \mathbf{0}$
- $\langle \mathbf{x}, \mathbf{x} \rangle =\geq 0$ (no-negatividad)
- Los productos internos definen normas: $\|\mathbf{x}\| = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$

Típicamente, el producto interno se define como el producto punto o euclidiano:

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^{n} x_i y_i$$

pero hay otras formas de definirlo que satisfacen las mismas propiedades.

Producto interno - interpretación geométrica

El producto interno puede usarse para definir el **ángulo** entre dos vectores, y así medir su orientación relativa:

$$\cos\theta = \frac{\langle x, y\rangle}{\|x\|\,\|y\|}$$

Por tanto

$$\theta = \cos^{-1}\left(\frac{\langle x, y\rangle}{\|x\|\,\|y\|}\right)$$

Ejercicio: Calcular el ángulo entre los vectores $x = (1, 0)$ e $y = (1, 1)$ usando el producto punto.

Similitud coseno el ángulo entre vectores se usa como medida de similitud en ML, especialmente para texto.

Ortogonalidad

Dos vectores son **ortogonales** si $\langle x, y \rangle = 0$.

Matrices ortogonales: son aquellas que preservan la ortogonalidad entre vectores al transformar: $\langle \mathbf{x}, \mathbf{y} \rangle = 0 \iff \langle A\mathbf{x}, A\mathbf{y} \rangle = 0$.

Una definición equivalente: A es ortogonal sii $A^\top A = I$

Esto implica:

- Las columnas de A forman una base ortonormal
- $A^{-1} = A^\top$ (invertir es trivial)
- **Preservan normas:** $\|Ax\| = \|x\|$
- **Preservan ángulos:** el ángulo entre Ax y Ay es el mismo que entre x e y

Geométricamente, las transformaciones ortogonales son composiciones de **rotaciones** con **reflexiones**.

Distancias

Al definir un producto interno, automáticamente obtenemos una norma y por tanto una noción de distancia:

$$d(x, y) = \|x - y\| = \sqrt{\langle x - y,\ x - y \rangle}$$

Con el producto interno usual (punto), esto es la **distancia euclidiana**:

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Nota: Cambiar el producto interno cambia la noción de norma/distancia en un espacio vectorial.

Resumen - geometría de los espacios vectoriales

El producto interno y la norma nos permiten **medir** longitudes, ángulos y distancias en un espacio vectorial.

Cuando representamos datos como vectores, estas herramientas nos brindan nociones de geometría que son indispensables para entender la estructura de los datos y las transformaciones que aplicamos sobre ellos.

En ML las nociones distancia y similitud son centrales para abordar tareas como clasificación, clustering (agrupamiento), y reducción de dimensionalidad, etc.

Próxima clase: usaremos estas herramientas para definir proyecciones, ortogonalización (Gram-Schmidt), y la descomposición QR.

Parte IV

Laboratorio 1: NumPy

Laboratorio 1 — Objetivo

Adquirir **fluidez operativa** con NumPy para álgebra lineal.

Abran el notebook: `lab1.ipynb`

Vamos a cubrir:

1. Vectores en NumPy
2. Matrices en NumPy
3. Broadcasting

Vectores en NumPy

```python
import numpy as np

# Crear vectores
v = np.array([1, 2, 3])
zeros = np.zeros(5)
linspace = np.linspace(0, 10, 5)   # [0, 2.5, 5, 7.5, 10]

# Propiedades
v.shape    # (3,)
v.ndim     # 1

# Operaciones
2 * v              # [2, 4, 6]
np.sqrt(v)         # elemento a elemento
np.dot(v, v)       # producto punto = 14
np.linalg.norm(v)  # norma L2
```

Matrices en NumPy

```
A = np.array([[1, 2], [3, 4]])
I = np.eye(3)

# Operaciones
A + A          # suma elemento a elemento
A * A          # producto elemento a elemento (¡no matricial!)
A @ A          # producto matricial
A.T            # transpuesta

# Álgebra lineal
np.linalg.det(A)          # determinante
np.linalg.inv(A)          # inversa
np.linalg.matrix_rank(A)  # rango
np.trace(A)               # traza
```

Cuidado: `*` es elemento a elemento. `@` es producto matricial.

Broadcasting

NumPy puede operar sobre arreglos de distintas formas:

```
A = np.random.rand(5, 3)    # 5×3
v = np.random.rand(3)       # (3,)

# Sumar v a cada fila de A
A + v           # broadcasting: v se "copia" a cada fila

# Sumar v2 a cada columna de A
v2 = np.random.rand(5)
A + v2[:, np.newaxis]   # v2 pasa de (5,) a (5,1)
```

Regla: las dimensiones se alinean de derecha a izquierda; si una dimensión es 1, se "estira".

Broadcasting — ¿por qué importa?

```
# Bucle elemento a elemento
for i in range(1000):
    for j in range(100):
        result[i, j] += v[j]
# ~ 1 segundo (100 iteraciones)

# Broadcasting
result = A + v
# ~ 0.001 segundos (100 iteraciones)
```

Factor de aceleración: **~1000×**

NumPy delega las operaciones a código optimizado en C/Fortran.

Si pueden evitar bucles en Python, **evítenlos**.

A trabajar

Resuelvan los ejercicios del notebook `lab1.ipynb`.

Temas clave para practicar:

- Normalizar filas de una matriz (dividir cada fila por su suma)
- Centrar columnas (restar la media de cada columna)
- Calcular distancias euclidianas usando broadcasting

Entrega: opcional, a través de Webasignatura (3% por completitud de todos los labs).

Qué sigue

Próxima clase:

Álgebra y geometría — proyecciones, Gram-Schmidt, descomposición QR.

Para leer:

MML 3.4–3.8, 4.1–4.4

ILA cap. 4, 6

Próximo laboratorio:

Proyecciones y ortogonalización. Implementación de QR desde cero.

¿Preguntas?

pablo.iturralde@ucu.edu.uy