Matemática para Aprendizaje Automático

Clase 3.1 — Valores Propios y Vectores Propios

Pablo A. Iturralde · Universidad Católica del Uruguay · 2026

Plan de la clase

Herramientas previas: traza, determinante, ecuación característica

Valores y vectores propios: definición, cálculo, multiplicidades

Ejemplos de cálculo: matrices 2×2, 3×3, y defectivas

Números complejos: extensión del campo, teorema fundamental del álgebra

Geometría de las transformaciones: interpretación visual de los valores propios

Diagonalización: cuándo es posible y para qué sirve

Matrices simétricas: teorema espectral, matrices definidas positivas

Referencia: MML 4.1-4.4, ILA Cap. 6, LAOML 3.1-3.3

Disclaimer: las diapositivas de clase son un breve resumen de los temas tratados. Las mismas no sustituyen la lectura de los textos recomendados.

Traza de una matriz

Para $A \in \mathbb{R}^{n \times n}$, la **traza** es la suma de los elementos de la diagonal:

$$\operatorname{tr}(A) = \sum_{i=1}^{n} a_{ii}$$

Propiedades:

- Linealidad: $\operatorname{tr}(A + B) = \operatorname{tr}(A) + \operatorname{tr}(B)$
- Propiedad cíclica: $\operatorname{tr}(ABC) = \operatorname{tr}(CAB) = \operatorname{tr}(BCA)$

Ejemplo: $A = \begin{bmatrix} 3 & 1 \\ 2 & -1 \end{bmatrix}$, $\operatorname{tr}(A) = 3 + (-1) = 2$.

Determinante de una matriz — caso 2×2

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

Interpretación geométrica: área con signo del paralelogramo formado por las columnas de A.

Si $\det(A) = 0$, las columnas son linealmente dependientes — la transformación colapsa el espacio.

Determinante de una matriz — caso 3×3

Expansión de cofactores (regla de Laplace) por la primera fila:

$$\det(A) = a_{11}(a_{22}a_{33} - a_{23}a_{32}) - a_{12}(a_{21}a_{33} - a_{23}a_{31}) + a_{13}(a_{21}a_{32} - a_{22}a_{31})$$

Interpretación geométrica: volumen con signo del paralelepípedo formado por las columnas de A.

Determinante de una matriz — caso general

Para $A \in \mathbb{R}^{n \times n}$, el determinante se define recursivamente por expansión de cofactores (regla de Laplace):

$$\det(A) = \sum_{j=1}^{n} a_{ij} \cdot (-1)^{i+j} \cdot \det\left(M_{ij}\right)$$

donde M_{ij} es el menor de orden $n-1$ (submatriz eliminando fila i, columna j).

Propiedades del determinante

- $\det(AB) = \det(A)\det(B)$
- A es invertible $\iff \det(A) \neq 0$
- $\det(A^T) = \det(A)$
- $\det(A^{-1}) = (\det(A))^{-1}$

Estas propiedades conectan el determinante con la ecuación característica que usaremos para calcular valores propios.

Definición — valor propio y vector propio

Dado $A \in \mathbb{R}^{n \times n}$, un vector **no nulo** $v \in \mathbb{C}^n$ es un **vector propio** de A con **valor propio** $\lambda \in \mathbb{C}$ si:

$$Av = \lambda v$$

Interpretación: La transformación dada por A solamente escala al vector v por el factor λ.

Ejemplo:

- Para $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$, un vector propio es $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ con valor propio $\lambda = 2$.

Polinomio característico - cálculo de valores propios

Para que $Av = \lambda v$ tenga solución no trivial, la matriz $A - \lambda I$ debe ser **singular**:

$$\det(A - \lambda I) = 0$$

Esto produce el **polinomio característico** de A — un polinomio de grado n en λ. Sus raíces son los valores propios de A.

En el ejemplo anterior:

$$A - \lambda I = \begin{bmatrix} 1-\lambda & 1 \\ 1 & 1-\lambda \end{bmatrix} \quad \Longrightarrow \quad (1-\lambda)^2 - 1 = \lambda^2 - 2\lambda \quad \Longrightarrow \quad \lambda = 0 \quad \lambda = 2$$

Cálculo de vectores propios

Para cada valor propio λ_i, los vectores propios son las soluciones de:

$$(A - \lambda_i I)\, v = 0$$

Las soluciones forman un subespacio vectorial (demostrar!) — el **espacio propio** asociado a λ_i.

El sistema siempre es compatible indeterminado. Al menos una solución no trivial ($v \neq 0$) y las ecuaciones siempre son linealmente dependientes (¿por qué?).

Cálculo de vectores propios (cont.)

Continuando con el ejemplo anterior para $\lambda = 2$:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \implies A - 2I = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}$$

$$(A - 2I) \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = 0 \implies -v_1 + v_2 = 0 \implies v_2 = v_1.$$

Un vector propio es $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$. Pero también lo son $\begin{bmatrix} 2 \\ 2 \end{bmatrix}$, $\begin{bmatrix} -1 \\ -1 \end{bmatrix}$, etc. — cualquier múltiplo escalar de v es también un vector propio (**dirección propia/subespacio de dim. 1**).

Formalmente, el espacio propio asociado a $\lambda = 2$ es $\{\alpha \begin{bmatrix} 1 \\ 1 \end{bmatrix} : \alpha \in \mathbb{R}\}$.

Cálculo de vectores propios (cont.)

Para $\lambda = 0$:

$$A - 0I = A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$$

Buscamos un vector $v = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$ tal que $v_1 + v_2 = 0$, es decir, $v_2 = -v_1$.

El subespacio propio asociado a $\lambda = 0$ son todos los vectors múltiplos de $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$.

Formalmente, $\{\alpha \begin{bmatrix} 1 \\ -1 \end{bmatrix} : \alpha \in \mathbb{R}\}$.

Subespacios propios de $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$

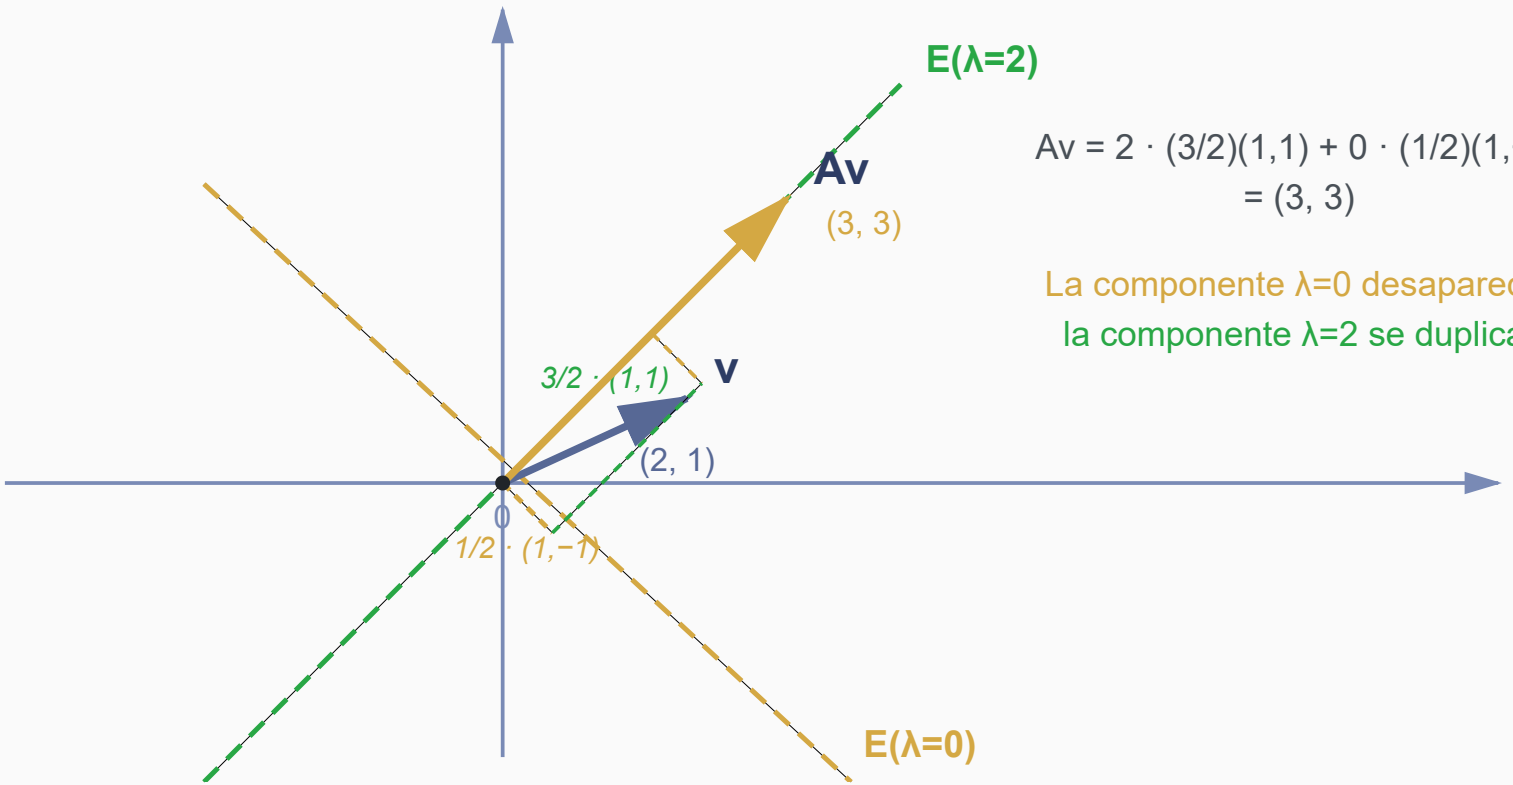

Av = 2 · (3/2)(1,1) + 0 · (1/2)(1,−1)
= (3, 3)

La componente λ=0 desaparece;
la componente λ=2 se duplica.

Multiplicidades de valores y vectores propios

- **Multiplicidad algebraica:** (m_i) número de veces que λ_i aparece como raíz del polinomio característico.
- **Multiplicidad geométrica:** $g_i = \dim \ker(A - \lambda_i I)$ — dimensión del espacio propio.

Siempre: $1 \leq g_i \leq m_i \leq n$

Cuando las multiplicidades algebraica y geométrica son iguales para todos los valores propios, los vectores propios forman una base del espacio.

Propiedades — traza, determinante y valores propios

Los valores propios y la traza/determinante están relacionados por los coeficientes del polinomio característico:

$$\mathrm{tr}(A) = \sum_{i=1}^{n} \lambda_i \qquad \det(A) = \prod_{i=1}^{n} \lambda_i$$

Consecuencia: A es invertible $\iff$ ningún valor propio es cero.

Ejemplo: para $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ $\implies \lambda_1 = 2,\ \lambda_2 = 0$: $\mathrm{tr}(A) = 2,\ \det(A) = 0.$

Propiedades — potencias e inversas

- Si $Av = \lambda v$, entonces: $A^2 v = A(\lambda v) = \lambda(Av) = \lambda^2 v$
- Por inducción: $A^k v = \lambda^k v$. Los valores propios de A^k son λ_i^k.
- Si A es invertible: $A^{-1} v = \lambda^{-1} v$. Los valores propios de A^{-1} son λ_i^{-1}.

Ejemplo: Matriz 2×2 (1/3)

Enunciado: Calcular valores propios y vectores propios de

$$A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$$

Ejemplo: Matriz 2×2 (2/3)

Polinomio característico:

$$\det(A - \lambda I) = (4-\lambda)(3-\lambda) - 2 = \lambda^2 - 7\lambda + 10 = (\lambda - 2)(\lambda - 5) = 0$$

Valores propios: $\lambda_1 = 2, \;\; \lambda_2 = 5$

Verificación: $\mathrm{tr}(A) = 7 = 2 + 5 \checkmark \qquad \det(A) = 10 = 2 \cdot 5 \checkmark$

Ejemplo: Matriz 2×2 (3/3)

Para $\lambda_1 = 2$: $(A - 2I)v = 0$

$$\begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} v = 0 \implies v_1 = k \begin{bmatrix} 1 \\ -2 \end{bmatrix},\ k \in \mathbb{R}$$

Para $\lambda_2 = 5$: $(A - 5I)v = 0$

$$\begin{bmatrix} -1 & 1 \\ 2 & -2 \end{bmatrix} v = 0 \implies v_2 = k \begin{bmatrix} 1 \\ 1 \end{bmatrix},\ k \in \mathbb{R}$$

Ejemplo: Matriz 3×3 (1/3)

Enunciado: Calcular valores propios y vectores propios de

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 1 \\ 0 & 1 & 3 \end{bmatrix}$$

Ejemplo: Matriz 3×3 (2/3)

Polinomio característico:

$$p(\lambda) = (2-\lambda)\det\begin{bmatrix} 3-\lambda & 1 \\ 1 & 3-\lambda \end{bmatrix}$$
$$= (2-\lambda)\left[(3-\lambda)^2 - 1\right] = (2-\lambda)(\lambda^2 - 6\lambda + 8)$$
$$= (2-\lambda)(2-\lambda)(4-\lambda)$$

Valores propios: $\lambda_1 = 2$ (multiplicidad algebraica 2), $\lambda_2 = 4$

Ejemplo: Matriz 3×3 (3/3)

Para $\lambda_2 = 4$:

$$v = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

Para $\lambda_1 = 2$: $(A - 2I)v = 0 \implies \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix} v = 0$

Espacio propio 2D: $v_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \; v_2 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}$

Para todo λ multiplicidad geométrica = multiplicidad algebraica → los vectores propios forman una base de $\mathbb{R}^3$.

Ejemplo: Matriz defectiva (1/2)

Enunciado: Analizar $B = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$

¿Cuántos vectores propios linealmente independientes tiene esta matriz?

Ejemplo: Matriz defectiva (2/2)

Polinomio característico: $(2-\lambda)^2 = 0 \implies \lambda = 2$ (multiplicidad algebraica 2)

Para $\lambda = 2$: $(B - 2I)v = 0$

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} v = 0 \implies v = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

Un único vector propio independiente. Multiplicidad geométrica $<$ multiplicidad algebraica → los vectores propios **no** forman una base de $\mathbb{R}^2$.

Matrices defectivas

Las matrices que no tienen tantos vectores propios linealmente independientes como para formar una base (menos que n) se llaman **defectivas** (no son diagonalizables: lo veremos en un rato).

Si A es defectiva, entonces existe al menos un valor propio λ_i tal que $g_i < m_i$.

Para ese λ_i **no** existen m_i vectores propios, pero sí existe un subespacio propio U de dimensión m_i (es decir, si $x \in U \implies y = Ax \in U$)

En la práctica no se calcula así

Para matrices de tamaño realista, resolver $\det(A - \lambda I) = 0$ directamente es:

- **Inestable numéricamente:** pequeños errores en los coeficientes del polinomio producen grandes errores en las raíces.
- **Ineficiente:** el determinante de una matriz $n \times n$ tiene $n!$ términos.

Los algoritmos modernos (p.ej. algoritmo QR iterativo) calculan valores propios sin construir el polinomio característico.

Breve Digresión: Números Complejos

Los números como tecnología

Sistema	Motivación
$\mathbb{N}$ (naturales)	Contar
$\mathbb{Z}$ (enteros)	Necesidad del cero y los negativos (contabilidad, deudas)
$\mathbb{Q}$ (racionales)	Necesidad de dividir: $2/3$, proporciones
Números algebraicos	Raíces de polinomios con coeficientes racionales: $\sqrt{2}$, $\sqrt[3]{5}$
$\mathbb{R}$ (reales)	Completitud, límites: π, e (números trascendentes)
$\mathbb{C}$ (complejos)	**Todas** las raíces de polinomios — teorema fundamental del álgebra

> *«Die ganzen Zahlen hat der liebe Gott gemacht, alles andere ist Menschenwerk.»*
> *(Dios hizo los números enteros; todo lo demás es obra del hombre.) — L. Kronecker*

Números complejos

Se define la unidad imaginaria i con la propiedad $i^2 = -1$.

A partir de i, se construyen los números complejos, que extienden a los números reales.

$$z = a + bi \quad \text{con } a, b \in \mathbb{R}$$

Una forma de pensar en los números complejos es como puntos o vectores en el plano, donde la parte real a es la coordenada horizontal (eje real) y la parte imaginaria b es la coordenada vertical (eje imaginario).

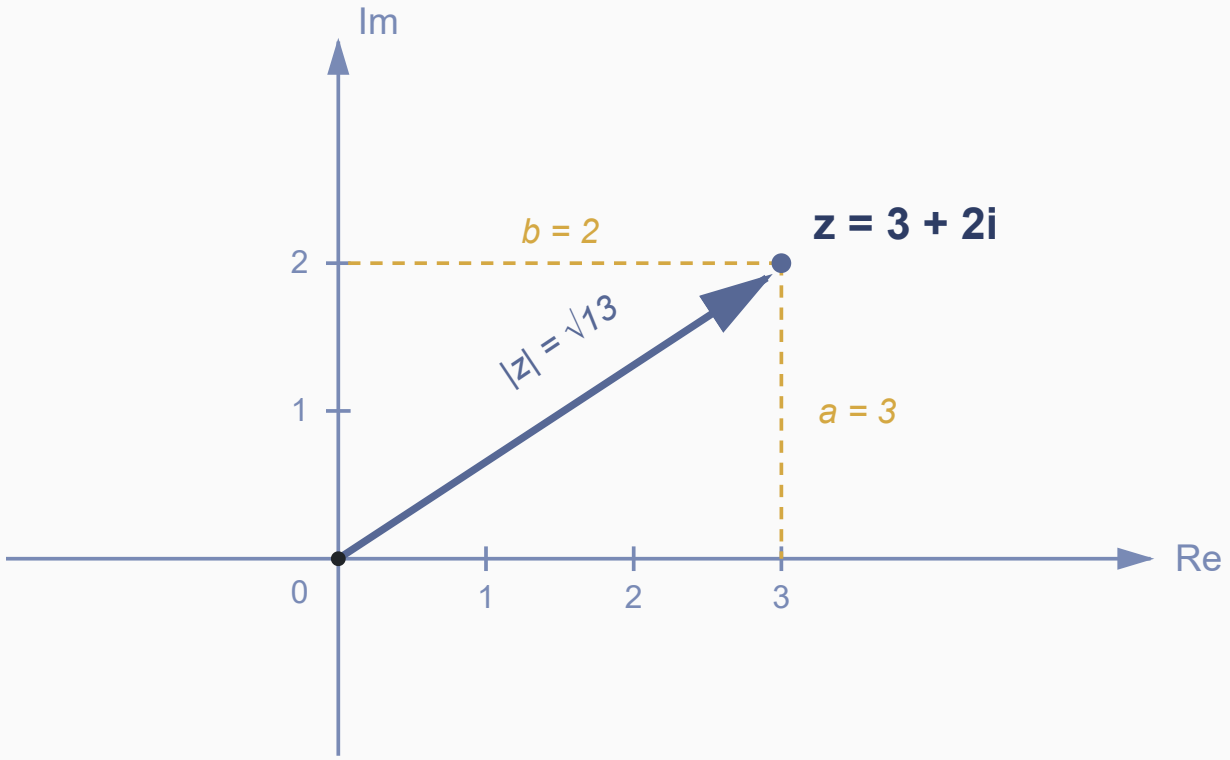

Operaciones con números complejos

Obedecen las mismas reglas de suma y multiplicación que los números reales, con la adición de la regla $i^2 = -1$.

Valen las propiedades distributiva, conmutativa y asociativa.

Ejemplo:

$$(1 + 2i) + (3 - i) = 4 + i$$

$$(1 + 2i)(3 - i) = 3 - i + 6i - 2i^2 = 3 + 5i + 2 = 5 + 5i$$

Conjugado de un número complejo

Sea $z = a + bi$, su **conjugado** se define como $\bar{z} = a - bi$.

Satisface que:

- $z\bar{z} = |z|^2 = a^2 + b^2$
- $z^{-1} = \frac{1}{z} = \frac{\bar{z}}{|z|^2}$

BONUS: identidad de Euler (fuera del curso)

Se puede mostrar que:

$$e^{i\theta} = \cos(\theta) + i\sin(\theta), \quad \forall \theta \in \mathbb{R}$$

Esto implica:

$$e^{i\pi} + 1 = 0$$

Teorema fundamental del álgebra

Todo polinomio de grado n con coeficientes complejos tiene exactamente n raíces complejas (contadas con multiplicidad).

Consecuencia directa: toda matriz $n \times n$ tiene exactamente n valores propios complejos (contados con multiplicidad).

- Las matrices reales pueden tener valores propios complejos — aparecen en **pares conjugados**.
- Ejemplo: $\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ tiene valores propios $\pm i$.

Geometría de las Transformaciones

Valores propios como descriptores de transformación

Toda matriz $A \in \mathbb{R}^{n \times n}$ define una transformación lineal $x \mapsto Ax$.

Los valores propios de A revelan la **naturaleza geométrica** de esa transformación:

- λ real positivo → **estiramiento o compresión** en la dirección del vector propio
- λ real negativo → **inversión de dirección** (reflexión + posible escalamiento)
- λ complejo ($a \pm bi$) → **rotación** con ángulo $\theta = \arctan(b/a)$ y escala $\sqrt{a^2 + b^2}$
- λ repetido, con tantos vectores propios como multiplicidad → **escalamiento uniforme** en el subespacio
- λ repetido, defectiva → **cizallamiento** (la transformación "arrastra" vectores hacia la dirección propia)

Estiramiento y compresión

Los valores propios reales positivos implican compresión/estiramiento a lo largo de las direcciones propias. Los vectores propios no tienen por qué ser ortogonales:

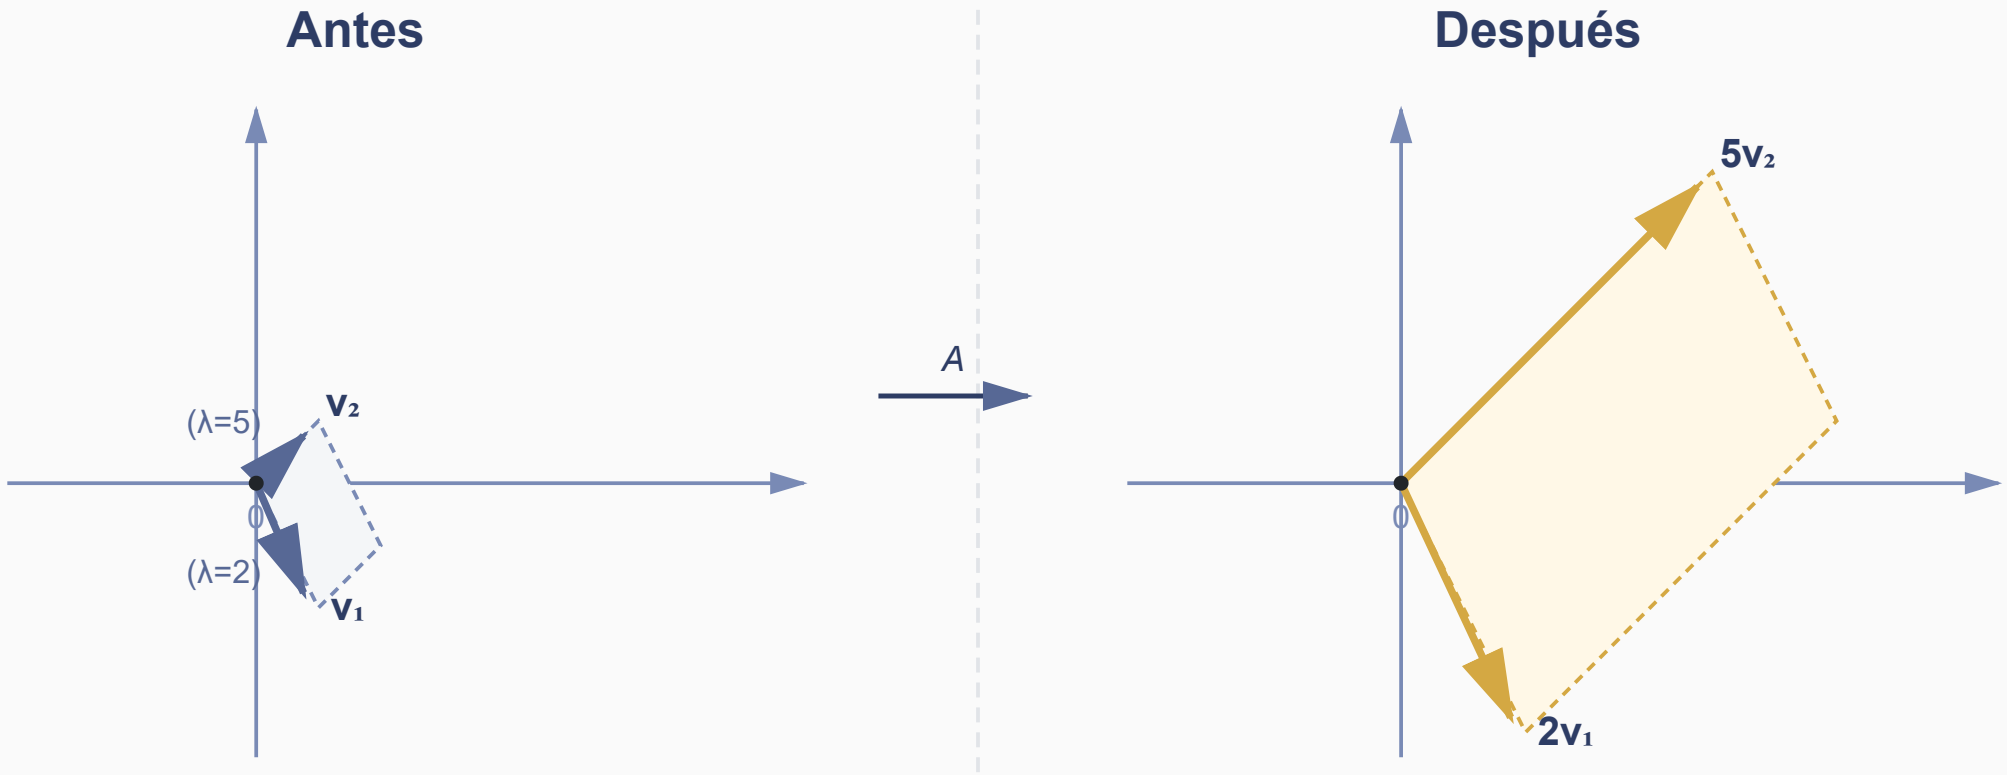

Rotación

Una matriz de rotación tiene λ complejos. Si $\lambda = \pm i$, la rotación es de 90 grados.

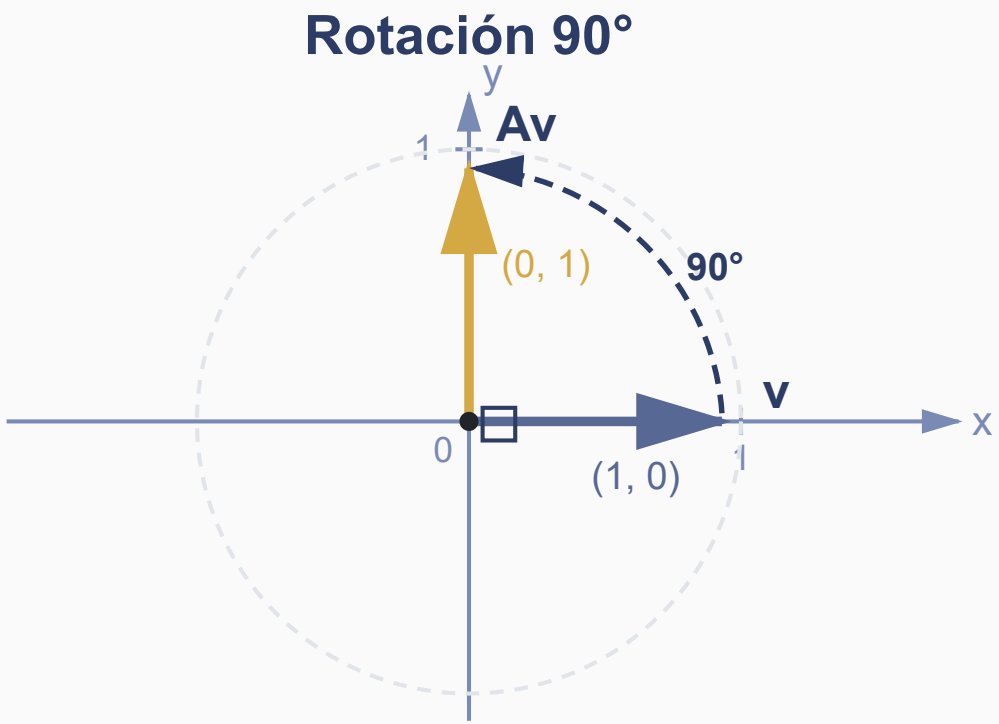

Nota: en gral, valores propios complejos conj. $\lambda = a \pm bi$ implican una roto-homotecia, con $|z| = \sqrt{a^2 + b^2}$ factor de escala y $\theta = \arctan(b/a)$ el ángulo de rotación.

Reflexión

Un valor propio negativo implica una reflexión (y posiblemente escalamiento).

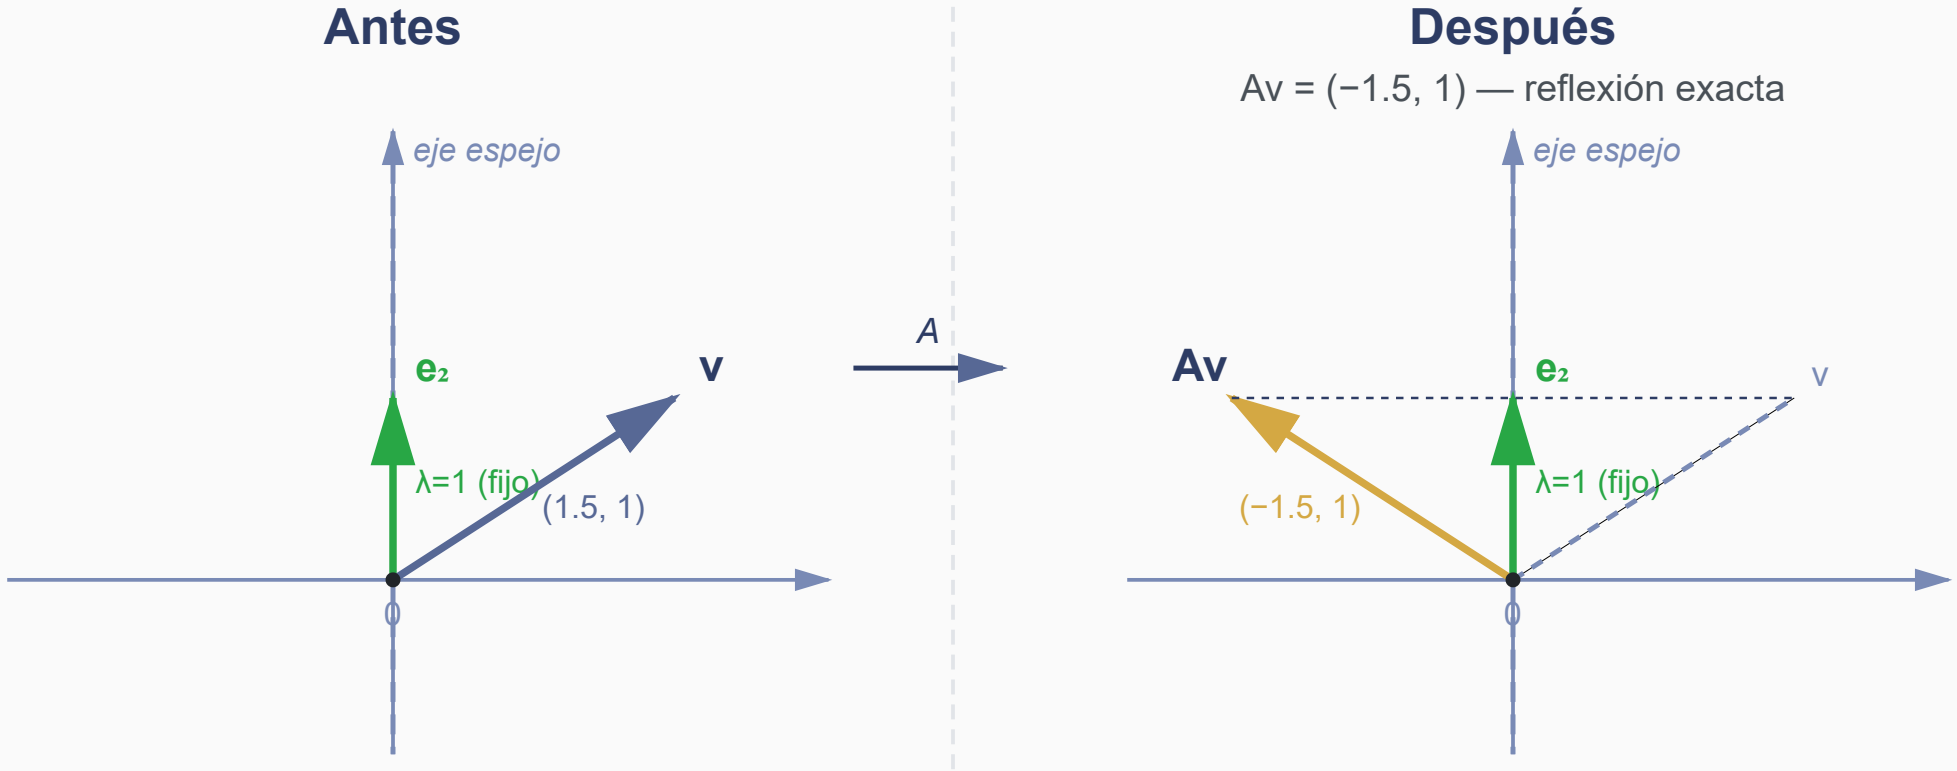

Cizallamiento — matriz defectiva

Las matrices defectivas no tienen una base de vectores propios: los vectores se "trasladan" hacia la(s) dirección(es) propia(s) sin llegar a ser paralelos a ella(s).

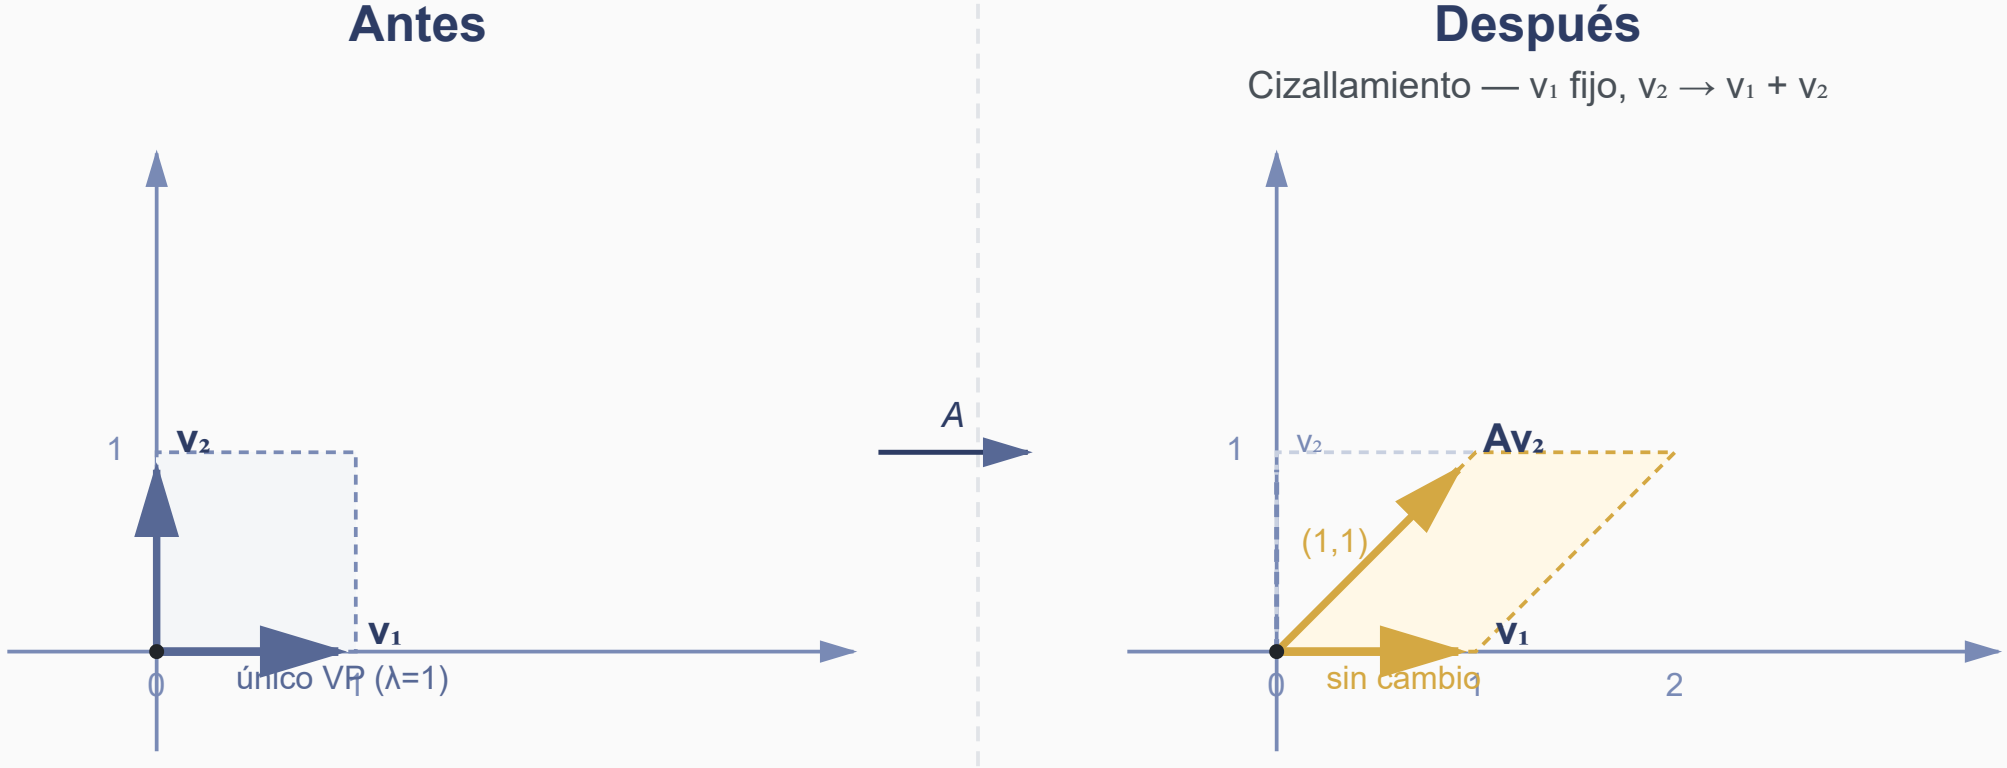

Valores propios como descriptores geom. (casos 2×2)

Caso	Ejemplo	Valores propios	Efecto geométrico
Reales distintos positivos	$\begin{bmatrix} 2 & 0 \\ 0 & 1/2 \end{bmatrix}$	$2,\ 1/2$	Estiramiento y compresión en direcciones propias
Reales distintos, alguno negativo	$\begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$	$-1,\ 1$	Reflexión respecto a un eje propio
Ambos reales negativos	$\begin{bmatrix} -2 & 0 \\ 0 & -1 \end{bmatrix}$	$-2,\ -1$	Rotación 180° + escalamiento
Doble real, 2 veps LI	$\begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}$	$3,\ 3$	Escalamiento uniforme (homotecia)
Doble real, defectiva	$\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$	$1,\ 1$	Cizallamiento hacia la dirección propia
Complejos conjugados	$\begin{bmatrix} 0 & -1 \\ & \end{bmatrix}$	$+i$	Roto-homotecia: escala $\sqrt{a^2+b^2}$,

Rotación en 3D y dimensiones superiores

Las rotaciones se definen como transformaciones que preservan distancias y ángulos.

¿Qué implica esto de sus valores propios?

Sugerencia: ¿existe algún vector que no se modifique al realizar una rotación en 3D?

Rotación en 3D - ejemplo

Calcular los valores y vectores propios de:

$$R = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

⏳ ...

Rotación en 3D — solución

$$p(\lambda) = (1-\lambda)\left[\lambda^2 + 1\right] = 0$$

Valores propios: $\lambda_1 = 1,\ \ \lambda_2 = i,\ \ \lambda_3 = -i$

Interpretación: R es una rotación de 90° en el plano xy.

- $\lambda_1 = 1$: el eje de rotación (z) queda fijo — su vector propio es $\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$.
- $\lambda = \pm i$: valores propios complejos conjugados — indican rotación en el plano perpendicular al eje.

En general, una rotación en $\mathbb{R}^3$ siempre tiene un valor propio real $\lambda = 1$ (el eje) y un par conjugado que codifica el ángulo de rotación.

Diagonalización

Diagonalización — definición

A es **diagonalizable** si existen P invertible y D diagonal tales que $A = PDP^{-1}$

$$A = P \begin{bmatrix} d_{11} & 0 & \cdots & 0 \\ 0 & d_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_{nn} \end{bmatrix} P^{-1}$$

Sean p_i las columnas de P, esto implica:

$$AP = PD \implies Ap_i = d_{ii}p_i, \quad \forall i$$

Por tanto p_i es un vector propio de A con valor propio d_{ii}.

A es diagonalizable si y solo si sus vectores propios forman una base del espacio $\mathbb{R}^n$

Diagonalización — cuándo es posible

- Si todos los valores propios son **distintos**: A es siempre diagonalizable (¿por qué?).
- Con valores propios repetidos: diagonalizable $\iff$ multiplicidad geométrica = algebraica para cada λ_i (¿por qué?)
- Caso suficiente: matrices simétricas son **siempre** diagonalizables (lo veremos en breve).

Diagonalización — utilidad

Si $A = PDP^{-1}$, entonces:

$$A^k = PD^kP^{-1}$$

Calcular D^k es trivial: $D^k = \begin{bmatrix} \lambda_1^k & 0 \\ 0 & \lambda_2^k \end{bmatrix}$.

En general: las matrices diagonalizables son aquellas tal que existe una base en la que su acción es simplemente escalar cada vector por su valor propio. Esto simplifica su análisis mediante el cambio de base dado por P.

Diagonalización — ejemplo

Diagonalizar $A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$ del ejemplo anterior:

$$P = \begin{bmatrix} 1 & 1 \\ -2 & 1 \end{bmatrix}, \quad D = \begin{bmatrix} 2 & 0 \\ 0 & 5 \end{bmatrix}$$

$$P^{-1} = \frac{1}{3} \begin{bmatrix} 1 & -1 \\ 2 & 1 \end{bmatrix}$$

Verificar: $PDP^{-1} = A$ ✓

Matrices Simétricas y Definidas Positivas

Matrices simétricas y sus valores propios

Recordatorio: A es **simétrica** si $A = A^T$.

Teorema espectral

Para una matriz simétrica real $A \in \mathbb{R}^{n \times n}$:

1. A es siempre **diagonalizable** — tiene n vectores propios linealmente independientes ($A = PDP^{-1}$)
2. Los vectores propios de distintos valores propios son **ortogonales** ($P^\top = P^{-1}$)
3. Todos sus valores propios son reales.

Por tanto:

$$A = PDP^T$$

donde D es diagonal con los valores propios en la diagonal.

Interpretación geométrica del teorema espectral

Las matrices simétricas tienen **ejes propios ortogonales** y solo **estiran o comprimen** a lo largo de esos ejes.

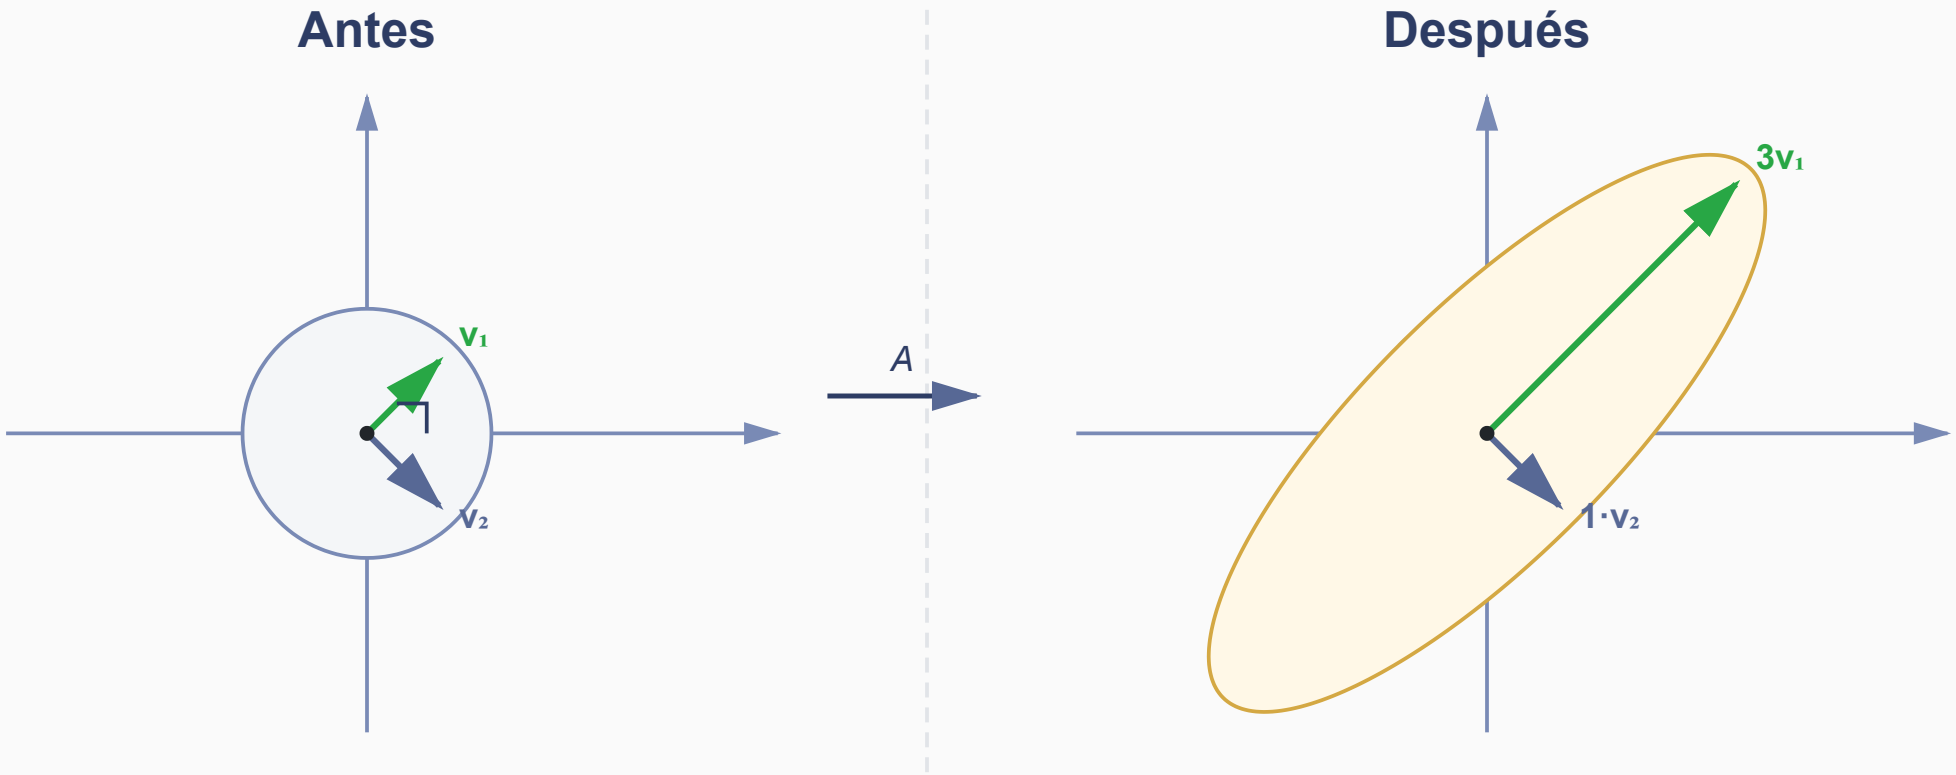

Matrices definidas positivas — definición

$A \in \mathbb{R}^{n \times n}$ simétrica es **definida positiva** (PD, Notación: $A \succ 0$) si:

$$\boxed{x^T A x > 0 \quad \forall x \neq 0}$$

Definida semipositiva (PSD, notación $A \succeq 0$) si:

$$\boxed{x^T A x \geq 0, \quad \forall x}$$

Ejercicio: mostrar que $A = B^\top B$ es siempre simétrica y semidefinida positiva.
Ejercicio: mostrar que $A = B + B^\top$ es siempre simétrica, pero no necesariamente PSD.
Ejercicio: mostrar que $x^T A x = x^T A^\top x = \frac{1}{2} x (A + A^\top) x$

Matrices definidas positivas — valores propios

Sea A simétrica real. Entonces:

- A es semidefinida positiva $\iff$ todos sus valores propios son **no negativos**.
- A es definida positiva $\iff$ todos sus valores propios son **estrictamente positivos**.

Sea A arbitraria (no simétrica). Entonces:

- Si A es semidefinida positiva, entonces todos sus valores propios tienen parte real **no negativa**.
- Si A es definida positiva, entonces todos sus valores propios tienen parte real **estrictamente positiva**.

Ejercicio: mostrar que para una matriz 2×2, si $a_{11} > 0$ y $\det(A) > 0$, entonces A es definida positiva.

BONUS: Matrices no diagonalizables — forma de Jordan

No todas las matrices son diagonalizables. Cuando la multiplicidad geométrica $<$ algebraica para algún λ_i, la matriz es **defectiva**: no tiene n vectores propios linealmente independientes.

La noción de diagonalización puede generalizarse. A esta generalización se la llama **forma de Jordan**. Puede verse que toda matriz puede *casi* diagonalizarse utilizando esta forma.

Por ejemplo, una matriz A con un valor propio λ de multiplicidad algebraica 3 pero multiplicidad geométrica 1, siempre se puede escribir como $A = PJP^{-1}$ con:

$$J = \begin{bmatrix} \lambda & 1 & 0 \\ 0 & \lambda & 1 \\ 0 & 0 & \lambda \end{bmatrix} \quad (\text{bloque de Jordan } 3 \times 3)$$

En este curso **no profundizaremos en la forma de Jordan**.

Normas matriciales

Norma espectral de una matriz

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2$$

La norma espectral mide la máxima expansión que A puede producir.

Norma de Frobenius

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$$

La norma de Frobenius mide la "magnitud total" de los elementos de A (raíz de la suma de todos sus elementos al cuadrado).

Normas matriciales y valores propios de $A^T A$

$A^T A$ es simétrica y PSD, entonces:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$$

Norma espectral de una matriz

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\lambda_1}$$

(veremos la demostración la próxima clase)

Norma de Frobenius

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\sum_{i=1}^{n} \lambda_i}$$

(surge directamente de la propiedad de que $\|A\|_F^2 = \mathrm{tr}(A^T A) = \sum_{i=1}^n \lambda_i$)

Normas matriciales: Ejemplo

Ejemplo: $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$

$$A^T A = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}, \ \lambda_{\max} = 3 + 2\sqrt{2}$$

$$\|A\|_2 = \sqrt{3 + 2\sqrt{2}} \approx 2.41 \quad \|A\|_F = \sqrt{6} \approx 2.45$$

Resumen de clase

Herramientas de soporte: traza, determinante, polinomio característica

Definición y cálculo: $Av = \lambda v$, espacios propios, multiplicidades algebraica y geométrica

Interpretación geométrica: escala, reflexión, rotación, cizallamiento — se deducen de los valores propios

Diagonalización: $A = PDP^{-1}$

Casos especiales: matrices simétricas (valores propios reales, vectores ortogonales), definidas positivas (valores propios positivos)

Normas matriciales: $\|A\|_2$ y $\|A\|_F$ vía valores propios de $A^T A$