Matemática para Aprendizaje Automático

Unidad 2 — Semana 3 (clases 5 y 6)

Resolución de $Ax = b$: el caso general

Pablo A. Iturralde · Universidad Católica del Uruguay · 2026

Plan de las clases

Repaso: tres miradas sobre $Ax = b$, existencia y unicidad

Sistemas sobredeterminados ($m > n$): mínimos cuadrados, ecuación normal, regresión

Sistemas subdeterminados ($n > m$): estructura del espacio de soluciones, norma mínima

Cierre: la pseudoinversa como solución unificada

Aviso: las diapositivas son un resumen de los temas tratados. No sustituyen la lectura de las notas del curso (secciones 3–5) ni de los textos recomendados (Strang ILA §4; Deisenroth, Faisal & Ong MML §9.2).

Parte 1

El problema $Ax = b$

Encuadre

Sea $A \in \mathbb{R}^{m \times n}$, $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$. Queremos encontrar x tal que

$$Ax = b.$$

Detrás de cuatro símbolos hay un universo de casos. Hoy nos vamos a focalizar en el caso **cuadrado e invertible**; las próximas dos semanas relajamos esto.

Por ahora trabajamos con **igualdad estricta**. Más adelante consideraremos $Ax \approx b$.

Tres miradas sobre la misma ecuación

1. Sistema de ecuaciones. Una ecuación por cada fila de A:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m \end{aligned}$$

Tres miradas sobre la misma ecuación

2. Transformación lineal. A es una transformación entre espacios:

$$A : \mathbb{R}^n \to \mathbb{R}^m, \qquad x \mapsto Ax.$$

Dado $b \in \mathbb{R}^m$, buscamos el vector x que se transforma en b. Resolver $Ax = b$ equivale a *invertir* la transformación.

Tres miradas sobre la misma ecuación

3. Coordenadas en el espacio columna. Las columnas de A son vectores en $\mathbb{R}^m$. Buscamos las coordenadas que expresan b como combinación lineal:

$$\vec{b} = x_1\,\vec{a}_1 + x_2\,\vec{a}_2 + \cdots + x_n\,\vec{a}_n.$$

Las tres miradas son equivalentes — la misma ecuación, perspectivas distintas. Según el problema, una es más útil que la otra.

Existencia y unicidad

¿Cuándo existe solución?

$$\boxed{Ax = b \text{ tiene solución} \iff b \in \operatorname{span}(A)}$$

(es decir, b es combinación lineal de las columnas de A)

Si existe, ¿es única?

$$\boxed{\text{La solución es única} \iff \text{las columnas de } A \text{ son LI} \iff \operatorname{rank}(A) = n}$$

Caso especial: A cuadrada $n \times n$

Cuando A es cuadrada, las nociones de rango completo, invertibilidad y span máximo coinciden:

$$\operatorname{rank}(A) = n \iff A \text{ invertible} \iff \operatorname{span}(A) = \mathbb{R}^n.$$

Esto deja **dos escenarios**:

1. A **invertible**: la solución existe y es única.
2. A **no invertible**: o no hay solución (incompatible) o hay infinitas (compatible indeterminado).

Ejemplos: A no invertible

Compatible indeterminado — $b \in \operatorname{span}(A)$, infinitas soluciones:

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 2 \\ 2 \end{bmatrix}, \qquad x_1 + x_2 = 2.$$

Cualquier x con $x_1 + x_2 = 2$ resuelve: $(0, 2)$, $(1, 1)$, $(2, 0)$, ...

Incompatible — $b \notin \operatorname{span}(A)$, no hay solución:

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

Las dos filas dan la misma combinación, pero pedimos resultados distintos.

Parte 2

Caminos para resolver $Ax = b$

(con A cuadrada e invertible)

Tres caminos conocidos

Camino 1 — Inversión. Calcular A^{-1} y hacer $x = A^{-1}b$.

Camino 2 — Factorización QR (vista en unidad 1). Si $A = QR$ con Q ortogonal y R triangular superior, reducimos a un sistema triangular.

Camino 3 — Eliminación gaussiana. Reducir $[A \mid b]$ a triangular superior y sustituir.

¿Cuál conviene?

Camino 1: ¿por qué evitar invertir?

Calcular A^{-1} equivale a resolver n sistemas en simultáneo: hallar B tal que $AB = I$, columna a columna.

Aspecto	Inversión + producto
Costo	$\sim 2n^3$ (factorización) $+2n^2$ (producto)
Precisión	Acumula errores de las n resoluciones
Memoria	Hay que guardar A^{-1} entera

Resolver el sistema directamente cuesta menos y propaga menos error.

Camino 2: resolver con QR

Si $A = QR$ con Q ortogonal ($Q^\top Q = I$) y R triangular superior:

$$Ax = b \;\Rightarrow\; QRx = b \;\overset{Q^\top}{\Rightarrow}\; Rx = Q^\top b.$$

Dos pasos (asumiendo Q, R ya calculadas):

1. Producto matriz–vector: $d = Q^\top b$ ($O(n^2)$).
2. Sustitución hacia atrás: $Rx = d$ ($O(n^2)$).

La parte cara es la factorización en sí ($\sim 2n^3$ por Gram-Schmidt, vista en unidad 1).

QR: ejemplo 3×3

Supongamos que ya tenemos $A = QR$ con

$$Q = \frac{1}{3}\begin{bmatrix} 2 & -2 & 1 \\ 2 & 1 & -2 \\ 1 & 2 & 2 \end{bmatrix}, \quad R = \begin{bmatrix} 3 & 6 & 9 \\ 0 & 3 & 6 \\ 0 & 0 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 6 \\ 3 \\ 9 \end{bmatrix}.$$

Paso 1 — calcular $d = Q^\top b$:

$$d = \frac{1}{3}\begin{bmatrix} 2 & 2 & 1 \\ -2 & 1 & 2 \\ 1 & -2 & 2 \end{bmatrix}\begin{bmatrix} 6 \\ 3 \\ 9 \end{bmatrix} = \begin{bmatrix} 9 \\ 3 \\ 6 \end{bmatrix}.$$

Paso 2 — sustitución hacia atrás en $Rx = d$:

$$3x_3 = 6 \Rightarrow x_3 = 2; \;\; 3x_2 + 6 \cdot 2 = 3 \Rightarrow x_2 = -3; \;\; 3x_1 + 6(-3) + 9 \cdot 2 = 9 \Rightarrow x_1 = 3.$$

Mini ejemplo: eliminación gaussiana

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 2 & 2 \end{bmatrix} x = \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}.$$

Matriz aumentada y combinación de filas (resta de la primera fila a la segunda y tercera; luego de la segunda a la tercera):

$$\left[\begin{array}{ccc|c} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 2 \\ 0 & 0 & -1 & -1 \end{array}\right].$$

Sustitución hacia atrás: $x_3 = 1$, $x_2 = 0$, $x_1 = 0$.

Comparación: costo y precisión

Método	Costo	Precisión
Inversión + producto $A^{-1}b$	$\sim 2n^3$	Peor (acumula error)
Factorización QR	$\sim 2n^3$	Buena, pero más cara
Eliminación gaussiana / LU	$\sim \frac{2}{3}n^3$	Mejor relación costo / precisión

La eliminación gaussiana hace **3× menos cuentas** que la inversión y propaga menos error.

`np.linalg.solve(A, b)` usa esta vía por debajo (con pivoteo). No invierte A.

Los tres casos

Cuando A tiene rango completo ($r = \min(m, n)$):

Forma de A	Condición	Soluciones
Cuadrada $m = n = r$	A invertible	Una, exacta
Alta $m > n = r$	$b \notin \operatorname{span}(A)$ en general	Ninguna exacta → aproximar
Ancha $n > m = r$	A sobreyectiva	Infinitas exactas

Las partes 3 y 4 abordan los dos casos no cuadrados.

Parte 3

Sistemas sobredeterminados

($m > n$: más ecuaciones que incógnitas)

Encuadre

$A \in \mathbb{R}^{m \times n}$ alta, con $m > n$ y rango columna completo ($r = n$).

El espacio columna $\mathrm{span}(A)$ tiene dimensión $n < m$: **la mayoría de los $b \in \mathbb{R}^m$ no pertenecen a $\mathrm{span}(A)$.**

Casos donde esto aparece: ajuste de curvas a datos experimentales, regresión lineal, sistemas de medición redundantes.

¿Qué hacemos cuando $Ax = b$ no tiene solución exacta?

Formulación: mínimos cuadrados

Si no existe solución exacta, relajamos el objetivo:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2.$$

La solución x^* se llama **solución de mínimos cuadrados**.

> *La norma-2 es una **decisión de diseño**, no una consecuencia del modelo. Otras normas son posibles; se discuten al final de esta parte.*

Interpretación geométrica

Descomponemos b respecto al espacio columna de A:

$$b = \underbrace{b_A}_{\in\, \mathrm{span}(A)} + \underbrace{b_\perp}_{\in\, \mathrm{Ker}(A^\top)}$$

De la misma forma, podemos descomponer $Ax - b$, notando que $Ax \in \mathrm{span}(A)$:

$$Ax - b = Ax - (b_A + b_\perp) = (Ax - b_A) + b_\perp.$$

Por el teorema de Pitágoras:

$$\|Ax - b\|_2^2 = \|Ax - b_A\|_2^2 + \|b_\perp\|_2^2$$

El término $\|b_\perp\|_2^2$ no depende de x. El mínimo se alcanza cuando $Ax^* = b_A$: el **residuo** $r = b - Ax^* = b_\perp$ **es ortogonal a** $\mathrm{span}(A)$.

Ecuación normal

La condición $r \perp \mathrm{span}(A)$ equivale a $A^\top r = 0$:

$$A^\top(b - Ax^*) = 0 \implies \boxed{A^\top A\, x^* = A^\top b.}$$

Ecuación(es) normal(es)

Si asumimos que A tiene rango columna completo, $A^\top A$ es invertible (SDP) y la solución es **única**:

$$x^* = (A^\top A)^{-1} A^\top b = A^+ b.$$

El residuo mínimo es $r = b_\perp$ y $\min_x \|Ax - b\|^2 = \|b_\perp\|^2$.

Ejemplo 1 — $b \notin \operatorname{span}(A)$

$$A = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}, \qquad b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

El sistema $Ax = b$ no tiene solución exacta: b no es combinación lineal de las columnas de A.

Calcular la solución de mínimos cuadrados x^* y verificar que $A^\top(b - Ax^*) = 0$.

Ejemplo 1 — Solución

Con $A^+ = \frac{1}{12}\begin{bmatrix} 5 & 2 & -1 \\ -1 & 2 & 5 \end{bmatrix}$:

$$x^* = A^+ b = \frac{1}{12}\begin{bmatrix} 7 \\ 13 \end{bmatrix}.$$

Residuo: $r = b - Ax^* = \frac{1}{6}\begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix}$.

Verificación:

$$A^\top r = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & 2 \end{bmatrix} \frac{1}{6}\begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad \checkmark$$

Costo mínimo: $\|r\|^2 = \frac{1}{6}$.

Ejemplo 2 — $b \in \mathrm{span}(A)$

Misma A, nuevo $b = [2,\ 2,\ 2]^\top$.

Verificar que $b = 1 \cdot a_1 + 1 \cdot a_2$ (columnas de A): el sistema tiene solución exacta.

¿Qué da la fórmula de mínimos cuadrados en este caso?

Ejemplo 2 — Solución

$$x^* = A^+ b = \frac{1}{12}\begin{bmatrix} 5 & 2 & -1 \\ -1 & 2 & 5 \end{bmatrix}\begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Verificar: $Ax^* = [2,\ 2,\ 2]^\top = b$. Residuo $r = 0$.

> *Cuando $b \in \operatorname{span}(A)$, la solución de mínimos cuadrados coincide con la solución exacta. La formulación es consistente con el caso determinado.*

Cómo calcular x^*: tres caminos

Camino	Método	Costo	Estabilidad	Uso en la práctica
1	Ecuaciones normales + Cholesky	$\sim mn^2 + \frac{1}{3}n^3$	Moderada (κ^2)	No/Problemas en papel
2	Factorización QR reducida	$\sim 2mn^2$	Mejor posible	Problemas de rango completo solo
3	Pseudoinversa vía SVD	$\sim 2mn^2$	Mejor posible	Problemas de cualquier rango

El caminos 1 (y el 2 si se calcula la pseudoinversa via $(A^\top A)^{-1}A^\top$, que no es óptimo) usan la matriz $A^\top A$, lo que **eleva el número de condición al cuadrado**. QR y SVD pueden trabajar directamente con A.

`np.linalg.lstsq(A, b)` usa SVD (`gelsd` de LAPACK) sin construir la matriz $A^\top A$ por defecto.

Aplicación: ¿Cómo hallamos la mejor recta que se ajusta a un conjunto de datos?

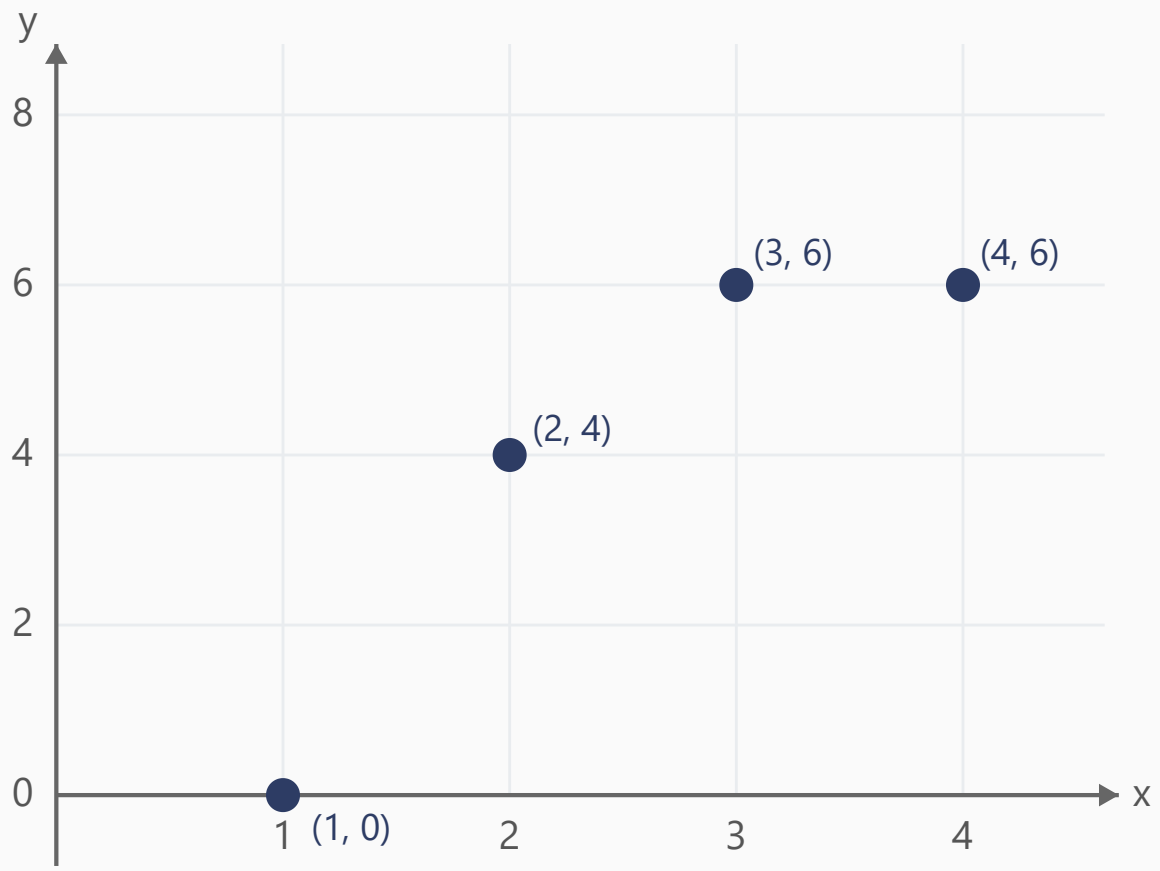

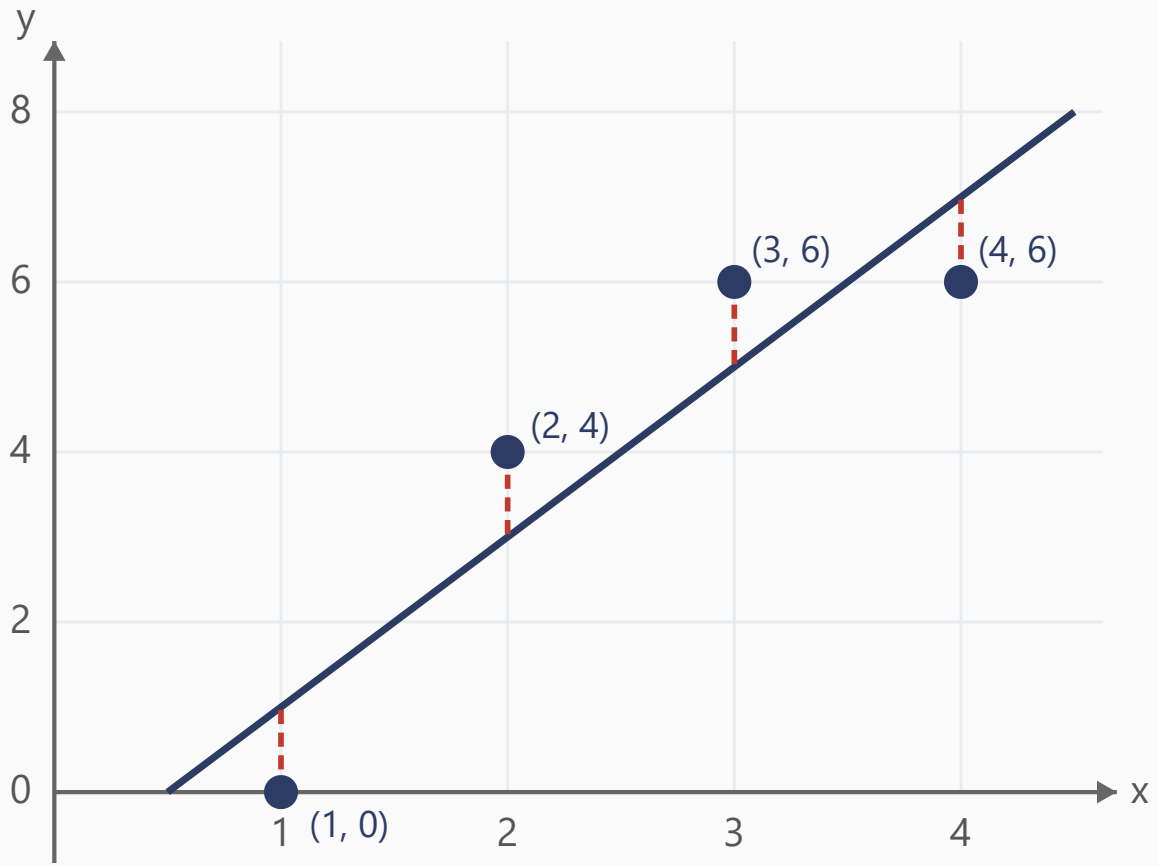
y
8
6
4
2
0
x
1
2
3
4
(1, 0)
(2, 4)
(3, 6)
(4, 6)

La mejor recta por un conjunto de datos: formulación de mínimos cuadrados

Dados m puntos $(x_1, y_1), \ldots, (x_m, y_m)$, buscamos $y = cx + d$ que minimice la suma de cuadrados de los **errores verticales** $e_i = y_i - (cx_i + d)$:

$$\min_{c,d} \sum_{i=1}^{m} (cx_i + d - y_i)^2 \;=\; \min_{x} \|Ax - b\|^2.$$

$$A = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_m & 1 \end{bmatrix}, \quad x = \begin{bmatrix} c \\ d \end{bmatrix}, \quad b = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}.$$

Ejemplo 3 — Cuatro puntos no colineales (planteo)

Puntos: $(1,0),\ (2,4),\ (3,6),\ (4,6)$.

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{bmatrix}, \qquad b = \begin{bmatrix} 0 \\ 4 \\ 6 \\ 6 \end{bmatrix}.$$

Encontrar la recta de mínimos cuadrados.

Ejemplo 3 — Solución

$$A^\top A = \begin{bmatrix} 30 & 10 \\ 10 & 4 \end{bmatrix}, \quad A^\top b = \begin{bmatrix} 50 \\ 16 \end{bmatrix}.$$

$$x^* = (A^\top A)^{-1} A^\top b = \frac{1}{20} \begin{bmatrix} 4 & -10 \\ -10 & 30 \end{bmatrix} \begin{bmatrix} 50 \\ 16 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

La recta es $y = 2x - 1$. Residuo: $\|Ax^* - b\|^2 = 4$.

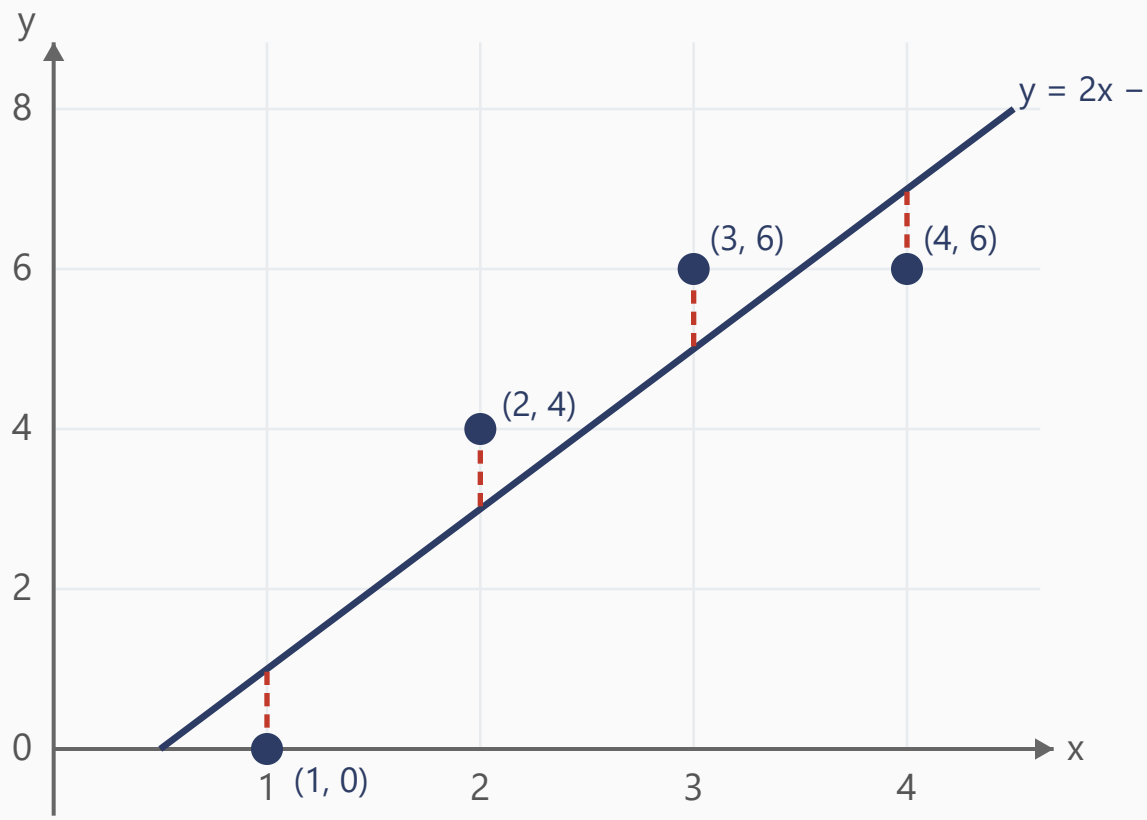

¿La única forma de definir mejor recta?

Ejemplo 5 — Parametrización alternativa

Mismos puntos: reparametrizamos la recta como $x = ey + f$, y minimizamos ahora el **error cuadrático horizontal** $\sum_i |e_i|^2$ donde $e_i = x_i - (ey_i + f)$.

$$A = \begin{bmatrix} 0 & 1 \\ 4 & 1 \\ 6 & 1 \\ 6 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \quad \Longrightarrow \quad x^* = \begin{bmatrix} 5/12 \\ 5/6 \end{bmatrix}.$$

La recta resultante es $y = \frac{12}{5}x - 2$, **distinta** de $y = 2x - 1$.

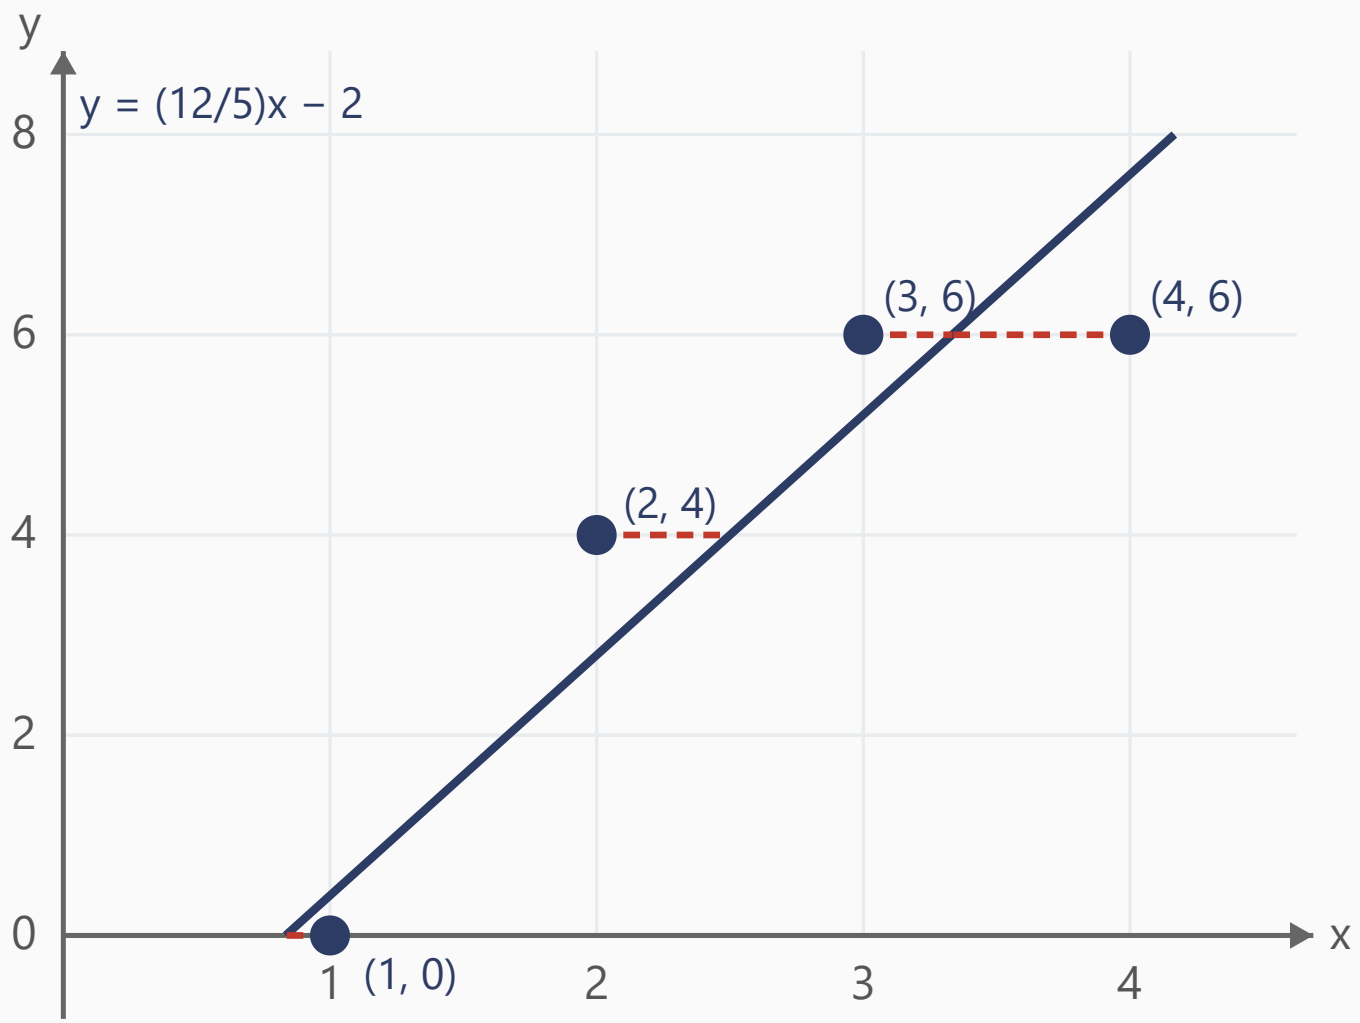
y
y = (12/5)x − 2
8
6
4
2
0
(3, 6)
(4, 6)
(2, 4)
(1, 0)
1
2
3
4
x

Tres formulaciones, tres rectas distintas

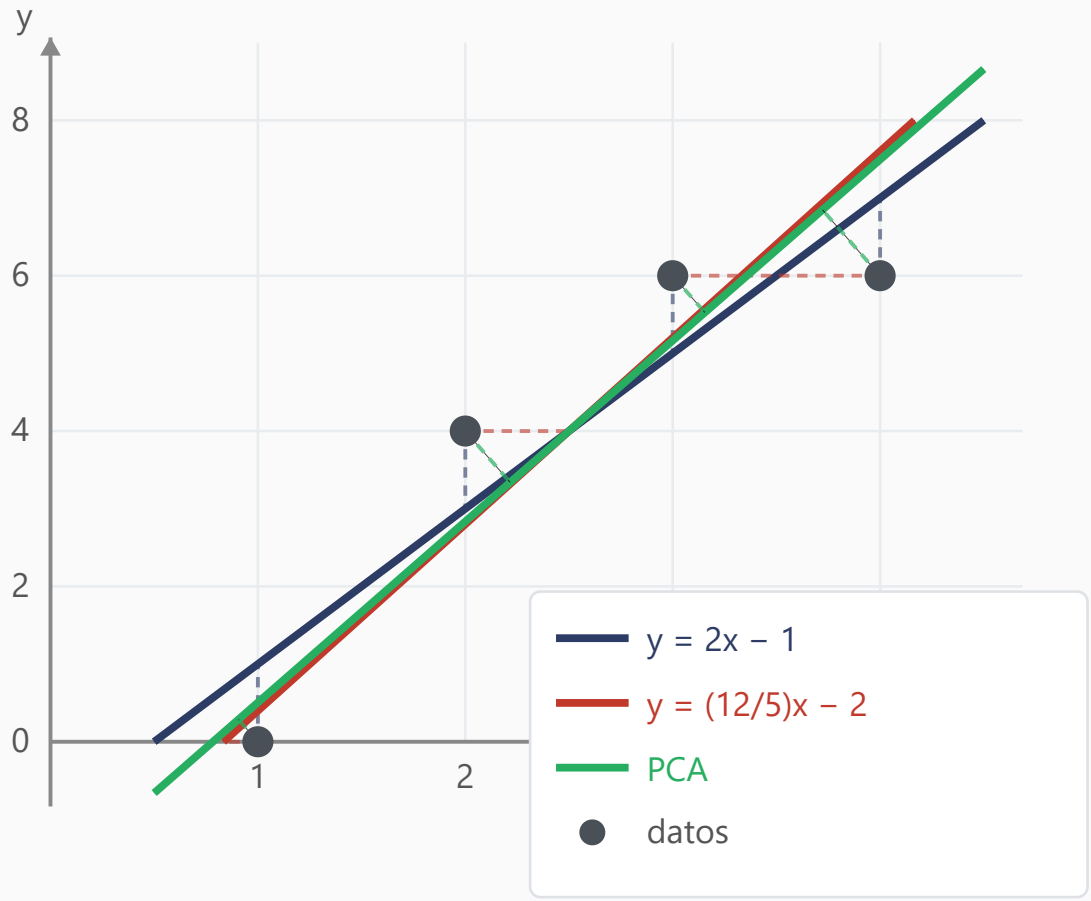

La noción de "mejor" es una decisión de diseño y depende del problema. No se desprende de los datos.

Regresión lineal generalizada

El mismo marco cubre cualquier modelo **lineal en los parámetros**. Supongamos una expresión de la forma:

$$y = c_1 f_1(x) + c_2 f_2(x) + \cdots + c_p f_p(x),$$

Y deseamos minimizar $\sum_i e_i^2$ con $e_i = y_i - \sum_{j=1}^{p} c_j f_j(x_i)$.

Este problema se reduce a un sistema de mínimos cuadrados:

$$\min_x \|Ax - b\|_2^2$$

Donde los elementos de la matrix A son $A_{ij} = f_j(x_i)$ y los elementos del vector b son $b_i = y_i$.

Ejemplos de funciones base: $\{1,\, x,\, x^2,\, \ldots,\, x^p\}$, $\{\sin(kx)\}$, $\{\ln(x)\}$.

Ejemplo 6 — Mejor parábola

Mismos cuatro puntos $(1,0),\ (2,4),\ (3,6),\ (4,6)$.

Buscamos $y = ax^2 + bx + c$. Funciones base: $f_1(x) = x^2,\ f_2(x) = x,\ f_3(x) = 1$.

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 4 & 2 & 1 \\ 9 & 3 & 1 \\ 16 & 4 & 1 \end{bmatrix}, \qquad y = \begin{bmatrix} 0 \\ 4 \\ 6 \\ 6 \end{bmatrix}.$$

Resolver las ecuaciones normales $A^\top A\, c = A^\top y$.

Ejemplo 6 — Solución

$$\begin{bmatrix} 354 & 100 & 30 \\ 100 & 30 & 10 \\ 30 & 10 & 4 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 166 \\ 50 \\ 16 \end{bmatrix} \implies a = -1,\ b = 7,\ c = -6.$$

Ejercicio: Calcular el residuo y verificar que en este caso es 0 (la parábola pasa **exactamente** por los cuatro puntos y $Ax = b$).

> *En general con más parámetros se pueden realizar mejores ajustes (aunque no necesariamente 0). El compromiso apropiado entre número de parámetros (complejidad del modelo) y residuo aceptable en un problema es otra decisión de diseño.*

Otras normas

Norma	Problema	Propiedad
ℓ_2 (estándar)	$\min_x \lvert Ax - b\rvert_2^2$	Solución analítica; sensible a outliers
ℓ_1	$\min_x \lvert Ax - b\rvert_1$	Robusta ante outliers; requiere métodos numéricos
ℓ_∞	$\min_x \lvert Ax - b\rvert_\infty$	Minimiza el error del peor caso; requiere métodos numéricos

La norma-2 se elige por su conveniencia analítica cuando no hay razón para preferir otra.

Parte 4

Sistemas subdeterminados

($n > m$: más incógnitas que ecuaciones)

Encuadre

$A \in \mathbb{R}^{m \times n}$ ancha, con $n > m$ y rango fila completo ($r = m$).

Como $r = m$, la transformación es **sobreyectiva**: para todo $b \in \mathbb{R}^m$ existe solución.

Como $\dim(\mathrm{Ker}(A)) = n - m > 0$, hay **infinitas soluciones**.

Casos típicos: sistemas de control subactuados, redes de flujo, *compressed sensing*.

Estructura del conjunto de soluciones

Sea x_p cualquier solución particular ($Ax_p = b$). El conjunto de todas las soluciones es el **espacio afín**:

$$\{x_p + v \ : \ v \in \mathrm{Ker}(A)\}.$$

Dimensión: $n - m$.

> *Si* $Ax_p = b$ *y* $Av = 0$, *entonces* $A(x_p + v) = Ax_p + Av = b$. ✓

Cómo encontrar una solución particular

Una forma sistemática: fijar $n - m$ variables en cero, resolver el sistema cuadrado resultante.

Si las m columnas asociadas a las variables libres son LI, el sistema cuadrado es compatible determinado y se resuelve directamente.

La solución es válida pero no especial: distintas elecciones de variables producen distintas soluciones particulares.

Ejemplo 4.1 — Sistema 1×2 (planteo)

$$A = \begin{bmatrix} 3 & 4 \end{bmatrix}, \quad b = [5].$$

La ecuación $3x_1 + 4x_2 = 5$ define una recta en $\mathbb{R}^2$.

Encontrar dos soluciones particulares y describir el conjunto de todas las soluciones.

Ejemplo 4.1 — Solución

$\mathrm{Ker}(A)$: generado por $v = (-4,\, 3)^\top$ (verificar: $3(-4) + 4(3) = 0$ ✓).

Dos soluciones particulares:

- Fijando $x_1 = 0$: $\quad x^{(1)} = (0,\ \frac{5}{4})^\top$
- Fijando $x_2 = 0$: $\quad x^{(2)} = (\frac{5}{3},\ 0)^\top$

Conjunto de soluciones:

$$\left\{x^{(1)} + t\,(-4,\, 3)^\top : t \in \mathbb{R}\right\} \quad (\text{la recta } 3x_1 + 4x_2 = 5 \text{ en } \mathbb{R}^2).$$

Ejemplo 4.2 — Sistema 2×4 (planteo)

$$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Identificar el núcleo de A y describir el espacio afín de soluciones.

Ejemplo 4.2 — Solución

$\mathrm{Ker}(A)$: dimensión $n - m = 2$, generado por $v_1 = (1, -1, 0, 0)^\top$, $v_2 = (0, 0, 1, -1)^\top$.

Solución particular: $x^{(1)} = (0, 1, 1, 0)^\top$.

Conjunto de soluciones (plano afín en $\mathbb{R}^4$):

$$\left\{(\alpha,\ 1-\alpha,\ 1+\beta,\ -\beta)^\top : \alpha, \beta \in \mathbb{R}\right\}.$$

Dos grados de libertad: un parámetro libre por cada ecuación "faltante".

Entre todas las infinitas soluciones…

¿existe alguna que sea preferible?

Solución de norma mínima

El conjunto de soluciones es un espacio afín — tiene un **punto más cercano al origen**.

Ese punto es la **solución de norma mínima** $x_{\min}$.

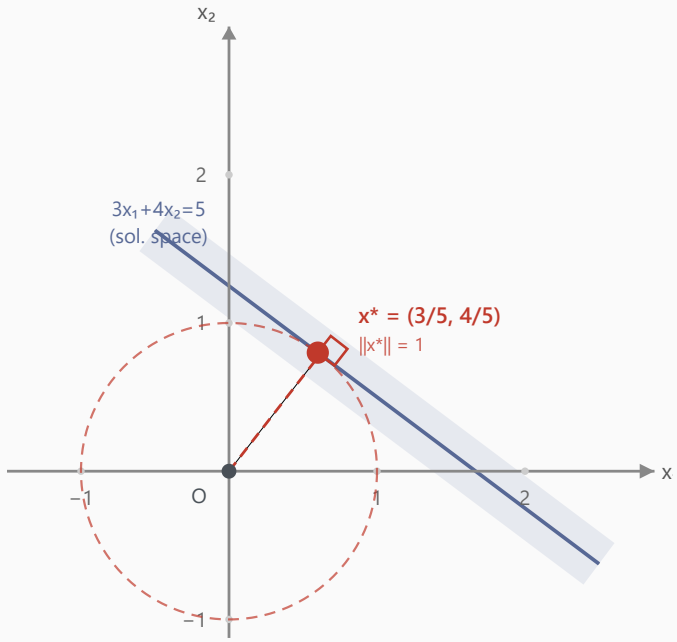

Derivación

Toda solución se descompone ortogonalmente:

$$x = \underbrace{x_{\text{row}}}_{\in \text{span}(A^\top)} + \underbrace{x_\perp}_{\in \text{Ker}(A)}$$

Como $Ax_\perp = 0$, x_{row} sola es también solución. Por Pitágoras:

$$\|x\|^2 = \|x_{\text{row}}\|^2 + \|x_\perp\|^2 \geq \|x_{\text{row}}\|^2$$

con igualdad si y solo si $x_\perp = 0$.

La solución de norma mínima es la **única solución en** $\text{span}(A^\top)$.

Fórmula

Como $x_{\min} \in \operatorname{span}(A^\top)$, existe y tal que $x_{\min} = A^\top y$. Sustituyendo en $Ax_{\min} = b$:

$$AA^\top y = b \implies y = (AA^\top)^{-1} b.$$

$$\boxed{x_{\min} = A^\top (AA^\top)^{-1} b = A^+ b.}$$

A^+ es la **inversa por derecha** de A (coincide con la pseudoinversa cuando A tiene rango fila completo).

Ejemplo 8 — Sistema 2×3 (planteo)

$$A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Encontrar tres soluciones particulares y determinar cuál tiene norma mínima.

Ejemplo 8 — Solución

Tres soluciones particulares (fijando $x_i = 0$):

$$x^{(1)} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} -1 \\ 0 \\ 2 \end{bmatrix}, \quad x^{(3)} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}. \qquad \|x^{(i)}\| = \sqrt{2},\ \sqrt{5},\ \sqrt{5}.$$

Solución de norma mínima:

$$x_{\min} = A^{+}b = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = x^{(1)}. \qquad \checkmark$$

Coincide con $x^{(1)}$ — coincidencia en este caso, no regla general.

Otras nociones de "mejor" solución

Criterio	Formulación	Uso
Norma ℓ_2 mínima	$\min \lvert x\rvert_2$ s.a. $Ax = b$	Solución canónica (A^+b)
Norma ℓ_1 mínima	$\min \lvert x\rvert_1$ s.a. $Ax = b$	Soluciones esparsas (*compressed sensing*)
Regularización	$\min \lvert Ax - b\rvert_2^2 + \lambda \lvert x\rvert_2^2$	Controla el tamaño de la solución

La regularización con $\lambda \to 0^+$ converge a la solución de norma-2 mínima.

Parte 5

El caso general y la pseudoinversa como solución unificada

Resumen hasta ahora

Tipo de A	Condición	Solución	Tipo de Solución
Cuadrada e invertible	$m = n = r$	$x = A^{-1}b$	Únicao vector que satisface $Ax = b$
Alta, rango col. completo	$m > n = r$	$x = (A^\top A)^{-1}A^\top b$	Única que minimiza $\|Ax - b\|_2$
Ancha, rango fila completo	$n > m = r$	$x = A^\top(AA^\top)^{-1}b$	Solución "más chica" (norma mínima) de Ax=b
Caso general	$r < \min(m, n)$	???	???

El caso general

¿Qué quiere decir resolver $Ax = b$ cuando A no tiene rango completo?

Tenemos una combinación de los dos casos anteriores (sobredeterminado y subdeterminado):

- Como $\mathrm{span}(A)$ no necesariamente contiene a b, no hay garantía de que exista solución exacta.
  Solo podemos aspirar a hallar soluciones aproximadas, por ejemplo, buscar la que minimice el residuo $\|Ax - b\|_2$ (mínimos cuadrados).
- Como $\mathrm{Ker}(A)$ no necesariamente es trivial (es decir contiene elementos no nulos), el conjunto de soluciones, incluso en el sentio de mínimos cuadrados, puede ser un espacio afín con infinitas soluciones. Tenemos que elegir la mejor entre ellas — p.ej. la de norma mínima.

Solución del caso general

Si en el caso general $r < \min(m, n)$, nos proponemos hallar la solución de mínima norma $\|x\|_2$ entre las que minimizan el residuo $\|Ax - b\|_2$:

$$\min_x \|x\|_2 \quad \text{s.a.} \quad \|Ax - b\|_2 = \min_z \|Az - b\|_2.$$

La solución es $x = A^+ b$, donde A^+ es la **pseudoinversa de Moore-Penrose** de A.

La demostración se reduce a trabajar como en los dos casos anteriores: la mejor aproximación $Ax \approx b$ implica $Ax = b_A$ donde b_A es la proyección de b sobre $\mathrm{span}(A)$, y dentro de todos los vectores x que cumplen esto,la solución de norma mínima es la proyección de cualquiera de dichas soluciones sobre $\mathrm{span}(A^\top)$.

Resumen final: Los cuatro casos

Tipo de A	Condición	Solución	Tipo de Solución	Relación con A^+
Cuadrada e invertible	$m = n = r$	$x = A^{-1}b$	Únicao vector que satisface $Ax = b$	$A^+ = A^{-1}$
Alta, rango col. completo	$m > n = r$	$x = (A^\top A)^{-1}A^\top b$	Única que minimiza $\|Ax - b\|_2$	$A^+ = (A^\top A)^{-1}A^\top$
Ancha, rango fila completo	$n > m = r$	$x = A^\top(AA^\top)^{-1}b$	Solución "más chica" (norma mínima) de Ax=b	$A^+ = A^\top(AA^\top)^{-1}$
Caso general	$r < \min(m, n)$	$x = A^+b$	Solución de norma mínima entre las que minimizan $\|Ax - b\|_2$	$A^+ = V\Sigma^+U^\top$ (SVD)

Fórmula unificada

$$\boxed{x = A^{+}b}$$

En todos los casos: primero **minimiza** $\|Ax - b\|_2$; entre todas las soluciones que alcanzan ese residuo mínimo, elige la de **menor norma**.

Los tres casos de rango completo son especializaciones donde A^{+} adopta formas cerradas que permiten despejar la solución analíticamente.

¿Preguntas?