Matemática para Aprendizaje Automático

Notas de Clase — Resolución de Sistemas Lineales Ax = b

Universidad Católica del Uruguay • 2026

> *Estas notas se encuentran en desarrollo. En caso de encontrar errores, se agradece lo notifiquen a pablo.iturralde@ucu.edu.uy.*

Referencias principales: Strang, *Introduction to Linear Algebra*, capítulos 2–4; Deisenroth, Faisal & Ong, *Mathematics for Machine Learning*, secciones 2.3–2.4 y 9.2.

Referencias complementarias: Strang, *Linear Algebra and Learning from Data*, capítulos I–III; Golub & Van Loan, *Matrix Computations*, capítulos 2–3 y 5; Trefethen & Bau, *Numerical Linear Algebra*, Lectures 11–13.

Contenidos

1. El problema Ax = b
   - 1.1 Tres miradas sobre la misma ecuación
   - 1.2 Existencia y unicidad
   - 1.3 Casos según forma y rango
2. Sistemas compatibles determinados
   - 2.1 Métodos de resolución
   - 2.2 Comparación práctica
3. Sistemas sobredeterminados: mínimos cuadrados
   - 3.1 Formulación e interpretación geométrica
   - 3.2 Cálculo de la solución
   - 3.3 Regresión lineal
     - 3.3.1 Mejor recta por un conjunto de puntos
     - 3.3.2 Regresión en dimensión mayor
     - 3.3.3 Regresión lineal generalizada: ajuste de curvas arbitrarias
   - 3.4 Otras normas
4. Sistemas subdeterminados: solución de norma mínima
   - 4.1 Estructura del conjunto de soluciones
   - 4.2 La solución de norma mínima
   - 4.3 Otras nociones de "mejor" solución
5. La pseudoinversa como solución unificada

1. El problema $Ax = b$

En esta unidad estudiamos cómo encontrar un vector $x \in \mathbb{R}^n$ que satisfaga

$$Ax = b,$$

donde $A \in \mathbb{R}^{m \times n}$ es una matriz dada y $b \in \mathbb{R}^m$ es un vector dado. Detrás de esta ecuación hay varios casos posibles según la forma de A y la relación entre b y las columnas de A. Antes de analizar esos casos conviene tener claras tres formas equivalentes de leer la misma ecuación.

1.1 Tres miradas sobre la misma ecuación

1. Sistema de ecuaciones. Cada fila de A da una ecuación lineal en las incógnitas $x_1, \ldots, x_n$:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m. \end{aligned}$$

Esta es la lectura más concreta: m restricciones lineales sobre n incógnitas.

2. Transformación lineal. La matriz A define una transformación lineal $A : \mathbb{R}^n \to \mathbb{R}^m$, y el vector b es un punto del codominio. Resolver $Ax = b$ es encontrar una preimagen de b bajo esa transformación.

3. Coordenadas en el espacio columna. Las columnas $a_1, \ldots, a_n$ de A son vectores en $\mathbb{R}^m$. La ecuación $Ax = b$ pide encontrar coeficientes $(x_1, \ldots, x_n)$ que expresen b como combinación lineal de esas columnas:

$$b = x_1 a_1 + x_2 a_2 + \cdots + x_n a_n.$$

Esta tercera perspectiva es la más útil para razonar sobre existencia: la ecuación tiene solución si y solo si b pertenece al espacio generado por las columnas de A, es decir, $b \in \operatorname{span}(A)$.

1.2 Existencia y unicidad

De la tercera mirada se desprende la condición de existencia:

$$Ax = b \text{ tiene solución} \iff b \in \operatorname{span}(A).$$

Si una solución existe, puede ser única o no. La unicidad depende de si hay vectores distintos de x que producen el mismo Ax. Eso ocurre cuando $\operatorname{Ker}(A)$ es no trivial: si $Ax_0 = b$ y $Av = 0$ con $v \neq 0$, entonces $A(x_0 + v) = b$ también. Por lo tanto:

$$\text{La solución (cuando existe) es única} \iff \operatorname{Ker}(A) = \{0\} \iff \operatorname{rango}(A) = n.$$

Estas dos condiciones — existencia y unicidad — son independientes entre sí. Una puede cumplirse sin la otra.

1.3 Casos según forma y rango

Suponiendo que A es de rango completo, es decir, $r = \min(m, n)$, los casos posibles son:

- $m = n = r$ **(sistema cuadrado de rango completo):** A es invertible; existe una única solución exacta.
- $m > n = r$ **(sistema sobredeterminado de rango columna completo):** A es alta; en general $b \notin \operatorname{span}(A)$ y no existe solución exacta, pero sí existe una única solución que minimiza $\|Ax - b\|_2$ (que definiremos en la sección 3).

- $n > m = r$ **(sistema subdeterminado de rango fila completo):** A es ancha; b siempre pertenece a $\mathrm{span}(A)$ (porque $r = m$ implica que A es sobreyectiva), y existen infinitas soluciones exactas.

El caso de rango deficiente ($r < \min(m, n)$) combina dificultades de los dos últimos — puede no haber solución exacta y a la vez haber infinitas soluciones — y requiere un tratamiento por separado; se estudia en la sección 5.

---

2. Sistemas compatibles determinados

Cuando A es cuadrada e invertible ($m = n = r$), existe una única solución exacta $x = A^{-1}b$. La pregunta práctica es cómo calcularla eficientemente.

2.1 Métodos de resolución

Camino 1 — Inversión directa. Calcular A^{-1} y hacer $x = A^{-1}b$. Esta opción es conceptualmente simple pero computacionalmente ineficiente: calcular A^{-1} equivale a resolver n sistemas lineales en simultáneo, con un costo aproximado de $2n^3$ operaciones y mayor acumulación de errores numéricos que los caminos alternativos. En la práctica, **no se recomienda** para resolver sistemas; sí tiene sentido cuando la inversa se necesita explícitamente para otros fines.

Camino 2 — Factorización LU. Factorizar $A = LU$ (o $PA = LU$ con pivoteo), donde L es triangular inferior con diagonal unitaria y U es triangular superior. El sistema $Ax = b$ se reduce a dos sistemas triangulares: $Ly = Pb$ (sustitución hacia adelante) y $Ux = y$ (sustitución hacia atrás). El costo de la factorización es $\approx \frac{2}{3}n^3$, y cada sistema adicional con la misma A cuesta solo $\sim 2n^2$. Se desarrolla en detalle en las notas de factorizaciones LU y Cholesky.

Camino 3 — Factorización QR. Si $A = QR$ con Q ortogonal y R triangular superior, el sistema se reduce a $Rx = Q^\top b$, que se resuelve por sustitución hacia atrás. El costo de la factorización es $\approx 2n^3$, mayor que LU, pero QR ofrece mejor estabilidad numérica en matrices mal condicionadas. Se desarrolla en las notas de factorización QR.

Para matrices simétricas definidas positivas (SDP), la **factorización de Cholesky** ($A = LL^\top$) tiene costo $\approx \frac{1}{3}n^3$ — la mitad que LU — y no requiere pivoteo. Es la opción preferida cuando A es SDP.

2.2 Comparación práctica

Método	Costo de factorización	Cada b adicional	Estabilidad	Recomendado para
Inversión $A^{-1}b$	$\sim 2n^3$	$\sim n^2$	Peor	Evitar para resolver sistemas
Factorización LU	$\sim \frac{2}{3}n^3$	$\sim 2n^2$	Buena	A general
Factorización de Cholesky	$\sim \frac{1}{3}n^3$	$\sim 2n^2$	Muy buena	A SDP
Factorización QR	$\sim 2n^3$	$\sim n^2$	Mejor	A mal condicionada

`np.linalg.solve(A, b)` usa LU con pivoteo parcial. **No invierte A.**

---

3. Sistemas sobredeterminados: mínimos cuadrados

Cuando $A \in \mathbb{R}^{m\times n}$ es alta ($m > n$) y tiene rango columna completo ($r = n$), el sistema $Ax = b$ tiene en general más restricciones que grados de libertad. El espacio columna $\mathrm{span}(A)$ tiene dimensión $n < m$, y un vector b genérico en $\mathbb{R}^m$ no tiene por qué pertenecer a ese subespacio.

La idea en este caso es reformular el problema, aceptando que en general no podremos obtener $Ax = b$ pero sí es posible buscar x que haga Ax lo más cercano posible a b posible.

3.1 Formulación e interpretación geométrica

Formulación: solución aproximada en norma-2

Podemos formalizar la intuición anterior observando que en el caso en que existen soluciones exactas tenemos:

$$Ax = b \iff Ax - b = 0 \iff \|Ax - b\| = 0.$$

Si el sistema no tiene solución exacta, no podemos alcanzar $\|Ax - b\| = 0$, pero podemos minimizar esta cantidad. Esto motiva el problema:

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|_2^2.$$

La solución a este problema se llama **solución de mínimos cuadrados**.

La elección de la norma-2 (y del cuadrado) es una **decisión de diseño**, no una consecuencia del problema original $Ax \approx b$. Otras normas son posibles y en algunos contextos más apropiadas; se comenta brevemente en la sección 3.4.

Interpretación geométrica y derivación

Sea $b = b_A + b_\perp$ la descomposición ortogonal de b respecto al espacio columna de A: $b_A \in \mathrm{span}(A)$ es la proyección de b sobre $\mathrm{span}(A)$, y $b_\perp \in \mathrm{Ker}(A^\top)$ es la componente ortogonal (ver las notas de pseudoinversa). Por el teorema de Pitágoras:

$$\|Ax - b\|^2 = \|Ax - b_A - b_\perp\|^2 = \|Ax - b_A\|^2 + \|b_\perp\|^2.$$

La segunda igualdad es válida porque $Ax - b_A \in \mathrm{span}(A)$ y $b_\perp \in \mathrm{Ker}(A^\top)$ son ortogonales. El término $\|b_\perp\|^2$ es constante respecto a x, así que minimizar $\|Ax - b\|^2$ equivale a minimizar $\|Ax - b_A\|^2$. Como $b_A \in \mathrm{span}(A)$, existe al menos un x^* con $Ax^* = b_A$, y para ese x^* el término $\|Ax^* - b_A\|^2 = 0$, que es el mínimo posible.

Entonces:

> *x^* es solución de mínimos cuadrados $\iff Ax^* = b_A \iff$ el residuo $r = b - Ax^*$ es ortogonal a $\mathrm{span}(A)$.*

La condición $r \perp \mathrm{span}(A)$ equivale a que r sea ortogonal a cada columna de A, es decir, $A^\top r = 0$:

$$A^\top(b - Ax^*) = 0 \implies A^\top b = A^\top A x^*.$$

Esto es la **ecuación normal** del problema de mínimos cuadrados:

$$\boxed{A^\top A\, x^* = A^\top b.}$$

Cuando A tiene rango columna completo, la matriz $A^\top A \in \mathbb{R}^{n\times n}$ es invertible (es simétrica definida positiva), y la solución es única:

$$x^* = (A^\top A)^{-1} A^\top b = A^+ b,$$

donde $A^+ = (A^\top A)^{-1} A^\top$ es la pseudoinversa de A, que en el caso de rango columna completo coincide con la inversa por izquierda (ver las notas de pseudoinversa). El residuo mínimo alcanzado es:

$$r_{\min} = b - Ax^* = b - b_A = b_\perp, \qquad \min_x \|Ax - b\|^2 = \|b_\perp\|^2.$$

Verificación

Para confirmar que x^* con $Ax^* = b_A$ es un mínimo, tomemos cualquier perturbación $x^* + e$ y calculemos su costo:

$$\|A(x^* + e) - b\|^2 = \|Ax^* + Ae - b\|^2 = \|b_\perp + Ae\|^2 = \|b_\perp\|^2 + 2\langle b_\perp, Ae\rangle + \|Ae\|^2.$$

El término cruzado $\langle b_\perp, Ae\rangle = 0$ porque $Ae \in \operatorname{span}(A)$ y $b_\perp \in \operatorname{Ker}(A^\top)$ son ortogonales. El término $\|Ae\|^2 \geq 0$. Por lo tanto, para cualquier $e \neq 0$:

$$\|A(x^* + e) - b\|^2 = \|b_\perp\|^2 + \|Ae\|^2 \geq \|b_\perp\|^2 = \|Ax^* - b\|^2,$$

con igualdad solo si $Ae = 0$. Cuando A es de rango columna completo, $Ae = 0$ implica $e = 0$, así que el mínimo es estricto y x^* es único.

Ejemplo 3.1: $b \notin \operatorname{span}(A)$ — solución aproximada

Consideramos el sistema $Ax = b$ con

$$A = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}, \qquad b = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

En este caso, $b \notin \operatorname{span}(A)$ porque b no es combinación lineal de las columnas de A. El sistema no tiene solución exacta. Si buscamos resolver en su lugar el problema de mínimos cuadrados, la solución es $x^* = A^+ b$ y el residuo es $r = b - Ax^*$, donde la pseudoinversa de A es

$$A^+ = \frac{1}{12}\begin{bmatrix} 5 & 2 & -1 \\ -1 & 2 & 5 \end{bmatrix}.$$

La solución de mínimos cuadrados es

$$x^* = A^+ b = \frac{1}{12}\begin{bmatrix} 5 & 2 & -1 \\ -1 & 2 & 5 \end{bmatrix}\begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} = \frac{1}{12}\begin{bmatrix} 5+4-2 \\ -1+4+10 \end{bmatrix} = \frac{1}{12}\begin{bmatrix} 7 \\ 13 \end{bmatrix}.$$

El residuo es

$$r = b - Ax^* = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} - \frac{1}{6}\begin{bmatrix} 7 \\ 10 \\ 13 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix}.$$

Verificamos que el residuo es ortogonal a las columnas de A:

$$A^\top r = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & 2 \end{bmatrix} \frac{1}{6}\begin{bmatrix} -1 \\ 2 \\ -1 \end{bmatrix} = \frac{1}{6}\begin{bmatrix} -2+2+0 \\ 0+2-2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}. \quad \checkmark$$

El costo mínimo es $\|r\|^2 = \frac{1}{36}(1+4+1) = \frac{1}{6}$.

Podemos verificar también que se satisface la ecuación normal. Con $A^\top A = \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix}$ y $A^\top b = \begin{bmatrix} 4 \\ 6 \end{bmatrix}$:

$$A^\top A x^* = \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix} \frac{1}{12} \begin{bmatrix} 7 \\ 13 \end{bmatrix} = \frac{1}{12} \begin{bmatrix} 48 \\ 72 \end{bmatrix} = \begin{bmatrix} 4 \\ 6 \end{bmatrix} = A^\top b. \quad \checkmark$$

Y también que si consideramos vectores x ligeramente perturbados respecto a x^*, el costo aumenta. Por la fórmula de la sección 3.1, para cualquier $e \neq 0$: $\|A(x^* + e) - b\|^2 = \|b_\perp\|^2 + \|Ae\|^2$. Por ejemplo, con $e = [0.1,\ -0.1]^\top$:

$$Ae = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0.1 \\ -0.1 \end{bmatrix} = \begin{bmatrix} 0.2 \\ 0 \\ -0.2 \end{bmatrix}, \qquad \|Ae\|^2 = 0.08,$$

$$\|A(x^* + e) - b\|^2 = \tfrac{1}{6} + 0.08 \approx 0.247 > \tfrac{1}{6} = \|Ax^* - b\|^2. \quad \checkmark$$

Ejemplo 3.2: $b \in \operatorname{span}(A)$ — solución exacta

Con la misma A y $b = [2, 2, 2]^\top$, el vector b está en el espacio columna de A (podemos verificar que $b = 1 \cdot a_1 + 1 \cdot a_2$, con a_1, a_2 las columnas de A). Aunque en este caso sí existe una solución exacta $Ax = b$, igualmente podemos tratar el problema como un problema de mínimos cuadrados, y obtener la misma solución que obtendríamos si aplicamos los mecanismos de resolución de problemas compatibles determinados.

La solución de mínimos cuadrados es:

$$x^* = A^+ b = \frac{1}{12} \begin{bmatrix} 5 & 2 & -1 \\ -1 & 2 & 5 \end{bmatrix} \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = \frac{1}{12} \begin{bmatrix} 12 \\ 12 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Verificamos que es solución exacta: $Ax^* = [2, 2, 2]^\top = b$. El residuo es cero y el costo mínimo es 0.

Esto ilustra que la formulación de mínimos cuadrados cubre también el caso con solución exacta: cuando $b \in \operatorname{span}(A)$, el mínimo es cero y se alcanza.

3.2 Cálculo de la solución

Existen tres caminos para calcular la solución de mínimos cuadrados.

Camino 1 — Ecuaciones normales. Resolver el sistema compatible determinado $A^\top A x = A^\top b$. Como $A^\top A$ es simétrica definida positiva (cuando A tiene rango columna completo), puede usarse la factorización de Cholesky. Este enfoque es eficiente cuando $A^\top A$ ya está disponible o cuando $n \ll m$.

Camino 2 — Pseudoinversa. Calcular $x^* = A^+ b$. En el caso de rango columna completo, $A^+ = (A^\top A)^{-1} A^\top$, que es numéricamente la misma que la ecuación normal. También podemos usar el cálculo de la pseudoinversa mediante la SVD (ver las notas de pseudoinversa). Este camino tiene la ventaja de que cuando A no tiene rango columna completo, la pseudoinversa sigue bien definida (ver la última sección).

Camino 3 — Factorización QR. Si $A = QR$ con $Q \in \mathbb{R}^{m \times n}$ de columnas ortonormales y $R \in \mathbb{R}^{n \times n}$ triangular superior (factorización QR delgada o reducida), la ecuación normal se simplifica:

$$A^\top A = R^\top Q^\top Q R = R^\top R, \qquad A^\top b = R^\top Q^\top b,$$

de donde $R^\top R x^* = R^\top Q^\top b$, es decir, $R x^* = Q^\top b$, que es la misma expresión que se obtiene mediante QR en sistemas compatibles determinados. Esto se resuelve por sustitución hacia atrás. Esta vía es numéricamente preferible cuando A está mal condicionada.

Cuando la solución se calcula formando explícitamente $A^\top A$ — como en las ecuaciones normales (Camino 1), o en el Camino 2 si se implementa vía la fórmula $(A^\top A)^{-1}A^\top$ — el número de condición se eleva al cuadrado: $\kappa_2(A^\top A) = \kappa_2(A)^2$. Para matrices bien condicionadas esto no supone problema, pero si A está mal condicionada, conviene usar el Camino 3 (QR) o el Camino 2 vía SVD, que trabajan directamente con A y evitan ese cuadrado del condicionamiento.

Camino	Costo aproximado	Estabilidad	Recomendado para
Ecuaciones normales (Cholesky)	$\sim mn^2 + \frac{1}{3}n^3$	Moderada (κ^2)	$m \gg n$, A bien condicionada
Pseudoinversa vía SVD	$\sim 2mn^2$	Mejor posible	A casi singular o de rango deficiente
Factorización QR	$\sim 2mn^2$	Muy buena (κ)	Uso general

En numpy la solución de mínimos cuadrados se calcula con `np.linalg.lstsq(A, b)` que usa por defecto la SVD (vía `gelsd` de LAPACK). Para sistemas bien condicionados a gran escala, las ecuaciones normales con Cholesky son más rápidas.

3.3 Regresión lineal

Un caso donde los sistemas sobredeterminados aparecen de forma natural es cuando queremos ajustar una curva a un conjunto de datos.

3.3.1 Mejor recta por un conjunto de puntos

Dados m puntos en el plano $(x_1, y_1), \ldots, (x_m, y_m)$, queremos encontrar la recta $y = cx + d$ que mejor los aproxima.

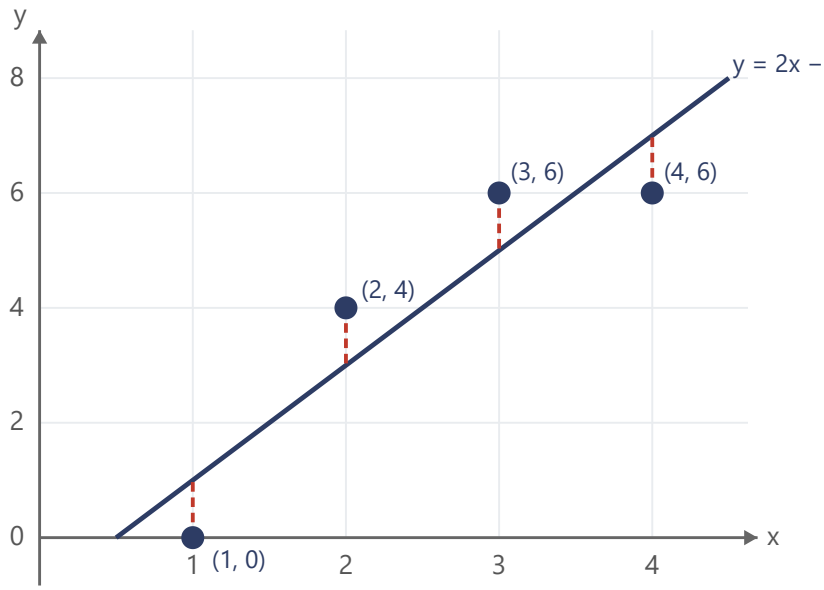

Los cuatro puntos del Ejemplo 3.3, la recta y = 2x − 1 y los errores verticales $y_i - (cx_i + d)$ (líneas rojas).

Si los puntos fueran colineales y eligiéramos la recta exacta, tendríamos el sistema $Ax = b$ donde

$$A = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_m & 1 \end{bmatrix}, \quad x = \begin{bmatrix} c \\ d \end{bmatrix}, \quad b = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}.$$

En general los puntos no son colineales, así que resolvemos el problema de mínimos cuadrados. Siempre que haya al menos dos valores de x_i distintos, A tiene rango columna completo y la solución de mínimos cuadrados es única. Su costo es:

$$\|Ax^* - b\|^2 = \sum_{i=1}^{m} (cx_i + d - y_i)^2,$$

la suma de los cuadrados de las distancias **verticales** entre los puntos y la recta. El término "mínimos cuadrados" viene exactamente de aquí.

La solución puede calcularse eficientemente mediante las ecuaciones normales $A^\top Ax^* = A^\top b$. Dado que A tiene solo 2 columnas, $A^\top A$ es 2×2 y el sistema es trivial de resolver:

$$A^\top A = \begin{bmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & m \end{bmatrix}, \qquad A^\top b = \begin{bmatrix} \sum x_i y_i \\ \sum y_i \end{bmatrix}.$$

Ejemplo 3.3: puntos no colineales

Consideramos los puntos $(1,0), (2,4), (3,6), (4,6)$, que no son colineales.

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 4 \\ 6 \\ 6 \end{bmatrix}.$$

$$A^\top A = \begin{bmatrix} 30 & 10 \\ 10 & 4 \end{bmatrix}, \quad (A^\top A)^{-1} = \frac{1}{20} \begin{bmatrix} 4 & -10 \\ -10 & 30 \end{bmatrix}, \quad A^\top b = \begin{bmatrix} 50 \\ 16 \end{bmatrix}.$$

$$x^* = (A^\top A)^{-1} A^\top b = \frac{1}{20} \begin{bmatrix} 4 & -10 \\ -10 & 30 \end{bmatrix} \begin{bmatrix} 50 \\ 16 \end{bmatrix} = \frac{1}{20} \begin{bmatrix} 40 \\ -20 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

La recta es $y = 2x - 1$. Como los puntos no son colineales, el residuo no es cero:

$$\|Ax^* - b\|^2 = (2 \cdot 1 - 1 - 0)^2 + (2 \cdot 2 - 1 - 4)^2 + (2 \cdot 3 - 1 - 6)^2 + (2 \cdot 4 - 1 - 6)^2 = 1 + 1 + 1 + 1 = 4.$$

Ejemplo 3.4: puntos colineales

Consideramos los puntos $(1,1), (2,3), (3,5), (4,7)$. La matriz A es la misma que antes; solo cambia $b = [1,3,5,7]^\top$.

$$A^\top b = \begin{bmatrix} 1 + 6 + 15 + 28 \\ 1 + 3 + 5 + 7 \end{bmatrix} = \begin{bmatrix} 50 \\ 16 \end{bmatrix}.$$

El sistema de ecuaciones normales tiene los mismos $A^\top A$ y $A^\top b$ que el ejemplo anterior, así que la solución es también $x^* = [2, -1]^\top$ y la recta es $y = 2x - 1$. Como los puntos son colineales, el residuo es cero: la solución de mínimos cuadrados es exacta. Esto ilustra que el método de mínimos cuadrados encuentra la solución exacta cuando los datos se ajustan perfectamente al modelo.

En el Ejemplo 3.3 elegimos minimizar el error $y - (cx + d)$, es decir, las distancias verticales entre los puntos y la recta, que es una elección natural al parametrizar la recta como $y = cx + d$. Pero podríamos igualmente haber parametrizado la recta como $x = ey + f$ (predecir x dado y) y minimizar las distancias horizontales $x - (ey + f)$.

La recta que minimiza esta nueva cantidad también es una "mejor" recta, pero en general no coincide con la del Ejemplo 3.3: cada una minimiza una cantidad distinta. Cuando los puntos son colineales, ambas parametrizaciones dan la misma recta — la única que los contiene. A continuación se muestra el cálculo para esta parametrización alternativa.

Ejemplo 3.5: parametrización alternativa

Con los mismos puntos $(1,0),(2,4),(3,6),(4,6)$, escribimos $x = ey + f$. Ahora A tiene columnas $[y_i, 1]$ y b tiene coordenadas x_i:

$$A = \begin{bmatrix} 0 & 1 \\ 4 & 1 \\ 6 & 1 \\ 6 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}.$$

$$A^\top A = \begin{bmatrix} 88 & 16 \\ 16 & 4 \end{bmatrix}, \quad (A^\top A)^{-1} = \frac{1}{24}\begin{bmatrix} 1 & -4 \\ -4 & 22 \end{bmatrix}, \quad A^\top b = \begin{bmatrix} 50 \\ 10 \end{bmatrix}.$$

$$x^* = \frac{1}{24}\begin{bmatrix} 1 & -4 \\ -4 & 22 \end{bmatrix}\begin{bmatrix} 50 \\ 10 \end{bmatrix} = \frac{1}{24}\begin{bmatrix} 10 \\ 20 \end{bmatrix} = \begin{bmatrix} 5/12 \\ 5/6 \end{bmatrix}.$$

La recta es $x = \frac{5}{12}y + \frac{5}{6}$, que equivale a $y = \frac{12}{5}x - 2$.

Notar que esta **no es la misma recta** que la del Ejemplo 3.3 ($y = 2x - 1$): los puntos no son colineales y las dos rectas minimizan cantidades distintas.

Existe una tercera opción: la recta que minimiza las distancias ortogonales de los puntos a la recta. Esa solución es la que obtenemos proyectando los datos mediante la primera componente principal (PCA).

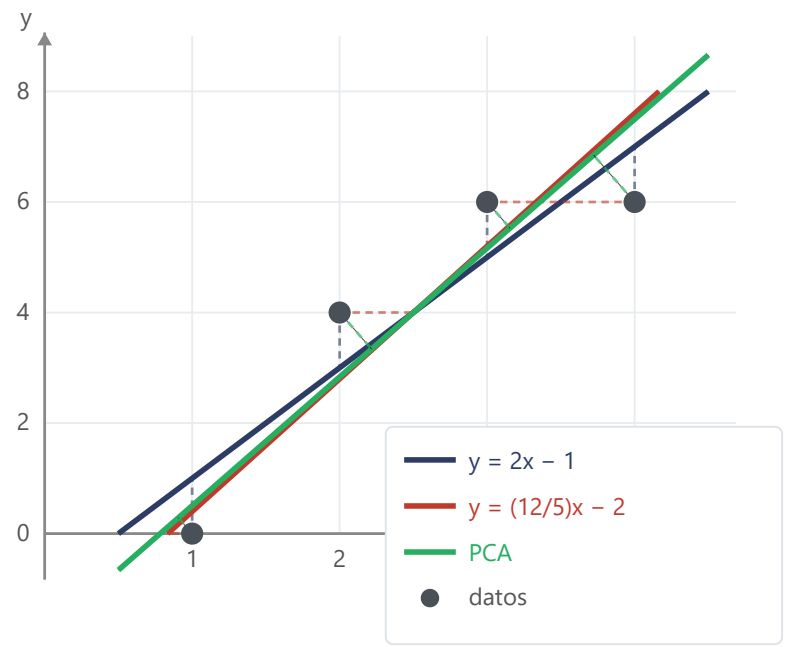

*Los cuatro puntos del Ejemplo 3.3 y tres nociones de "mejor" recta: mínimo error vertical y − ŷ (**azul**), mínimo error horizontal x − x̂ (**rojo**), y mínima distancia ortogonal / PCA (**verde**).*

La elección entre estas tres formulaciones depende del problema. Si x es la variable que medimos con precisión y y es la que estimamos (o viceversa), la parametrización adecuada es la que pone el error en la dirección de la variable incierta o dependiente. Cuando hay ruido en ambas variables y no hay razón para privilegiar una dirección, la distancia ortogonal (PCA) suele ser la más apropiada. En cualquier caso, la elección de la métrica de error es una decisión de diseño que debe ser informada por el contexto del problema, y no se desprende del modelo matemático.

3.3.2 Regresión en dimensión mayor

La misma idea de hallar la mejor recta por un conjunto de puntos se extiende sin modificaciones a más dimensiones: podemos buscar el mejor plano o espacio que se ajusta a un conjunto de puntos. La formulación de

este problema es la siguiente: dados m puntos en $\mathbb{R}^n$ de la forma $(x_{i1}, \ldots, x_{i,n-1}, y_i)$, buscamos el hiperplano $y = c_1 x_1 + \cdots + c_{n-1} x_{n-1} + d$ que mejor los aproxima. La matriz A tiene columnas $[x_{i1}, \ldots, x_{i,n-1}, 1]^\top$ para cada punto, y la solución de mínimos cuadrados da los coeficientes del hiperplano que minimiza la suma de cuadrados de las distancias en la dirección de y.

3.3.3 Regresión lineal generalizada: ajuste de curvas arbitrarias

La formulación se extiende también a funciones que no son lineales en x pero sí en los parámetros, por ejemplo podemos utilizarla para hallar el polinomio de grado p que mejor se ajusta a un conjunto de puntos $y = a_p x^p + \cdots + a_1 x + a_0$, o cualquier otro tipo de combinación lineal de funciones dadas.

Si queremos ajustar $y = \sum_{k=1}^{p} c_k f_k(x)$, donde $f_1, \ldots, f_p$ son funciones fijas (dadas) de x (senos, cosenos, potencias, etc.), y definimos nuestra métrica o error de ajuste como la suma de los cuadrados de las distancias verticales entre los puntos y la curva,

$$\sum_{i=1}^{m} \left(y_i - \sum_{k=1}^{p} c_k f_k(x_i) \right)^2,$$

podemos ver que esta función es equivalente a $\|Ac - y\|^2$ con la siguiente matriz A y vector y:

$$A = \begin{bmatrix} f_1(x_1) & \cdots & f_p(x_1) \\ \vdots & & \vdots \\ f_1(x_m) & \cdots & f_p(x_m) \end{bmatrix}, \qquad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}.$$

El problema se reduce entonces a uno de mínimos cuadrados convencional, donde $c = [c_1, \ldots, c_p]^\top$ es el vector de parámetros desconocido y $\min_c \|Ac - y\|^2$ es el problema a resolver.

A continuación se muestran dos ejemplos de este tipo de regresión lineal generalizada, con funciones base logarítmicas y cuadráticas respectivamente.

Ejemplo 3.6: mejor parábola

Retomamos los puntos del Ejemplo 3.3: $(1,0), (2,4), (3,6), (4,6)$. En lugar de una recta, ahora queremos ajustar una parábola $y = ax^2 + bx + c$. La formulación de este problema mediante regresión lineal generalizada implica notar que las incógnitas son los coeficientes a, b, y c, y las funciones base son $f_1(x) = x^2$, $f_2(x) = x$, $f_3(x) = 1$. De esta forma obtenemos la siguiente formulación en términos de un sistema sobredeterminado de la forma $Ac = y$:

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 4 & 2 & 1 \\ 9 & 3 & 1 \\ 16 & 4 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 0 \\ 4 \\ 6 \\ 6 \end{bmatrix}.$$

Podemos resolver el sistema mediante las ecuaciones normales $A^\top A\, c = A^\top y$:

$$\begin{bmatrix} 354 & 100 & 30 \\ 100 & 30 & 10 \\ 30 & 10 & 4 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 166 \\ 50 \\ 16 \end{bmatrix}.$$

Resolviendo el sistema (por ejemplo, por eliminación) obtenemos $a = -1$, $b = 7$, $c = -6$.

En este caso la parábola $y = -x^2 + 7x - 6$ pasa exactamente por los cuatro puntos (como puede verificarse sustituyendo), así que el residuo es cero. Los puntos, aunque no colineales, sí son "coparabólicos", lo que ilustra que un sistema sobredeterminado puede tener solución exacta si los datos satisfacen el modelo propuesto.

Ejemplo 3.7: mejor curva logarítmica

La misma idea puede utilizarse para ajustar otro tipos de curva, como por ejemplo una curva logarítmica $y = a\ln(x) + b$. En este caso las funciones base son $f_1(x) = \ln(x)$ y $f_2(x) = 1$, y la formulación es:

$$A = \begin{bmatrix} 0 & 1 \\ \ln(2) & 1 \\ \ln(3) & 1 \\ \ln(4) & 1 \end{bmatrix} \approx \begin{bmatrix} 0 & 1 \\ 0.693 & 1 \\ 1.099 & 1 \\ 1.386 & 1 \end{bmatrix}, \quad y = \begin{bmatrix} 0 \\ 4 \\ 6 \\ 6 \end{bmatrix}.$$

Resolviendo el sistema de ecuaciones normales $A^\top Ac = A^\top y$ obtenemos $a \approx 4.58$ y $b \approx 0.36$, así que la curva logarítmica que mejor se ajusta a los datos es $y \approx 4.58\ln(x) + 0.36$. En este caso el residuo no es cero.

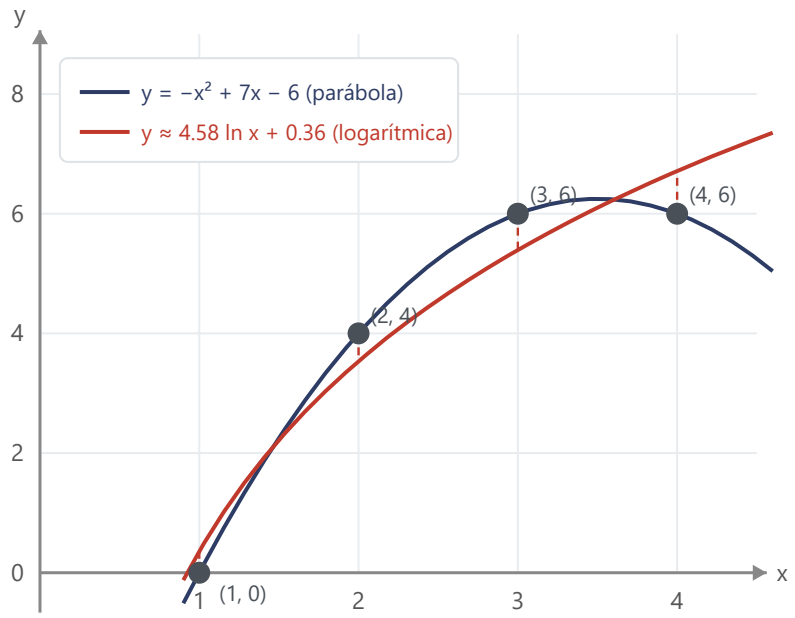

*Los cuatro puntos de los Ejemplos 3.6 y 3.7, la parábola y = −x² + 7x − 6 (**azul**) y la curva logarítmica y ≈ 4.58 ln x + 0.36 (**rojo**) con sus respectivos errores verticales.*

3.4 Otras normas

En esta sección vimos una forma de concebir la resolución de sistemas sobredeterminados $Ax = b$ que no tienen solución exacta, mediante la reconceptualización como un problema de "la mejor solución posible" en el sentido de minimizar la norma-2 del residuo $Ax - b$.

La elección de la norma-2 es arbitraria y no necesariamente es la mejor opción en todos los casos. Entre muchas otras opciones, podría plantearse el problema mediante otras normas, como:

- $\min_x \|Ax - b\|_1$ (suma de valores absolutos de los residuos): esta formulación es más robusta ante observaciones atípicas (*outliers*), pero no es posible despejar la solución de forma analítica y requiere del uso de métodos numéricos para su solución.
- $\min_x \|Ax - b\|_\infty$ (minimizar el máximo elemento del residuo): útil cuando se quiere limitar el error peor caso; también requiere métodos de resolución numérica.

Ambas formulaciones tienen usos importantes en ciencia de datos y procesamiento de señales, pero su resolución queda fuera del alcance de estas notas. La norma-2 suele ser elegida por su conveniencia analítica cuando no hay una razón clara para optar por otra métrica de error.

4. Sistemas subdeterminados: solución de norma mínima

En la sección anterior estudiamos el caso de un sistema $Ax = b$ con más ecuaciones que incógnitas ($m > n$), que en general no tiene solución exacta. En esta sección analizamos el caso opuesto, cuando hay más incógnitas que ecuaciones ($n > m$). A este sistema se lo conoce como un sistema subdeterminado, porque las ecuaciones disponibles no son suficientes para determinar una solución única.

En general este tipo de sistemas es compatible (tiene solución) pero no determinado (tiene infinitas soluciones). Las preguntas que nos hacemos son dos: ¿cómo hallamos el conjunto de todas las soluciones? y ¿existe algún criterio para elegir una solución particular entre todas las posibles?

4.1 Estructura del conjunto de soluciones

Supongamos que tenemos un sistema $Ax = b$ con $A \in \mathbb{R}^{m\times n}$, $b \in \mathbb{R}^m$, y $n > m$ (más incógnitas que ecuaciones). Veremos a continuación que si el sistema tiene alguna solución, entonces tiene infinitas soluciones, específicamente un espacio afín (una traslación de un subespacio lineal, que en general no pasa por el origen) de dimensión $n - m > 0$.

Para ilustrar esto, supongamos que x_p es una solución del sistema ($Ax_p = b$) y v es un vector cualquiera en el núcleo de A ($v \in \mathrm{Ker}(A)$, notar que $\dim(\mathrm{Ker}(A)) = n - m > 0$ en este caso: el núcleo no es trivial). Consideremos entonces el vector $x = x_p + v$. Entonces:

$$Ax = A(x_p + v) = Ax_p + Av = b + 0 = b$$

así que $x = x_p + v$ es también solución del sistema. Dado que v es cualquier vector en un subespacio de dimensión $n - m > 0$, hay infinitas soluciones: el conjunto de soluciones es el espacio afín

$$\{x_p + v : v \in \mathrm{Ker}(A)\}.$$

> *Para un sistema subdeterminado, si existe una solución existen infinitas soluciones.*

La existencia de soluciones dependerá, igual que en todos los sistemas lineales, de que $b \in \mathrm{span}(A)$. Una condición suficiente para esto es que A tenga rango fila completo ($r = m$), lo que implica que $\mathrm{span}(A) = \mathbb{R}^m$. En este caso, todos los vectores $b \in \mathbb{R}^m$ satisfacen la condición, y el sistema es por tanto compatible. En esta sección asumiremos que A tiene rango fila completo, aunque el análisis se puede extender a casos de rango deficiente, que se estudian en la sección 5 de este documento.

4.1.1 Solución particular

En lo anterior mostramos que si existe una solución, existen infinitas soluciones, pero no dimos ninguna forma de encontrar una solución particular x_p.

Asumiendo que A tiene rango fila completo, y por tanto el sistema es compatible, una forma de encontrar una solución particular x_p es elegir m columnas linealmente independientes de A (de las n columnas disponibles), e ignorar las demás $n - m$ columnas. Esto es equivalente a asumir que hay $n - m$ variables que toman el valor 0, y por tanto solo debemos determinar el valor de las otras m variables.

El procedimiento anterior da lugar a un sistema cuadrado de m ecuaciones con m incógnitas. Dado que las columnas elegidas son linealmente independientes, el sistema cuadrado es compatible determinado, y se puede resolver por cualquier método de los enumerados en la sección 2. El resultado es una solución particular x_p del

sistema original. Debe notarse que esta solución es válida pero no es especial en ningún sentido; dependiendo de qué columnas se elijan, se obtienen soluciones distintas, todas igualmente válidas.

Ejemplo 4.1

Consideramos el sistema subdeterminado $Ax = b$ con

$$A = \begin{bmatrix} 3 & 4 \end{bmatrix}, \quad b = \begin{bmatrix} 5 \end{bmatrix}.$$

Aquí $n = 2$, $m = 1$, rango fila completo. El sistema $3x_1 + 4x_2 = 5$ tiene infinitas soluciones; el núcleo de A tiene dimensión $n - m = 1$ y está generado por $v = (-4, 3)^\top$ (se verifica: $Av = 3(-4) + 4(3) = 0$).

Para encontrar dos soluciones particulares imponemos una incógnita igual a cero:

- Fijando $x_1 = 0$: $4x_2 = 5 \to x^{(1)} = (0, \frac{5}{4})^\top$.
- Fijando $x_2 = 0$: $3x_1 = 5 \to x^{(2)} = (\frac{5}{3}, 0)^\top$.

El conjunto de todas las soluciones es el espacio afín (una recta en $\mathbb{R}^2$):

$$\{x^{(1)} + t\,v : t \in \mathbb{R}\} = \{(0, \tfrac{5}{4})^\top + t\,(-4, 3)^\top : t \in \mathbb{R}\}$$

Este conjunto puede visualizarse directamente en el plano $\mathbb{R}^2$ como la recta $3x_1 + 4x_2 = 5$ (véase la figura en la sección 4.2).

Ejemplo 4.2

Consideramos el sistema subdeterminado

$$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Aquí $n = 4$, $m = 2$, rango fila completo. El núcleo tiene dimensión $n - m = 2$, generado por $v_1 = (1, -1, 0, 0)^\top$ y $v_2 = (0, 0, 1, -1)^\top$ (se verifica: $Av_1 = 0$ y $Av_2 = 0$).

Para obtener soluciones particulares, fijamos $n - m = 2$ incógnitas en cero simultáneamente, eligiendo una de cada ecuación para que el sistema reducido sea 2×2 determinado:

- Fijando $x_2 = 0, x_4 = 0$: $x_1 = 1, x_3 = 1 \to x^{(1)} = (1, 0, 1, 0)^\top$.
- Fijando $x_1 = 0, x_3 = 0$: $x_2 = 1, x_4 = 1 \to x^{(2)} = (0, 1, 0, 1)^\top$.
- Fijando $x_1 = 0, x_4 = 0$: $x_2 = 1, x_3 = 1 \to x^{(3)} = (0, 1, 1, 0)^\top$.

El conjunto de todas las soluciones es el espacio afín bidimensional en $\mathbb{R}^4$:

$$\{x^{(1)} + \alpha\,v_1 + \beta\,v_2 : \alpha, \beta \in \mathbb{R}\} = \{(1 + \alpha,\ -\alpha,\ 1 + \beta,\ -\beta)^\top : \alpha, \beta \in \mathbb{R}\}.$$

Este conjunto no puede visualizarse geométricamente (está en $\mathbb{R}^4$), pero la estructura algebraica es la misma que en el ejemplo anterior: un plano afín de dimensión 2 parametrizado por dos parámetros libres.

4.2 La solución de norma-2 mínima

La pregunta que surge del desarrollo anterior es: entre todas las soluciones, ¿existen peores o mejores soluciones? La respuesta depende de la aplicación y de qué entendemos por "peor" o "mejor" en el contexto específico. Sin embargo, una noción de "mejor" solución que es útil en muchos problemas subdeterminados es la solución más "pequeña" o de norma mínima. Es decir, entre todas las (infinitas) soluciones posibles, consideramos mejor aquella que tiene la menor norma de la solución $\|x\|$ o, lo que es lo mismo, la solución más cercana al origen.

Al igual que en la sección de mínimos cuadrados, la elección de una norma específica para medir el tamaño de la solución (x) es arbitraria, y la elección apropiada depende del contexto. En lo que sigue discutiremos la solución de norma-2 mínima, que es la más comúnmente utilizada.

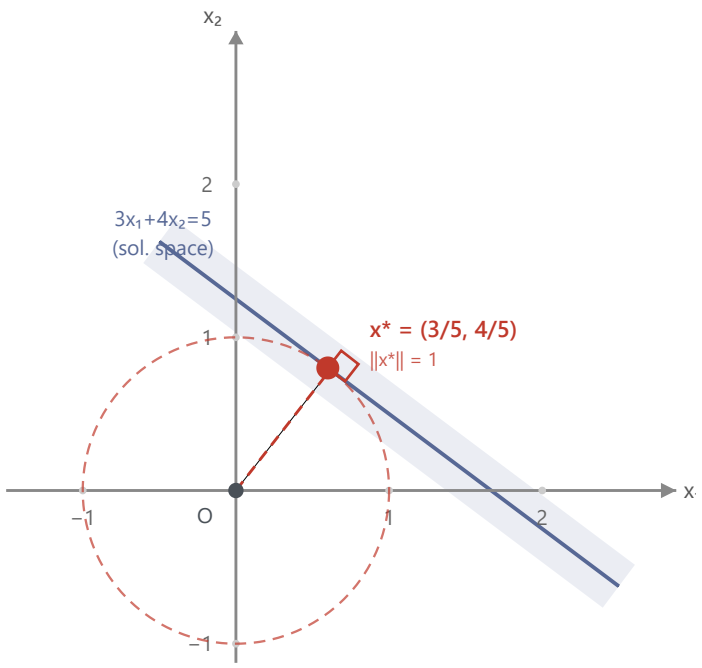

El conjunto de soluciones (recta) del sistema del Ejemplo 4.1. La solución de norma mínima (punto rojo) es el punto de la recta más cercano al origen; la circunferencia punteada indica su norma $\|x^*\|_2=1$.

Formalicemos la idea anterior. La solución de norma mínima es la solución x^* que satisface $Ax^* = b$ y que tiene $\|x^*\| \leq \|x\|$ para toda solución x del sistema. Al elegir la norma-2, esta solución se puede calcular de forma analítica, y dicha solución es única (es decir, no hay dos soluciones distintas con la misma norma mínima).

La intuición geométrica es: el conjunto de soluciones es un subespacio afín (una recta, un plano, etc.) que no pasa por el origen (en general). Todo subespacio afín tiene un punto más cercano al origen, y ese punto es el que buscamos. A continuación se detalla una forma de hallar dicho punto, que se basa en la descomposición ortogonal de x en dos componentes, una que pertenece al espacio fila de A y otra que pertenece al núcleo de A.

Consideremos cualquier vector $x \in \mathbb{R}^n$ que pertenezca al conjunto de soluciones, es decir, que satisfaga $Ax = b$. Dado que $\mathrm{span}(A^\top)$ y $\mathrm{Ker}(A)$ son subespacios ortogonales que generan todo el espacio $\mathbb{R}^n$, podemos escribir x como la suma de dos componentes ortogonales:

$$x = x_{\mathrm{row}} + x_{\mathrm{ker}}, \qquad x_{\mathrm{row}} \in \mathrm{span}(A^\top), \quad x_{\mathrm{ker}} \in \mathrm{Ker}(A).$$

Como $Ax_{\mathrm{ker}} = 0$, la componente x_{row} sola satisface la ecuación original: $Ax_{\mathrm{row}} = Ax - Ax_{\mathrm{ker}} = b$. Por tanto x_{row} es también una solución particular. Ahora, por el teorema de Pitágoras (los dos subespacios son ortogonales):

$$\|x\|^2 = \|x_{\mathrm{row}}\|^2 + \|x_{\mathrm{ker}}\|^2 \geq \|x_{\mathrm{row}}\|^2,$$

con igualdad si y solo si $x_{\mathrm{ker}} = 0$. Por tanto, toda solución tiene norma al menos $\|x_{\mathrm{row}}\|$, con igualdad exactamente cuando la solución pertenece a $\mathrm{span}(A^\top)$. La solución de norma mínima es $x^* = x_{\mathrm{row}}$: la única solución en $\mathrm{span}(A^\top)$.

Dado que dicha solución pertenece a $\mathrm{span}(A^\top)$, podemos definir un vector auxiliar $y \in \mathbb{R}^m$ tal que $x^* = A^\top y$. Sustituyendo esta expresión en la ecuación $Ax^* = b$ obtenemos:

$$AA^\top y = b \implies y = (AA^\top)^{-1} b \implies x^* = A^\top (AA^\top)^{-1} b.$$

Aquí $AA^\top \in \mathbb{R}^{m\times m}$ es invertible porque asumimos que A tiene rango fila completo. La expresión $A^+ = A^\top(AA^\top)^{-1}$ es la inversa de A por derecha, que coincide con la pseudoinversa de A en el caso de rango fila completo (ver las notas de pseudoinversa), así que:

$$x^* = A^\top(AA^\top)^{-1}b = A^+b.$$

Ejemplo 4.3: sistema subdeterminado con rango fila completo

Sea el sistema subdeterminado $Ax = b$ dado por:

$$A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Al ser A de rango fila completo, el sistema es compatible y tiene infinitas soluciones. Tres soluciones particulares se obtienen imponiendo $x_i = 0$ para cada i:

$$x^{(1)} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \text{ (fijando } x_1 = 0), \quad x^{(2)} = \begin{bmatrix} -1 \\ 0 \\ 2 \end{bmatrix} \text{ (fijando } x_2 = 0), \quad x^{(3)} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \text{ (fijando } x_3 = 0).$$

El núcleo de A está generado por $v = (-1, -1, 1)^\top$, así que el espacio afín de soluciones es:

$$x_{\text{sol}} = x^{(1)} + \alpha \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -\alpha \\ 1-\alpha \\ 1+\alpha \end{bmatrix}, \quad \alpha \in \mathbb{R}.$$

La solución de norma mínima pertenece a $\operatorname{span}(A^\top)$ y se calcula mediante la inversa por derecha:

$$AA^\top = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad (AA^\top)^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix},$$

$$A^+ = A^\top(AA^\top)^{-1} = \frac{1}{3}\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix},$$

$$x^* = A^+b = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} = x^{(1)}.$$

En este caso coincide con $x^{(1)}$ (la que fija $x_1 = 0$). Esto es una coincidencia; la solución de norma mínima no tiene por qué fijar ninguna componente en cero.

Verificamos que es efectivamente la de menor norma entre las tres soluciones particulares:

$$\|x^{(1)}\| = \sqrt{0+1+1} = \sqrt{2}, \quad \|x^{(2)}\| = \sqrt{1+0+4} = \sqrt{5}, \quad \|x^{(3)}\| = \sqrt{1+4+0} = \sqrt{5}.$$

$x^{(1)}$ tiene la norma más baja, $\sqrt{2} < \sqrt{5}$.

4.3 Otras nociones de "mejor" solución

La norma-2 mínima no es la única manera de seleccionar entre las infinitas soluciones. Dependiendo del contexto, otros criterios utilizados en la práctica son:

- La solución más **esparsa** (con más ceros): la solución de norma-1 mínima sujeta a $Ax = b$. Este criterio se usa en aplicaciones de *sparse recovery* o *compressed sensing*.
- Una solución que satisfaga restricciones adicionales sobre x (p.ej. que todas las componentes de x sean positivas).

- La solución que minimiza $\|Ax - b\|^2 + \lambda\|x\|^2$ para algún valor $\lambda > 0$ (criterio *regularizado*). Este criterio pondera el cumplimiento de $Ax = b$ vs. el tamaño de la solución que se obtiene. Para cualquier valor de $\lambda > 0$, la solución será distinta a la de norma-2 mínima, pero en el límite $\lambda \to 0^+$ esta solución converge a la de norma-2 mínima.

5. La pseudoinversa como solución unificada

Los tres casos de rango completo discutidos en las secciones 2–4 pueden resumirse de forma unificada: en todos ellos la solución es $x = A^+b$, donde A^+ es la pseudoinversa de Moore-Penrose.

El último caso que debemos considerar es el más general: una matriz de rango incompleto (deficiente) por filas y columnas ($r < m$ y $r < n$). En este caso la transformación lineal dada por A no es sobreyectiva ni inyectiva: pueden no existir soluciones exactas a un problema $Ax = b$ y aun si nos conformamos con minimizar $\|Ax - b\|_2$, hay infinitas soluciones igualmente buenas. Es decir, tenemos posiblemente una combinación de las últimas dos secciones.

Por lo desarrollado en las secciones anteriores, una forma de buscar una solución única a este problema es buscar primero todas las soluciones que minimizan $\|Ax - b\|_2$ (mínimos cuadrados), y entre las infinitas soluciones equivalentes quedarnos con la de menor norma del vector solución. Es decir:

$$x = \arg\min \|x\|_2, \quad \text{sujeto a } \|Ax - b\|_2 = \min_x \|Ax - b\|_2$$

Puede mostrarse que esto es equivalente a resolver:

$$x = \lim_{\lambda \to 0^+} \arg\min_x \|Ax - b\|_2^2 + \lambda\|x\|_2^2,$$

Por argumentos análogos a los dados en las secciones anteriores, la solución de este problema se puede hallar en dos pasos:

1. Hallar el subespacio afín de soluciones que minimizan $\|Ax - b\|_2$.
2. Dentro de ese subespacio afín, hallar la solución de norma mínima.

Para el primer paso, como fue visto en la sección de Mínimos Cuadrados, el residuo mínimo alcanzable es $\|b_\perp\|_2$, donde $b_\perp$ es la componente de b ortogonal a $\mathrm{span}(A)$, y los minimizadores son exactamente los vectores x que satisfacen la ecuación normal

$$A^\top Ax = A^\top b,$$

pero en este caso son infinitas soluciones (dimensión $n - r$) ya que $\mathrm{Ker}(A) \neq \{0\}$ y por tanto no es posible invertir la matriz $A^\top A$ para hallar una solución.

Para el segundo paso, la solución de norma mínima es la única solución que pertenece a $\mathrm{span}(A^\top)$. Por tanto, se satisface también la ecuación normal:

$$AA^\top y = b,$$

con y tal que $x = A^\top y$, pero tampoco es posible invertir $AA^\top$ para hallar una solución, ya que A no tiene rango fila completo.

Si bien no podemos despejar directamente las ecuaciones anteriores para hallar la solución, podemos verificar que el vector generado por la pseudo-inversa, $x^* = A^+b$, satisface ambas condiciones:

$$A^\top Ax^* = A^\top AA^+b = A^\top(AA^+)^\top b = A^\top(A^\top)^+A^\top b = A^\top b$$

donde el paso $(AA^+)^\top = (A^\top)^+ A^\top$ usa la propiedad $(A^+)^\top = (A^\top)^+$ y que AA^+ es simétrica (propiedad de Moore-Penrose, ver las notas de pseudoinversa).

A su vez $\mathrm{span}(A^\top) = \mathrm{span}((A^+)^\top)$, por construcción de la pseudoinversa, así que $x^* = A^+ b$ pertenece a $\mathrm{span}(A^\top)$ y es la solución de norma mínima entre las soluciones de mínimos cuadrados.

En resumen, la pseudoinversa resuelve también el problema combinado:

$$x = A^+ b = \arg \min_{\|Ax-b\|=\min} \|x\|_2.$$

Es decir: primero minimiza el residuo $\|Ax - b\|_2$, y entre todos los x que logran ese residuo mínimo, elige el de menor norma. Este problema tiene solución única para cualquier A y cualquier b.

Los casos de rango completo vistos en las secciones anteriores pueden verse como casos especiales de este problema general, cuando la pseudoinversa adopta formas particulares (inversa, inversa por derecha, inversa por izquierda) que permiten despejar la solución de forma analítica.

Para más detalles sobre la pseudoinversa (definición axiomática, cálculo vía SVD, verificación) ver las notas de pseudoinversa de Moore-Penrose.

Notar que en los cuatro problemas es cierto que $x = A^+ b$ es la solución, pero el tipo de solución que se obtiene debe interpretarse según el caso.

Tipo de A	Condición	Solución	Tipo de Solución	Relación con A^+
Cuadrada e invertible	$m = n = r$	$x = A^{-1} b$	Únicao vector que satisface $Ax = b$	$A^+ = A^{-1}$
Alta, rango col. completo	$m > n = r$	$x = (A^\top A)^{-1} A^\top b$	Única que minimiza $\|Ax - b\|_2$	$A^+ = (A^\top A)^{-1} A^\top$
Ancha, rango fila completo	$n > m = r$	$x = A^\top (AA^\top)^{-1} b$	Solución "más chica" (norma mínima) de Ax=b	$A^+ = A^\top (AA^\top)^{-1}$
Caso general	$r < \min(m, n)$	$x = A^+ b$	Solución de norma mínima entre las que minimizan $\|Ax - b\|_2$	$A^+ = V \Sigma^+ U^\top$ (SVD)