Matemática para Aprendizaje Automático

Notas de Clase — Descomposición en Valores Singulares (SVD)

Universidad Católica del Uruguay • 2026

> ***Referencias principales:*** *Deisenroth, Faisal & Ong, Mathematics for Machine Learning, secciones 4.5–4.6; Strang, Introduction to Linear Algebra, capítulo 7.* ***Referencias complementarias:*** *Aggarwal, Linear Algebra and Optimization for Machine Learning, capítulo 7; Strang, Linear Algebra and Learning from Data, secciones I.8–I.9; Trefethen & Bau, Numerical Linear Algebra, Lectures 4–5 y 31; Golub & Van Loan, Matrix Computations, secciones 2.4 y 8.6; Higham, Accuracy and Stability of Numerical Algorithms, capítulo 20.*

Contenidos

1. Introducción
2. La SVD
   - 2.1 Definición
   - 2.2 Interpretación geométrica
   - 2.3 Formas equivalentes
   - 2.4 Existencia y unicidad
   - 2.5 Relación con la descomposición espectral
3. Cálculo de la SVD
   - 3.1 Relación con la descomposición espectral de $A^\top A$ y $AA^\top$
   - 3.2 Algoritmo de cálculo a partir de la descomposición espectral
   - 3.3 Ejemplos de cálculo
   - 3.4 SVD reducida
   - 3.5 Comentarios sobre el cálculo numérico en la práctica
4. Propiedades y aplicaciones de la SVD
   - 4.1 Normas matriciales
   - 4.2 Número de condición
   - 4.3 SVD de la transpuesta
   - 4.4 SVD de la inversa
   - 4.5 Pseudoinversa (esquema)
   - 4.6 Aproximación de rango bajo: teorema de Eckart–Young
   - 4.7 Otras aplicaciones (referencias)

1. Introducción

Una de las descomposiciones matriciales con la que ya trabajamos en el curso es la diagonalización:

ParseError: KaTeX parse error: Can't use function '$' in math mode at position 15: A = P D P^{-1}$$ donde D es...

con Q ortogonal y Λ diagonal.

Esta descomposición es muy útil cuando existe, su uso es limitado: sólo se aplica a matrices cuadradas y que admitan una base de vectores propios, es decir, que tengan n vectores propios LI. En muchas aplicaciones, sin embargo, nos encontramos con matrices rectangulares (p. ej. datos organizados en filas y columnas) o con matrices cuadradas que no son diagonalizables.

La pregunta que surge naturalmente es: ¿podemos encontrar una descomposición similar a la diagonalización que se aplique a cualquier matriz, sin restricciones? Es decir, ¿es cierto que cualquier matriz puede concebirse como una transformación lineal que, bajo un cambio de base adecuado, se reduce a un simple escalado por ejes? La respuesta es sí, y a esta descomposición se la conoce como la **descomposición en valores singulares (SVD)**.

---

2. La Descomposición en Valores Singulares (SVD)

2.1 Definición

Para toda matriz $A \in \mathbb{R}^{m \times n}$ existe una factorización

$$A = U \Sigma V^\top$$

donde:

- $U \in \mathbb{R}^{m \times m}$ es ortogonal ($U^\top U = UU^\top = I_m$); sus columnas $u_1, \ldots, u_m$ se llaman **vectores singulares izquierdos**.
- $V \in \mathbb{R}^{n \times n}$ es ortogonal ($V^\top V = VV^\top = I_n$); sus columnas $v_1, \ldots, v_n$ se llaman **vectores singulares derechos**.
- $\Sigma \in \mathbb{R}^{m \times n}$ es diagonal con elementos diagonales no negativos. Es decir, tiene entradas $\sigma_{ij} = 0$ si $i \neq j$ y entradas diagonales no negativas ordenadas $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{\min(m,n)} \geq 0$, llamadas **valores singulares**.

Adicionalmente, si $r = \text{rango}(A)$, entonces $\sigma_1 \geq \cdots \geq \sigma_r > 0$ y $\sigma_{r+1} = \cdots = \sigma_{\min(m,n)} = 0$. La cantidad de valores singulares no nulos es exactamente el rango de A.

2.1.1 Observaciones sobre la estructura de la descomposición

Las matrices U y V son cuadradas y ortogonales, pero posiblemente de tamaños distintos ($m \times m$ y $n \times n$).

La matriz Σ es siempre del mismo tamaño que A ($m \times n$), y es "diagonal" en un sentido generalizado. Sus tres formas posibles son:

- Si $m = n$: Σ cuadrada diagonal.
- Si $m > n$ (matriz alta): Σ es diagonal en el bloque superior $n \times n$ y tiene $m - n$ filas de ceros debajo.
- Si $m < n$ (matriz ancha): Σ es diagonal en el bloque izquierdo $m \times m$ y tiene $n - m$ columnas de ceros a la derecha.

$$\underbrace{\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix}}_{m=n}, \quad \underbrace{\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \\ 0 & \cdots & 0 \\ \vdots & & \vdots \end{bmatrix}}_{m>n}, \quad \underbrace{\begin{bmatrix} \sigma_1 & & & 0 & \cdots \\ & \ddots & & \vdots & \\ & & \sigma_m & 0 & \cdots \end{bmatrix}}_{m<n}.$$

2.1.2 Un ejemplo

Antes de calcular nada, mostremos la SVD ya construida de una matriz pequeña, para ver cómo se ven los factores. Sea

$$A = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}.$$

Su SVD es:

$$A = U\Sigma V^\top = \underbrace{\begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & 0 & \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} \sqrt{6} & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}}_{V^\top}.$$

Sin hacer la cuenta del producto, podemos verificar que la estructura es consistente con la definición:

(a) Ortogonalidad de U. Las tres columnas tienen norma 1 y son mutuamente ortogonales: por ejemplo $\langle u_1, u_2 \rangle = \frac{1}{\sqrt{6}}(1 - 0 - 1) = 0$. Luego $U^\top U = I_3$.

(b) Ortogonalidad de V. Las dos columnas son $\frac{1}{\sqrt{2}}[1, 1]^\top$ y $\frac{1}{\sqrt{2}}[1, -1]^\top$: ortonormales. Luego $V^\top V = I_2$.

(c) Valores singulares ordenados y no negativos: $\sigma_1 = \sqrt{6} \approx 2.449 > \sigma_2 = 2 > 0$.

Podemos también verificar el producto $A = U\Sigma V^\top$ mediante el cálculo completo.

2.2 Interpretación geométrica

La factorización $A = U\Sigma V^\top$ descompone la transformación $x \mapsto Ax$ en tres pasos sucesivos:

1. $V^\top$: rotación/reflexión en el dominio $\mathbb{R}^n$ (cambia a la base $\{v_1, \ldots, v_n\}$).
2. Σ: escalado independiente a lo largo de cada eje coordenado en la nueva base, por los factores $\sigma_1, \ldots, \sigma_{\min(m,n)}$ (más, si $m \neq n$, una proyección o inclusión canónica que elimina o agrega coordenadas).

3. U: rotación/reflexión en el codominio $\mathbb{R}^m$ (cambia a la base $\{u_1, \ldots, u_m\}$).

Es decir, *toda transformación lineal* es la composición de un cambio de base ortogonal, un escalado por ejes, y otra transformación ortogonal. A diferencia de la diagonalización, la SVD no encuentra una base única que diagonalice la transformación, sino que requiere **dos bases distintas**, una para el dominio y otra para el codominio, lo que le permite "diagonalizar" cualquier matriz, incluso las rectangulares o no simétricas.

Como consecuencia inmediata, A aplica la esfera unitaria de $\mathbb{R}^n$ sobre un (hiper)elipsoide en $\mathrm{Col}(A) \subseteq \mathbb{R}^m$, cuyos ejes principales tienen direcciones $u_1, \ldots, u_r$ y longitudes de semieje $\sigma_1, \ldots, \sigma_r$. Las direcciones v_i son las preimágenes de esos ejes: $Av_i = \sigma_i u_i$.

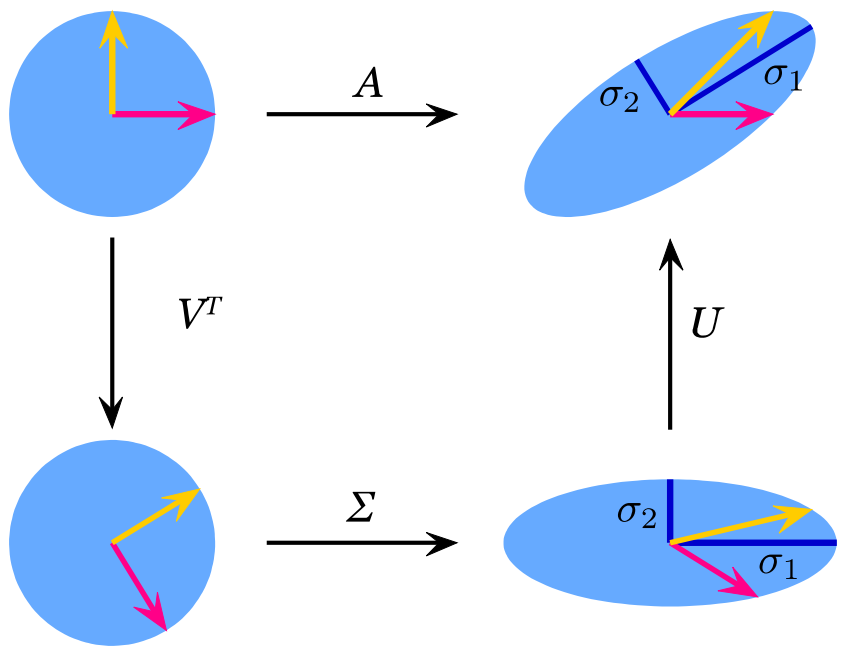

$$A = U \cdot \Sigma \cdot V^T$$

Fuente: Wikipedia.

2.3 Formas equivalentes

La SVD admite varias expresiones equivalentes:

1. **Forma matricial completa:** $A = U\Sigma V^\top$.
2. **Ecuaciones de valor singular:** $Av_i = \sigma_i u_i$ y $A^\top u_i = \sigma_i v_i$ para $i = 1, \ldots, \min(m, n)$.
3. **Suma de matrices de rango 1:** $A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top$, donde $r = \mathrm{rango}(A)$.
4. **SVD reducida (forma compacta):** $A = U_r \Sigma_r V_r^\top$, donde $U_r \in \mathbb{R}^{m \times r}$, $V_r \in \mathbb{R}^{n \times r}$ contienen sólo las primeras r columnas de U y V, y $\Sigma_r \in \mathbb{R}^{r \times r}$ es diagonal con los valores singulares no nulos.

Las cuatro formas son **equivalentes**: contienen la misma información sobre A. La forma 3 (suma de rangos 1) revela que la SVD descompone A como una suma de contribuciones individuales, una por cada valor singular no nulo, ordenadas por magnitud — esta visión motivará la aproximación de rango bajo de la sección 4.6. La forma reducida 4 será discutida con más detalle en la sección 3.4.

Ejemplo

Verificamos las tres formas equivalentes sobre el ejemplo de la sección 2.1.2, con

$$v_1 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix}, \quad v_2 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\end{bmatrix}, \quad u_1 = \tfrac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix}, \quad u_2 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}1\\0\\-1\end{bmatrix}, \quad \sigma_1 = \sqrt{6},\ \sigma_2 = 2.$$

Forma 2 ($Av_i = \sigma_i u_i$ y $A^\top u_i = \sigma_i v_i$):

$$Av_1 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}2\\2\\2\end{bmatrix} = \sqrt{2}\begin{bmatrix}1\\1\\1\end{bmatrix} = \sigma_1 u_1, \qquad Av_2 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}2\\0\\-2\end{bmatrix} = \sqrt{2}\begin{bmatrix}1\\0\\-1\end{bmatrix} = \sigma_2 u_2.$$

$$A^\top u_1 = \tfrac{1}{\sqrt{3}}\begin{bmatrix}3\\3\end{bmatrix} = \sqrt{3}\begin{bmatrix}1\\1\end{bmatrix} = \sigma_1 v_1, \qquad A^\top u_2 = \tfrac{1}{\sqrt{2}}\begin{bmatrix}2\\-2\end{bmatrix} = \sqrt{2}\begin{bmatrix}1\\-1\end{bmatrix} = \sigma_2 v_2.$$

Forma 3 (suma de matrices de rango 1):

$$\sigma_1 u_1 v_1^\top = \tfrac{\sqrt{6}}{\sqrt{3}\sqrt{2}}\begin{bmatrix}1\\1\\1\end{bmatrix}\begin{bmatrix}1 & 1\end{bmatrix} = \begin{bmatrix}1 & 1\\1 & 1\\1 & 1\end{bmatrix}, \qquad \sigma_2 u_2 v_2^\top = \tfrac{2}{\sqrt{2}\sqrt{2}}\begin{bmatrix}1\\0\\-1\end{bmatrix}\begin{bmatrix}1 & -1\end{bmatrix} = \begin{bmatrix}1 & -1\\0 & 0\\-1 & 1\end{bmatrix}.$$

$$\sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top = \begin{bmatrix}2 & 0\\1 & 1\\0 & 2\end{bmatrix} = A.$$

Notar que $u_3 = \frac{1}{\sqrt{6}}[-1, 2, -1]^\top$ no aparece en la suma final: contribuye a U pero su valor singular asociado es $\sigma_3 = 0$, así que la tercera fila de Σ lo "anula" al multiplicar. Esta observación motivará la **SVD reducida** de la sección 3.4: si sólo nos interesa reconstruir A, podemos descartar a u_3 y la fila de ceros de Σ.

2.4 Existencia y unicidad

- **Existencia:** la SVD existe para cualquier matriz real (o compleja).
- **Unicidad de los valores singulares:** los σ_i son únicos (pero pueden estar repetidos).
- **Unicidad de los vectores singulares:** si todos los σ_i son distintos y no nulos, los vectores singulares quedan determinados a menos de un signo global por par (u_i, v_i) (equivalente a la unicidad de vectores propios). Si hay σ_i repetidos o nulos, los subespacios singulares correspondientes son únicos pero no las bases dentro de ellos.

2.5 Relación con la descomposición espectral

El teorema espectral establece que toda matriz simétrica $A \in \mathbb{R}^{n\times n}$ admite una factorización ortogonal $A = Q\Lambda Q^\top$, con Q ortogonal y Λ diagonal. Esta descomposición impone dos restricciones sobre A: que sea cuadrada — de modo que dominio y codominio sean el mismo espacio $\mathbb{R}^n$ — y que sea simétrica, lo que garantiza la existencia de una única base ortonormal válida tanto para el dominio como para el codominio.

La SVD relaja ambas restricciones a la vez, a costa de admitir dos bases distintas. A puede ser rectangular ($m \times n$ con $m \neq n$), y no se exige simetría alguna: en su lugar se usan dos bases ortonormales

independientes, $\{v_1, \ldots, v_n\}$ en el dominio $\mathbb{R}^n$ y $\{u_1, \ldots, u_m\}$ en el codominio $\mathbb{R}^m$. El resultado es una descomposición del mismo tipo — dos factores ortogonales flanqueando una diagonal — ahora aplicable a cualquier matriz real: $A = U\Sigma V^\top$. Cada v_i se envía a $\sigma_i u_i$ sin exigir que "vuelva sobre sí mismo".

Caso simétrico. Cuando A es simétrica, las dos bases pueden tomarse iguales y la SVD coincide con la descomposición espectral, a menos de signos. Sea $A = Q\Lambda Q^\top$ con autovalores λ_i (posiblemente negativos) y sea $A = U\Sigma V^\top$ la SVD. Entonces $\sigma_i = |\lambda_i|$ y, columna a columna:

- si $\lambda_i \geq 0$: $u_i = v_i = q_i$;
- si $\lambda_i < 0$: $u_i = q_i$ y $v_i = -q_i$ (o viceversa) — el signo se absorbe en Σ para que sus entradas sean no negativas.

Para matrices no simétricas, la SVD se relaciona con la descomposición espectral de las matrices simétricas semidefinidas positivas $A^\top A$ y $AA^\top$. Esta relación fundamenta el algoritmo de cálculo y se desarrolla en la sección 3.1.

---

3. Cálculo de la SVD

3.1 Relación con la descomposición espectral de $A^\top A$ y $AA^\top$

A partir de $A = U\Sigma V^\top$, tenemos:

$$A^\top A = (U\Sigma V^\top)^\top (U\Sigma V^\top) = V\Sigma^\top U^\top U\Sigma V^\top = V(\Sigma^\top \Sigma)V^\top,$$
$$AA^\top = (U\Sigma V^\top)(U\Sigma V^\top)^\top = U\Sigma V^\top V\Sigma^\top U^\top = U(\Sigma\Sigma^\top)U^\top.$$

Las matrices $\Sigma^\top\Sigma \in \mathbb{R}^{n\times n}$ y $\Sigma\Sigma^\top \in \mathbb{R}^{m\times m}$ son ambas diagonales con entradas σ_i^2 (rellenando con ceros según corresponda).

Reconocemos en estas dos identidades la **descomposición espectral** de matrices simétricas semidefinidas positivas, ya estudiada en la unidad anterior. Entonces:

- los v_i son los **vectores propios de** $A^\top A$, con valores propios $\lambda_i = \sigma_i^2$;
- los u_i son los **vectores propios de** $AA^\top$, con los mismos valores propios no nulos σ_i^2;
- los **valores singulares** son las raíces cuadradas no negativas de esos valores propios: $\sigma_i = \sqrt{\lambda_i}$.

3.2 Algoritmo de cálculo a partir de la descomposición espectral

A partir de esa conexión, la siguiente receta permite calcular la SVD:

1. Calcular $A^\top A$ (o $AA^\top$) (**recomendación:** elegir la matriz más pequeña para ahorrar cómputo).
2. Diagonalizar la matriz simétrica del paso 1: obtener valores propios $\lambda_i \geq 0$ y una base **ortonormal** de vectores propios. Si un valor propio λ tiene multiplicidad > 1, cualquier base ortonormal del subespacio

propio correspondiente sirve.

3. Tomar $\sigma_i = \sqrt{\lambda_i}$, ordenar de mayor a menor.
4. Para los $\sigma_i \neq 0$, obtener el vector singular del otro lado mediante $u_i = \frac{1}{\sigma_i} A v_i$ (o $v_i = \frac{1}{\sigma_i} A^\top u_i$). Este paso **no** se puede aplicar cuando $\sigma_i = 0$, pues implicaría dividir por cero.
5. Completar los vectores singulares correspondientes a $\sigma_i = 0$. Hay dos caminos:
   - **Completar por Gram–Schmidt:** elegir vectores adicionales en el espacio de llegada (o salida) que sean ortonormales a los ya obtenidos en el paso 4. Esto es necesario cuando se trabaja con la matriz más pequeña, porque los vectores del lado más grande con $\sigma_i = 0$ no se recuperan por el paso 4.
   - **Diagonalizar la matriz mayor:** en lugar de la más pequeña, diagonalizar completamente la matriz simétrica del lado que tiene vectores "extra"; así todos salen directamente, sin Gram–Schmidt adicional (a costa de un sistema más grande).

> ***Nota:*** *Esta receta es útil para resolver ejercicios y entender la estructura, pero es ineficiente y numéricamente inestable como algoritmo general. Ver sección 3.5.*

3.3 Ejemplos de cálculo

3.3.1 Cálculo vía $A^\top A$ (matriz de rango completo)

Retomemos $A = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix}$ del ejemplo de la sección 2.1.2 y calculemos su SVD.

Paso 1.

$$A^\top A = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix}.$$

Paso 2. Resolvemos $\det(A^\top A - \lambda I) = (5-\lambda)^2 - 1 = 0$, de donde $\lambda_1 = 6$, $\lambda_2 = 4$. Vectores propios normalizados:

$$v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \qquad v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Paso 3. $\sigma_1 = \sqrt{6}$, $\sigma_2 = 2$.

Paso 4. Vectores singulares izquierdos asociados a $\sigma_i \neq 0$:

$$u_1 = \frac{1}{\sqrt{6}} A v_1 = \frac{1}{\sqrt{6}\sqrt{2}} \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix},$$

$$u_2 = \tfrac{1}{2} A v_2 = \tfrac{1}{2\sqrt{2}} \begin{bmatrix} 2 \\ 0 \\ -2 \end{bmatrix} = \tfrac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}.$$

Paso 5. Falta u_3 para completar U a 3×3. Como u_3 debe ser ortonormal a u_1 y u_2, lo construimos por Gram–Schmidt a partir de un candidato simple, e.g., $e_2 = [0, 1, 0]^\top$:

$$\tilde{u}_3 = e_2 - \langle u_1, e_2 \rangle u_1 - \langle u_2, e_2 \rangle u_2 = e_2 - \tfrac{1}{3} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} - 0 = \begin{bmatrix} -\frac{1}{3} \\ \frac{2}{3} \\ -\frac{1}{3} \end{bmatrix},$$

y normalizando $u_3 = \frac{1}{\sqrt{6}}[-1, 2, -1]^\top$. Esto reproduce la SVD ya mostrada en la sección 2.1.2.

3.3.2 Variante: cálculo vía $AA^\top$

Sobre la misma matriz A, calcular en cambio

$$AA^\top = \begin{bmatrix} 4 & 2 & 0 \\ 2 & 2 & 2 \\ 0 & 2 & 4 \end{bmatrix},$$

cuyo polinomio característico se factoriza como $\lambda(\lambda - 4)(\lambda - 6)$. Obtenemos los **tres** valores propios $6, 4, 0$ y los tres vectores propios u_1, u_2, u_3 directamente, sin ortogonalización adicional. Los v_i se recuperan por $v_i = \frac{1}{\sigma_i} A^\top u_i$, sólo para $i = 1, 2$ (no hay v_3 porque A tiene sólo $\min(m, n) = 2$ valores singulares).

Trade-off. $AA^\top$ es 3×3 frente a $A^\top A$ que es 2×2: cuesta más diagonalizar pero obtenemos los vectores singulares del lado "grande" sin necesidad de un paso de ortogonalización. La elección depende de qué dimensión sea menor.

3.3.3 Matriz de rango deficiente

Consideremos

$$A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix}.$$

La tercera columna es la suma de las dos primeras (y, equivalentemente, la tercera fila es la suma de las dos primeras), así que $\operatorname{rango}(A) = 2$. Ninguna fila ni columna es nula: la deficiencia de rango está "escondida" en una dependencia lineal.

Paso 1.

$$A^\top A = \begin{bmatrix} 2 & 1 & 3 \\ 1 & 2 & 3 \\ 3 & 3 & 6 \end{bmatrix}.$$

Paso 2. El polinomio característico es $-\lambda(\lambda - 1)(\lambda - 9)$, de donde $\lambda_1 = 9$, $\lambda_2 = 1$, $\lambda_3 = 0$. Los vectores propios normalizados resultan

$$v_1 = \frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\2\end{bmatrix}, \quad v_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}, \quad v_3 = \frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\-1\end{bmatrix}.$$

Paso 3. $\sigma_1 = 3$, $\sigma_2 = 1$, $\sigma_3 = 0$. Hay sólo dos valores singulares no nulos, en consonancia con el rango.

Paso 4. Vectores singulares izquierdos para $\sigma_i \neq 0$:

$$u_1 = \tfrac{1}{3}Av_1 = \frac{1}{3\sqrt{6}}\begin{bmatrix}3\\3\\6\end{bmatrix} = \frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\2\end{bmatrix},$$

$$u_2 = Av_2 = \frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix}.$$

Paso 5. Completamos U con un vector u_3 ortonormal a u_1 y u_2. Por Gram–Schmidt (o producto cruz $u_1 \times u_2$):

$$u_3 = \frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\-1\end{bmatrix}.$$

Verificación: $A^\top u_3 = \frac{1}{\sqrt{3}}[1+0-1,\ 0+1-1,\ 1+1-2]^\top = 0$, consistente con $\sigma_3 = 0$.

La tercera columna de V es $v_3 = \frac{1}{\sqrt{3}}[1,1,-1]^\top$ (ya calculada en el paso 2). Nótese que $u_3 = v_3$, lo que no es casualidad: A es simétrica, así que su SVD satisface $U = V$ (véase sección 2.5).

SVD completa:

$$A = U\Sigma V^\top = \underbrace{\begin{bmatrix}\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}}\\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}}\\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}}\end{bmatrix}}_{U}\underbrace{\begin{bmatrix}3&0&0\\0&1&0\\0&0&0\end{bmatrix}}_{\Sigma}\underbrace{\begin{bmatrix}\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}}\\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0\\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{3}}\end{bmatrix}}_{V^\top}.$$

3.4 SVD reducida

Cuando $\operatorname{rango}(A) = r < \min(m,n)$, las últimas $\min(m,n) - r$ columnas de U y V no aportan a A (sus valores singulares son cero). La **SVD reducida** descarta esa parte:

$$A = U_r\Sigma_r V_r^\top = \sum_{i=1}^{r}\sigma_i u_i v_i^\top,$$

donde:

- $U_r \in \mathbb{R}^{m\times r}$ contiene las primeras r columnas de U,
- $V_r \in \mathbb{R}^{n\times r}$ contiene las primeras r columnas de V,
- $\Sigma_r \in \mathbb{R}^{r\times r}$ es diagonal con los valores singulares no nulos.

La SVD reducida contiene exactamente la información necesaria para reconstruir A. Ahorra almacenamiento ($r(m+n+1)$ números frente a m^2+mn+n^2 de la SVD completa) y deja implícitos los espacios donde A no actúa (las columnas con $\sigma_i = 0$).

Ejemplo. Para la matriz A de la sección 3.3.3, con $\operatorname{rango}(A) = 2$ y $\sigma_3 = 0$, la SVD reducida descarta u_3, v_3 y la última fila/columna cero de Σ:

$$A = U_2 \Sigma_2 V_2^\top = \underbrace{\begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} \\ \frac{2}{\sqrt{6}} & 0 \end{bmatrix}}_{U_2 \in \mathbb{R}^{3\times 2}} \underbrace{\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}}_{\Sigma_2} \underbrace{\begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{bmatrix}}_{V_2^\top}.$$

Almacenamos $3 \cdot 2 + 2 + 2 \cdot 3 = 14$ valores, frente a $3 \cdot 3 + 3 \cdot 3 + 3 \cdot 3 = 27$ de la SVD completa, sin pérdida de información.

3.5 Comentarios sobre el cálculo numérico en la práctica

El algoritmo anterior es simple, pero **no** es el que usan las bibliotecas numéricas, por dos motivos:

1. **Condicionamiento.** El número de condición de $A^\top A$ es el cuadrado del número de condición de A:

$$\kappa_2(A^\top A) = \kappa_2(A)^2.$$

Para matrices mal condicionadas esto implica pérdida de precisión.

2. **Inestabilidad numérica.** Diagonalizar (es decir, hallar valores y vectores propios de) $A^\top A$ vía polinomio característico no es eficiente ni preciso, como se discutió al tratar la descomposición espectral.

En la práctica se utilizan algoritmos que evitan formar $A^\top A$ o $AA^\top$ explícitamente, y que trabajan directamente con A para obtener la SVD, por ejemplo mediante el algoritmo de Golub–Reinsch (1970) y sus variantes.

> ***Lecturas opcionales para profundizar.*** *Trefethen & Bau, Numerical Linear Algebra, Lectures 4–5 (introducción geométrica) y 31 (algoritmos); Golub & Van Loan, Matrix Computations, sección 8.6 (algoritmos detallados); Higham, Accuracy and Stability of Numerical Algorithms, capítulo 20 (análisis de estabilidad).*

En la práctica, en NumPy:

```python
import numpy as np

A = np.array([[2, 0],
              [1, 1],
              [0, 2]], dtype=float)

# full_matrices=True es el valor por defecto: devuelve SVD completa
U, s, Vt = np.linalg.svd(A, full_matrices=True)   # SVD completa: U (3×3), s (2,), Vt (2×2)
Ur, sr, Vrt = np.linalg.svd(A, full_matrices=False)  # SVD reducida: Ur (3×2), sr (2,), Vrt (2×2)

print(s)   # array con sigma_1, sigma_2 ordenados de mayor a menor
```

`np.linalg.svd` es una interfaz a la rutina `gesdd` de LAPACK (algoritmo *divide-and-conquer*).

---

4. Propiedades y aplicaciones de la SVD

4.1 Normas matriciales

Recordemos las definiciones vistas previamente para las normas de una matriz A y su relación con los valores propios de $A^\top A$:

- **Norma espectral (2-norma):** $\|A\|_2 = \sup_{x\neq 0} \frac{\|Ax\|_2}{\|x\|_2}$. En la unidad anterior vimos que coincide con $\sqrt{\lambda_{\max(A^\top A)}}$ para cualquier matriz, y con $|\lambda_{\max(A)}|$ para matrices simétricas.
- **Norma de Frobenius:** $\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\mathrm{tr}(A^\top A)}$.

A partir de la SVD, podemos reescribir estas relaciones directamente en términos de los valores singulares, sin pasar explícitamente por los valores propios de $A^\top A$:

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \sqrt{\sum_{i=1}^{r} \sigma_i^2}.$$

Esto **no contradice** ni reemplaza las definiciones anteriores: como los σ_i^2 son los autovalores no nulos de $A^\top A$, la fórmula $\sigma_1 = \sqrt{\lambda_{\max(A^\top A)}}$ es la misma expresión ya conocida, ahora expresada en términos de la SVD.

4.2 Número de condición

Para una matriz invertible A definimos $\kappa_2(A) = \|A\|_2 \cdot \|A^{-1}\|_2$. Usando los resultados de la sección 4.1,

$$\kappa_2(A) = \frac{\sigma_1}{\sigma_n}.$$

Para matrices rectangulares o de rango deficiente, la **extensión natural** es $\kappa_2(A) = \sigma_1/\sigma_r$, donde $r = \mathrm{rango}(A)$. Es decir, es el cociente entre el mayor y el menor valor singular no nulo.

4.3 SVD de la transpuesta

Si $A = U\Sigma V^\top$, entonces

$$A^\top = V\Sigma^\top U^\top.$$

Es decir, A y $A^\top$ tienen los mismos valores singulares, y los vectores singulares izquierdo y derecho se intercambian. Consecuencia familiar: $\operatorname{rango}(A) = \operatorname{rango}(A^\top)$.

Ejemplo. Para la matriz $A \in \mathbb{R}^{3\times 2}$ de la sección 3.3.1 con $\sigma_1 = \sqrt{6}$, $\sigma_2 = 2$, la SVD era $A = U\Sigma V^\top$. Entonces la SVD de $A^\top \in \mathbb{R}^{2\times 3}$ es:

$$A^\top = V\Sigma^\top U^\top = \underbrace{\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}}_{V} \underbrace{\begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix}}_{\Sigma^\top} \underbrace{\begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{6}} \end{bmatrix}}_{U^\top}.$$

Los factores ortogonales se intercambian (V pasa a ser el factor izquierdo y $U^\top$ el derecho), y $\Sigma^\top \in \mathbb{R}^{2\times 3}$ es la transpuesta de $\Sigma \in \mathbb{R}^{3\times 2}$. Los valores singulares son los mismos: $\sqrt{6}$ y 2.

4.4 SVD de la inversa

Si A es cuadrada e invertible (rango completo, ningún valor singular nulo), su inversa es

$$A^{-1} = (U\Sigma V^\top)^{-1} = V\Sigma^{-1}U^\top,$$

donde Σ^{-1} es diagonal con entradas $1/\sigma_i$. Esto es ya la SVD de A^{-1}, aunque con los valores singulares en orden inverso: los de A^{-1} son $1/\sigma_n \geq \cdots \geq 1/\sigma_1 > 0$.

Ejemplo. Sea $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$. Como A es simétrica con autovalores $\lambda_1 = 3$ y $\lambda_2 = 1$ (ambos positivos), su SVD tiene $U = V$ y valores singulares $\sigma_1 = 3$, $\sigma_2 = 1$:

$$A = U\Sigma U^\top = \underbrace{\tfrac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}}_{\Sigma} \underbrace{\tfrac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}}_{U^\top}.$$

La inversa, por la fórmula $A^{-1} = V\Sigma^{-1}U^\top = U\Sigma^{-1}U^\top$:

$$A^{-1} = \tfrac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1/3 & 0 \\ 0 & 1 \end{bmatrix} \tfrac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \tfrac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix},$$

que coincide con la fórmula directa $A^{-1} = (\det A)^{-1}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$ con $\det A = 3$.

Los valores singulares de A^{-1} son $1/\sigma_2 = 1$ y $1/\sigma_1 = 1/3$: el mayor y el menor se han invertido, en concordancia con la fórmula $A^{-1} = V\Sigma^{-1}U^\top$.

4.5 Pseudoinversa (esquema)

Cuando A no es invertible — porque no es cuadrada, o porque tiene rango deficiente — la SVD ofrece un camino para pensar en una "transformación inversa" generalizada. Su definición, propiedades y aplicaciones (mínimos cuadrados, sistemas de rango deficiente, regresión lineal) se desarrollarán en notas específicas.

4.6 Aproximación de rango bajo: teorema de Eckart–Young

4.6.1 Motivación: descripciones de rango bajo

En muchas aplicaciones interesa aproximar una matriz por otra de menor rango. La razón es que una matriz de rango k admite una descripción compacta: basta con almacenar k vectores en $\mathbb{R}^m$ y k vectores en $\mathbb{R}^n$, es decir, $k(m+n)$ números en total (incluso menos si se imponen restricciones adicionales, como ortogonalidad). Frente a los mn números de una matriz arbitraria, si $k \ll \min(m,n)$, la descripción reducida puede ser mucho más eficiente.

La SVD ofrece una forma natural de construir aproximaciones de rango bajo a partir de la SVD completa o reducida. El punto de partida es la suma de matrices de rango 1 ya vista:

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top .$$

Cualquier suma parcial de k de estos términos es una matriz de rango $\leq k$, porque cada término individual es de rango 1. En particular, dado que los términos están ordenados por σ_i de mayor a menor, los primeros términos concentran la mayor parte de la "energía" de A y los últimos corresponden a detalles de menor magnitud. Intuitivamente, esto sugiere usar una descripción de rango $k < r$ reteniendo sólo los primeros k términos:

$$A_k := \sum_{i=1}^{k} \sigma_i u_i v_i^\top .$$

El teorema de Eckart-Young establece que esta elección no es sólo natural, sino también óptima: A_k es la mejor aproximación de rango $\leq k$ a A si medimos el error de reconstrucción tanto en norma de Frobenius como en norma espectral.

4.6.2 Mejor aproximación de rango k: teorema de Eckart–Young

Teorema (Eckart–Young–Mirsky). Sea $A \in \mathbb{R}^{m\times n}$ con SVD $A = \sum_{i=1}^{r} \sigma_i u_i v_i^\top$. Para cualquier $k \leq r$, la matriz

$$A_k := \sum_{i=1}^{k} \sigma_i u_i v_i^\top = U_k \Sigma_k V_k^\top$$

es la **mejor aproximación de rango k a A** tanto en norma de Frobenius como en norma espectral. Es decir:

$$A_k = \arg \min_{\substack{B \in \mathbb{R}^{m\times n} \\ \operatorname{rango}(B) \le k}} \|A - B\|_F = \arg \min_{\substack{B \\ \operatorname{rango}(B) \le k}} \|A - B\|_2.$$

Los errores correspondientes son, respectivamente:

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}, \qquad \|A - A_k\|_2 = \sigma_{k+1}.$$

Idea de la demostración (caso Frobenius). Por la invariancia de la norma de Frobenius bajo multiplicación por matrices ortogonales:

$$\|A - B\|_F^2 = \|U^\top (A - B) V\|_F^2 = \|\Sigma - \tilde{B}\|_F^2,$$

donde $\tilde{B} = U^\top B V$ tiene el mismo rango que B. El problema se reduce a aproximar la matriz diagonal Σ por una matriz $\tilde{B}$ de rango $\le k$. La mejor opción es retener las k entradas diagonales más grandes y poner el resto a cero, dando $\|A - A_k\|_F^2 = \sum_{i>k} \sigma_i^2$. Una demostración rigurosa requiere el lema de Weyl para la norma espectral; ver Strang, *Learning from Data*, sección I.9.

4.6.3 Ejemplo

Ejemplo. Para la matriz A de la sección 3.3.3 con $\sigma_1 = 3$, $\sigma_2 = 1$, $\sigma_3 = 0$ y $r = 2$, calculamos la mejor aproximación de rango 1:

$$A_1 = \sigma_1 u_1 v_1^\top = 3 \cdot \tfrac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix} \tfrac{1}{\sqrt{6}} \begin{bmatrix} 1 & 1 & 2 \end{bmatrix} = \tfrac{1}{2} \begin{bmatrix} 1 & 1 & 2 \\ 1 & 1 & 2 \\ 2 & 2 & 4 \end{bmatrix}.$$

El error de esta aproximación:

$$A - A_1 = \begin{bmatrix} \frac{1}{2} & -\frac{1}{2} & 0 \\ -\frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 0 \end{bmatrix}, \qquad \|A - A_1\|_F = 1 = \sigma_2, \qquad \|A - A_1\|_2 = 1 = \sigma_2.$$

La mejor aproximación de rango 2 es $A_2 = A$, puesto que $\operatorname{rango}(A) = 2$; el error es $\|A - A_2\|_F = \|A - A_2\|_2 = 0 = \sigma_3$.

4.6.4 Conexión con PCA

El teorema de Eckart–Young justifica la optimalidad de PCA, ya vista en el curso. Dado un conjunto de datos representado como una matriz X, PCA busca proyectarlos sobre un subespacio de dimensión k que minimice el error de reconstrucción — que es exactamente el problema de mejor aproximación de rango k. La solución, $X_k = U_k \Sigma_k V_k^\top$, determina el subespacio óptimo; sus vectores base son las componentes principales, es decir, los vectores propios de la matriz de covarianza asociados a los k autovalores más grandes. La relación precisa entre SVD y PCA se desarrolla en Deisenroth, Faisal & Ong, §10.7.

4.7 Aplicaciones de la aproximación de rango bajo

La aproximación de matrices por matrices de bajo rango o rango reducido tiene varias aplicaciones en ciencia de datos, aprendizaje automático, procesamiento de señales e imágenes, entre otros:

- **Compresión de imágenes:** una imagen en escala de grises es una matriz de píxeles; truncando su SVD se obtiene una aproximación con reducción de almacenamiento.
- **Eliminación de ruido (denoising):** en muchos casos, la señal vive en un subespacio de baja dimensión y el ruido se distribuye en todos los modos. Retener los k valores singulares dominantes filtra el ruido.
- **Sistemas de recomendación:** ratings usuario × ítem se aproximan por una matriz de rango bajo, donde las dimensiones latentes capturan factores de gusto/género.
- **Latent Semantic Analysis (LSA):** matrices documento × término aproximadas con SVD truncada para revelar temas latentes.